Εθνικό και Καποδιστριακό Πανεπιστήμιο Αθηνών
Τμήμα Πληροφορικής και Τηλεπικοινωνιών

# Deep Learning for NLP

Ονοματεπώνυμο φοιτήτριας: Αγάπη Καλλίνικου
ΑΜ: *sma*2200210

Μάθημα: Τεχνητή Νοημοσύνη ΙΙ (*YS19* M*226* M*262* M*325* M*405*)
Εξάμηνο: Εαρινό Εξάμηνο 2025-2026

## Περιεχόμενα

1 Περίληψη 2

2 Επεξεργασία και Ανάλυση Δεδομένων 2
2.1 Προεπεξεργασία . . . 2
2.2 Ανάλυση . . . 3
2.3 Διαχωρισμός Δεδομένων (train, test και validation) . . . 10
2.4 Διανυσματική Αναπαράσταση Κειμένου . . . 10

3 Αλγόριθμοι και Πειραματική Διαδικασία 11
3.1 Πειραματική Διαδικασία . . . 11
3.1.1 Πίνακας Πειραμάτων . . . 12
3.2 Συντονισμός Υπερπαραμέτρων (Hyper-parameter tuning) . . . 13
3.3 Τεχνικές Βελτιστοποίησης . . . 14
3.4 Αξιολόγηση . . . 14
3.4.1 Καμπύλη Μάθησης . . . 15
3.4.2 Πίνακας Σύγχυσης . . . 16

4 Αποτελέσματα και Συνολική Ανάλυση 17
4.1 Ανάλυση Αποτελεσμάτων . . . 17
4.1.1 Βέλτιστη δοκιμή . . . 18
4.1.2 Πίνακας Σύγχυσης . . . 19
4.1.3 Καμπύλες Μάθησης . . . 20
4.2 Συγκριτική Ανάλυση Σφαλμάτων . . . 20

5 Προτάσεις για Μελλοντική Έρευνα 21

6 Βιβλιογραφία 22

7 Παραρτήματα - Πρόσθετες Θεωρήσεις 23

# 1. Περίληψη

Η παρούσα εργασία πραγματεύεται το πρόβλημα της αυτόματης ανίχνευσης πολιτικών υπεκφυγών σε διαλόγους συνεντεύξεων. Στόχος είναι η ταξινόμηση των πολιτικών τοποθετήσεων σε τρεις κατηγορίες: σαφείς απαντήσεις, σαφείς αρνήσεις και αμφίσημες απαντήσεις. Λόγω της έντονης ανισορροπίας των κλάσεων, δόθηκε ιδιαίτερη έμφαση στη στοχευμένη προεπεξεργασία του κειμένου και στη χρήση σταθμισμένης μάθησης. Στο πειραματικό στάδιο, εφαρμόστηκαν και συγκρίθηκαν εκτενώς δύο διαφορετικές μέθοδοι διανυσματικής αναπαράστασης: η προσέγγιση συχνοτήτων Bag-of-Words μέσω TF-IDF και η χρήση προεκπαιδευμένων πυκνών διανυσμάτων (GloVe), και οι δύο μέσω ταξινομητή Λογιστικής Παλινδρόμησης (Logistic Regression). Η αξιολόγηση μέσω 5-μελούς διασταυρούμενης επικύρωσης (5-fold Cross-Validation) έδειξε ότι το μοντέλο TF-IDF υπερτερεί σημαντικά, επιτυγχάνοντας Macro F1-score 0.5309, καθώς κατόρθωσε να απομονώσει αποτελεσματικά τις λέξεις-κλειδιά που διαφοροποιούν την άμεση απάντηση από την υπεκφυγή. Αντίθετα, η προσέγγιση των πυκνών διανυσμάτων (mean pooling) εμφάνισε αδυναμία σύλληψης της συντακτικής δομής (underfitting). Τέλος, μέσω στοχευμένης ανάλυσης σφαλμάτων, αναδεικνύονται τα όρια των λεξιλογικών προσεγγίσεων απέναντι σε περίπλοκες στρατηγικές πολιτικής υπεκφυγής, επιβεβαιώνοντας την ανάγκη μετάβασης σε σύγχρονα γλωσσικά μοντέλα για την κατανόηση του βαθύτερου σημασιολογικού πλαισίου.

# 2. Επεξεργασία και Ανάλυση Δεδομένων

## 2.1. Προεπεξεργασία

Ο καθαρισμός και η κατάλληλη προεπεξεργασία των δεδομένων αποτελεί ένα πρωταρχικό, εξαιρετικά κρίσιμο στάδιο, δεδομένου ότι η ποιότητα των δεδομένων της εισόδου καθορίζει σε μεγάλο βαθμό την απόδοση των προβλεπτικών μοντέλων. Στο πλαίσιο της παρούσας εργασίας, εφαρμόστηκε βελτιστοποίηση της ποιότητας του συνόλου δεδομένων και καθαρισμός τους από οτιδήποτε θα μπορούσε δυνητικά να αποτελέσει 'θόρυβο' και να αλλοιώσει την επίδοση του μοντέλου. Τα βήματα που ακολουθήθηκαν παρουσιάζονται παρακάτω ενώ, επίσης, παρατίθεται παράδειγμα κειμένου πριν και μετά την επεξεργασία στην ενότητα των παραρτημάτων.

1. Προπαρασκευή κειμενικών δεδομένων:
   Πριν από την εφαρμογή οποιασδήποτε τεχνικής καθαρισμού δεδομένων, πραγματοποιήθηκε αυστηρός έλεγχος δομικής ακεραιότητας, με σκοπό την αφαίρεση προβληματικών εγγραφών. Πιο συγκεκριμένα, η διαδικασία επικεντρώθηκε σε δύο άξονες:

   (α′) Διαγραφή Ελλιπών Τιμών:
   Πραγματοποιήθηκε έλεγχος για εγγραφές που παρουσίαζαν κενές τιμές σε κάποιο από τα δοσμένα πεδία, με στόχο την αποφυγή ασυνεπειών κατά την επεξεργασία των δεδομένων της εισόδου και, εν γένει, τη μείωση ρίσκου μελλοντικών αστοχιών. Δεν εντοπίστηκε καμία τέτοια εγγραφή.

   (β′) Αφαίρεση Διπλότυπων Εγγραφών:
   Διαγράφηκαν 58 πανομοιότυπα ζεύγη ερωτήσεων και απαντήσεων, κρατώντας μόνο μία εγγραφή για κάθε περίπτωση, καθώς η εκπαίδευση σε διπλότυπα δεδομένα εισάγει ανεπιθύμητη προκατάληψη (bias) και αυξάνει τον κίνδυνο υπερεκπαίδευσης σε συγκεκριμένα μοτίβα, με αποτέλεσμα την αλλοίωση της μετέπειτα αξιολόγησης του συστήματος.

(γ′) Μορφοποίηση Εισόδου:
Για κάθε εγγραφή, η ερώτηση του δημοσιογράφου και η αντίστοιχη απάντηση του πολιτικού ενοποιήθηκαν σε ένα ενιαίο κείμενο με τη χρήση του ειδικού διαχωριστικού `SEPTOKEN`, αφού πρώτα η ερώτηση και η απάντηση είχαν τροποποιηθεί κατάλληλα κατά τη φάση του καθαρισμού δεδομένων. Η προσέγγιση αυτή επιτρέπει στο μοντέλο να επεξεργαστεί τα δύο πεδία ως ένα ενιαίο σημασιολογικό πλαίσιο.

2. Καθαρισμός δεδομένων:

Αρχικά, το σύνολο του κειμένου μετατράπηκε σε πεζούς χαρακτήρες, ενέργεια μείζονος σημασίας, καθώς οι αλγόριθμοι εξαγωγής χαρακτηριστικών διακρίνουν πεζά από κεφαλαία (case-sensitive). Έτσι, διασφαλίστηκε ότι λέξεις σημασιολογικά κοινές (π.χ. 'Government' και 'government') θα ταυτίζονται, μειώνοντας την περιττή διαστατικότητα του λεξιλογίου.

Έπειτα, απομακρύνθηκαν ενδεχόμενοι υπερσύνδεσμοι (URLs), αριθμητικές τιμές, σημεία στίξης αλλά και λέξεις και προτάσεις εξαιρετικά μικρού μήκους. Τα στοιχεία αυτά προσθέτουν μόνο 'θόρυβο' στα δεδομένα και σπάνια φέρουν ουσιαστική σημασία για την κατηγοριοποίηση της σαφήνειας μιας απάντησης.

Τέλος, πραγματοποιήθηκε φιλτράρισμα και, εν τέλει, εξαίρεση των λέξεων κενού περιεχομένου (stopwords) της αγγλικής γλώσσας. Ωστόσο, κατά τις αρχικές δοκιμές παρατηρήθηκε το εξής πρόβλημα: η αφαίρεση λέξεων που συνδέονται σημασιολογικά με άρνηση (π.χ. 'no', 'not', 'never') αλλοίωνε θεμελιωδώς το νόημα των προτάσεων. Για παράδειγμα, στην 3η εγγραφή του συνόλου, η φράση '*look there is no doubt*' μετατράπηκε σε '*look doubt*', δηλαδή η αφαίρεση του 'no' ήταν αρκετή ώστε να αντιστρέψει πλήρως την αρχική σημασιολογία. Επειδή το φαινόμενο αυτό αναπόφευκτα υποβαθμίζει την ικανότητα ταξινόμησης του μοντέλου, η συνάρτηση clean_text προσαρμόστηκε ώστε να εξαιρεί ρητά τις λέξεις άρνησης από τη λίστα των stopwords, εξασφαλίζοντας την αυτούσια διατήρηση του νοήματος.

## 2.2. Ανάλυση

Προκειμένου να κατανοηθεί σε βάθος η δομή και οι ιδιαιτερότητες του συνόλου δεδομένων, η διαδικασία της προεπεξεργασίας πραγματοποιήθηκε παράλληλα με την Εξερευνητική Ανάλυση Δεδομένων (Exploratory Data Analysis - EDA), με στόχο την οπτικοποίηση των δεδομένων και την εξαγωγή κρίσιμων στατιστικών συμπερασμάτων. Αξίζει να σημειωθεί ότι η ανάλυση της κατανομής των κλάσεων και του μήκους των κειμένων πραγματοποιήθηκε στα αρχικά, ακατέργαστα δεδομένα. Αυτό κρίθηκε ως η βέλτιστη πρακτική, προκειμένου να αποτυπωθεί η πραγματική δομή του dataset πριν υποστεί την οποιαδήποτε αλλοίωση. Αντίθετα, για την περαιτέρω ανάλυση του λεξιλογίου (π.χ. εξαγωγή των πιο συχνών λέξεων), τα δεδομένα υποβλήθηκαν πρώτα στην πλήρη διαδικασία καθαρισμού.

Αρχικά, στην ανάλυση εξετάστηκε η προέλευση των δηλώσεων, με το σύνολο των 3.448 δειγμάτων να μοιράζεται σε τέσσερις προέδρους των ΗΠΑ: Donald J. Trump (1.325), Barack Obama (1.010), George W. Bush (714) και Joseph R. Biden (399). Επίσης, πραγματοποιήθηκε ανάλυση του μήκους των κειμένων για την κατανόηση της δομής τους. Τα αποτελέσματα παρουσιάζονται αναλυτικά στον Πίνακα 1. Σημειώνουμε ότι η υψηλή τυπική απόκλιση υποδηλώνει μεγάλη μεταβλητότητα στην έκταση του πολιτικού λόγου, όπως άλλωστε ήταν αναμενόμενο.

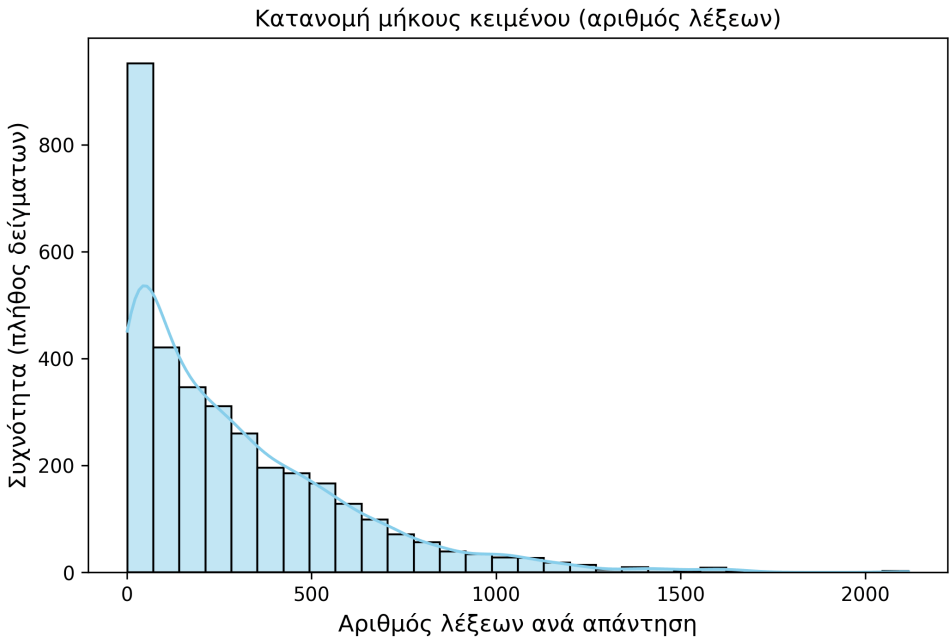


Σχήμα 1: Κατανομή μήκους κειμένου (αριθμός λέξεων).

Πίνακας 1: Στατιστικά στοιχεία μήκους κειμένων (word count) σε στρογγυλοποίηση

| Στατιστικό Μέγεθος | Τιμή |
|---|---|
| Πλήθος Δειγμάτων Λέξεων (Count) | 3.390 |
| Μέσος Όρος (Mean) | 294,02 |
| Τυπική Απόκλιση (Std) | 300,96 |
| Ελάχιστο (Min) | 1 |
| 25% (Πρώτο Τεταρτημόριο) | 58,25 |
| Διάμεσος (50%) | 208 |
| 75% (Τρίτο Τεταρτημόριο) | 440 |
| Μέγιστο (Max) | 2.117 |

Όπως αποτυπώνεται στο Σχήμα 1, η κατανομή συγκεντρώνεται κυρίως στα αριστερά, γεγονός που υποδηλώνει τη γενικότερη τάση των πολιτικών προσώπων για σύντομες και περιεκτικές δηλώσεις κατά τη διάρκεια των συνεντεύξεων. Παράλληλα, εντοπίζεται περιορισμένος αριθμός ακραίων τιμών (outliers), οι οποίες αντιστοιχούν σε απαντήσεις μεγαλύτερου όγκου κειμένου. Η μελέτη του μήκους του κειμένου φέρνει σημαντικά συμπεράσματα, καθώς στο πλαίσιο της ανίχνευσης υπεκφυγών, μια υπερβολικά εκτενής απάντηση ενδέχεται να υποκρύπτει προσπάθεια αποπροσανατολισμού ενώ μια εξαιρετικά βραχεία ενδέχεται να υποδηλώνει απόλυτη αμεσότητα ή κάθετη άρνηση τοποθέτησης.

Σύμφωνα με το Σχήμα 2, παρατηρείται μια έντονη ανισορροπία (class imbalance) στα δεδομένα. Η συντριπτική κυριαρχία της αμφίσημης κατηγορίας αντανακλά τη φύση του πολιτικού λόγου, όπου τα πολιτικά πρόσωπα συχνά επιλέγουν έμμεσες ή διπλωματικές τοποθετήσεις αντί για ευθείες απαντήσεις.

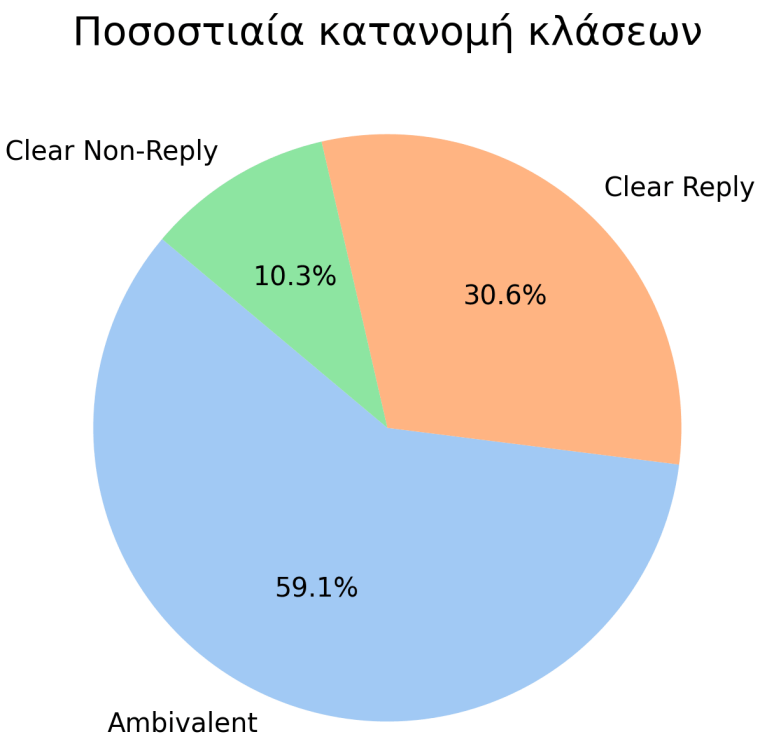


Σχήμα 2: Ποσοστιαία κατανομή κλάσεων.

Φυσικά, επειδή κατά την εκπαίδευσή του το μοντέλο θα εκτίθεται διαρκώς σε παραδείγματα της κατηγορίας `Ambivalent`, ενδέχεται να αναπτύξει μεροληψία (bias) και να αρχίσει να προβλέπει συνεχώς τη συγκεκριμένη κλάση, αγνοώντας, για παράδειγμα, την κατηγορία `Clear Non-Reply` η οποία διαθέτει πολύ λιγότερα παραδείγματα. Έτσι επιβεβαιώνεται και η αναγκαιότητα για τη χρήση εντολής στρωματοποιημένης δειγματοληψίας (`stratify`), προκειμένου να διατηρηθεί αυτή η αναλογία αυτούσια και στο εκάστοτε validation set.

Σχήμα 3: Λεξιλόγιο σαφών απαντήσεων.

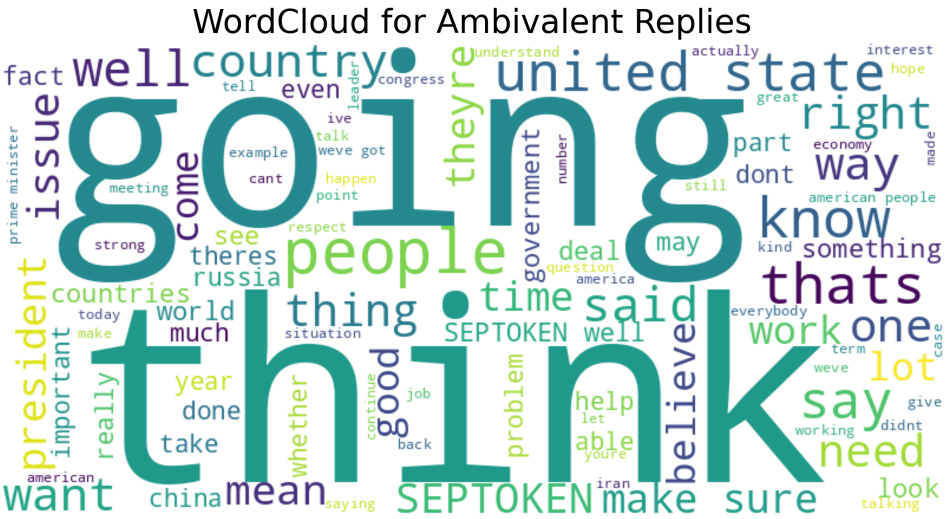


Σχήμα 4: Λεξιλόγιο αμφίσημων απαντήσεων.

Η οπτικοποίηση που προκύπτει αναδεικνύει σημαντικές διαφοροποιήσεις ως προς τις λεξιλογικές επιλογές των πολιτικών. Συγκεκριμένα, το νέφος λέξεων των σαφών απαντήσεων (Σχήμα 3) συγκροτείται από ένα σαφώς πιο άμεσο, απόλυτο και στοχευμένο λεξιλόγιο. Αντίθετα, το νέφος λέξεων των αμφίσημων απαντήσεων (Σχήμα 4) εμπεριέχει σε πολύ μεγαλύτερη συχνότητα όρους επιφύλαξης, εκφράσεις διστακτικότητας, αλλά και λέξεις που υποδηλώνουν υποθετικό λόγο.

Τέλος, για περαιτέρω κατανόηση των γλωσσικών μοτίβων που κυριαρχούν στο σύνολο δεδομένων, πραγματοποιήθηκε η εξής ανάλυση:

Σχήμα 5: Οι 15 συχνότερες λέξεις στο σύνολο εκπαίδευσης.

Επειδή η μελέτη μεμονωμένων όρων συχνά στερείται ευρύτερου νοηματικού πλαισίου, η ανάλυση επεκτάθηκε στην εξαγωγή των συχνότερων bigrams, καθώς αυτή αναδεικνύει χαρακτηριστικές φράσεις-κλειδιά που χρησιμοποιούνται στις συνεντεύξεις.

Αξίζει να σημειωθεί πως η εξαιρετικά υψηλή συχνότητα εμφάνισης του ειδικού token `SEPTOKEN`, το οποίο αποτελεί δομικό διαχωριστικό του dataset, είναι απολύτως αναμενόμενη, καθώς υπάρχει σε κάθε δείγμα. Ωστόσο, η παρουσία του δεν διακρίνει ουσιωδώς τις κλάσεις και, ως εκ τούτου, αναμένεται να αγνοηθεί τελικά από το μοντέλο.

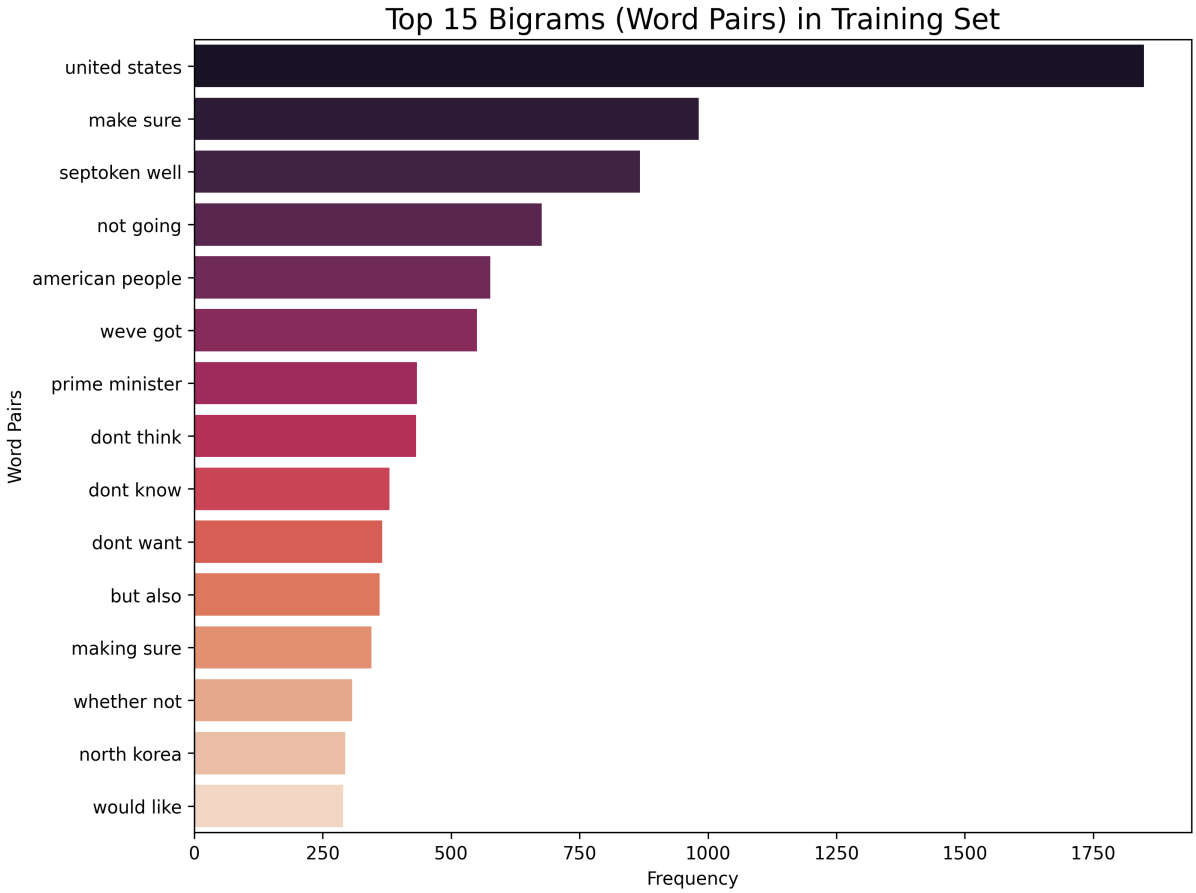


Σχήμα 6: Τα 15 συχνότερα ζεύγη λέξεων στο σύνολο εκπαίδευσης.

Τέλος, εξήχθησαν τα 15 (**unigrams** και **bigrams**) με το μεγαλύτερο βάρος για κάθε κλάση. Η ανάλυση αυτών των όρων προσφέρει πολύτιμες γλωσσολογικές πληροφορίες για τη στρατηγική των πολιτικών:

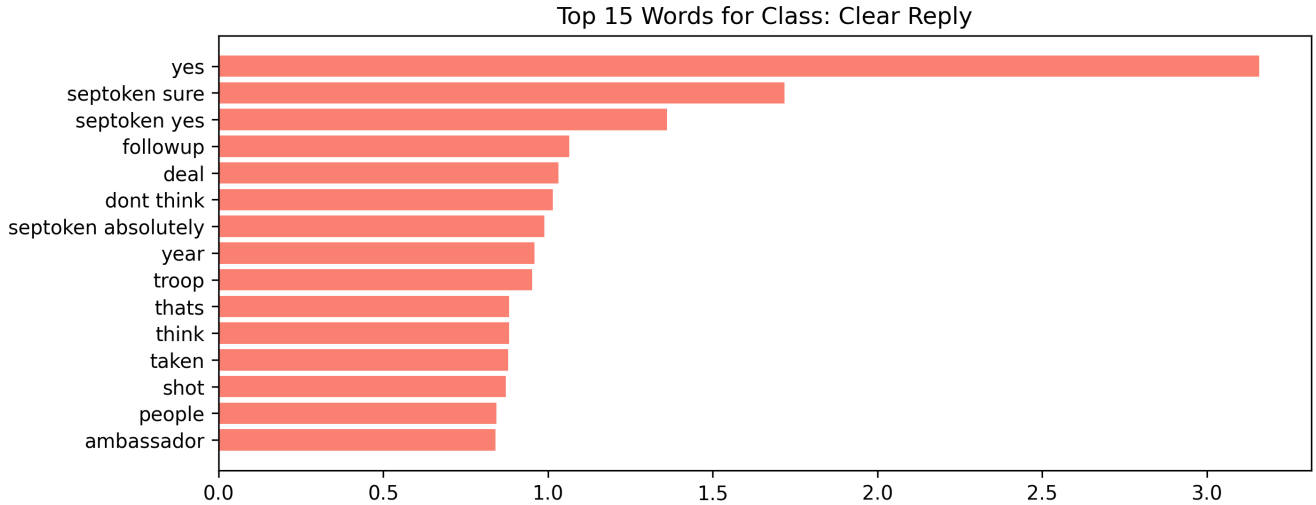


Σχήμα 7: Clear Reply

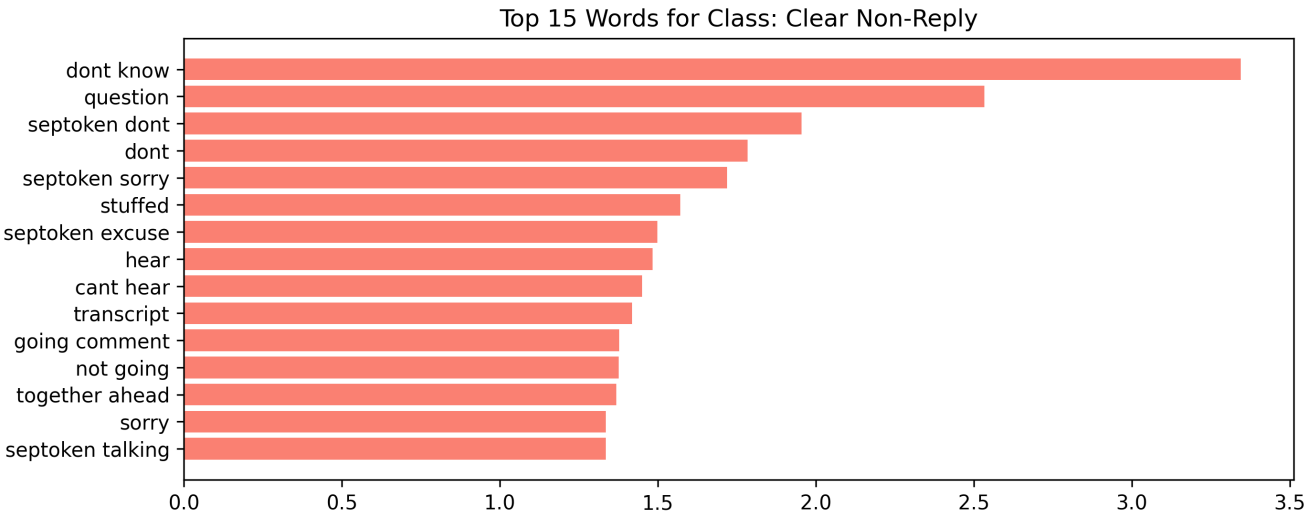


Σχήμα 8: Clear Non-Reply

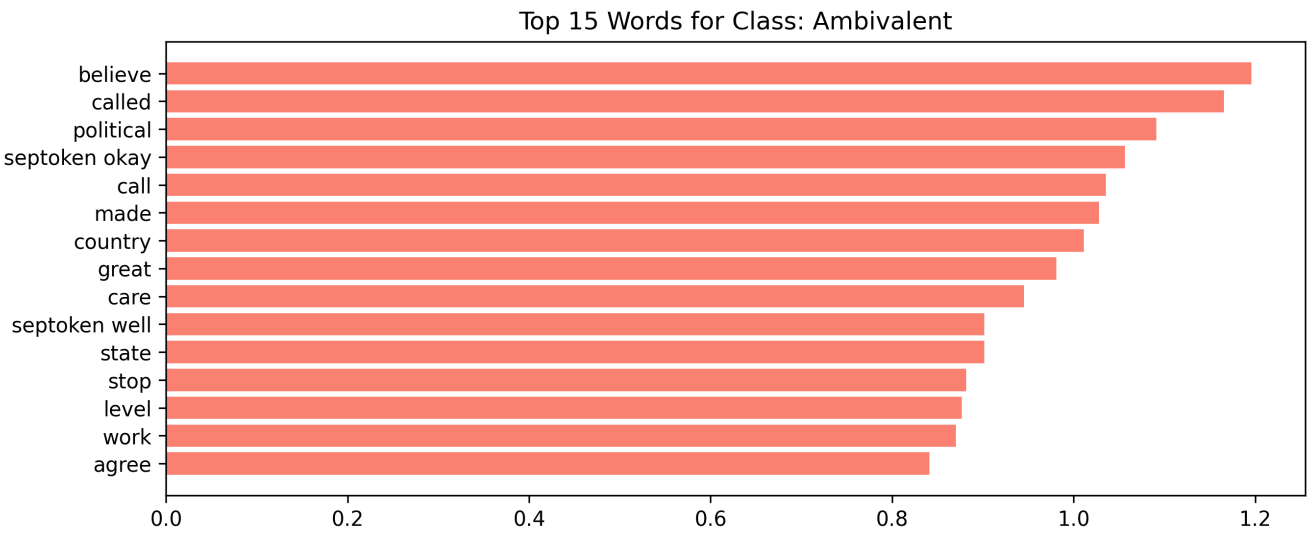


Σχήμα 9: Ambivalent

- **Clear Reply**: Το λεξιλόγιο κυριαρχείται από απόλυτες και άμεσες καταφάσεις ('yes', 'sure', 'absolutely', 'deal'). Το ενδιαφέρον στοιχείο εδώ είναι η εμφάνιση διγραμμάτων με το septoken (septoken yes, septoken sure). Αυτό υποδηλώνει ότι στις σαφείς απαντήσεις, ο πολιτικός δίνει την επιβεβαίωση αμέσως μετά την ερώτηση.

- **Clear Non-Reply**: Σε αυτή την κλάση εντοπίζεται ακριβώς η αντίθετη συμπεριφορά, δηλαδή η άμεση άρνηση. Εκφράσεις όπως 'dont know', 'sorry' και 'cant hear' δείχνουν ξεκάθαρη αποφυγή και άρνηση τοποθέτησης. Ξανά, η εμφάνιση διγραμμάτων όπως το septoken sorry δείχνει ότι η άρνηση εκφράζεται ευθέως στην αρχή της πρότασης.

- **Ambivalent**: Εδώ, καθότι είναι η ενότητα της υπεκφυγής, απουσιάζουν εντελώς οι λέξεις άμεσης κατάφασης ή άρνησης. Αντιθέτως, παρατηρούνται στρατηγικές καθυστέρησης, όπως 'septoken okay' και 'septoken well'. Ο ομιλητής ξεκινά με λέξεις 'γεμίσματος', ενώ στη συνέχεια χρησιμοποιεί αφηρημένους όρους ('country', 'state',

'political') και ρήματα υποκειμενικής γνώμης ('believe', 'agree'), προκειμένου να χτίσει μια εκτενή αλλά μη ουσιώδη απάντηση.

### 2.3. Διαχωρισμός Δεδομένων (**train**, **test** και **validation**)

Για την ανάπτυξη και την αξιολόγηση των μοντέλων, αξιοποιήθηκε το επίσημο σύνολο δεδομένων του διαγωνισμού SemEval 2026 (Task 6). Η βασική κατάτμηση σε σύνολο εκπαίδευσης (train set) και σύνολο δοκιμής (test set) διατηρήθηκε όπως καθορίστηκε από τους διοργανωτές. Επομένως, η αξιολόγηση κατά τη διάρκεια της ανάπτυξης βασίστηκε στο σύνολο εκπαίδευσης. Ωστόσο, αντί για έναν απλό στατικό διαχωρισμό σε σύνολα εκπαίδευσης και επικύρωσης, επιλέχθηκε η μέθοδος της διασταυρούμενης επικύρωσης 5 επιπέδων (5-fold Cross-Validation). Σύμφωνα με αυτή, το σύνολο εκπαίδευσης χωρίστηκε σε πέντε ισομερή τμήματα. Σε κάθε επανάληψη, το μοντέλο εκπαιδευόταν σε τέσσερα τμήματα και αξιολογούταν στο πέμπτο, το οποίο λειτουργούσε ως σύνολο επικύρωσης. Η προσέγγιση αυτή θεωρείται βέλτιστη, καθώς επιτρέπει την πλήρη αξιοποίηση των δεδομένων και παρέχει μια πιο αξιόπιστη εκτίμηση της απόδοσης του μοντέλου, μειώνοντας ταυτόχρονα την πιθανότητα μεροληψίας που θα μπορούσε να προκύψει από έναν τυχαίο μοναδικό διαχωρισμό.

Επιπλέον, λόγω της σημαντικής ανισορροπίας που παρατηρήθηκε στις κλάσεις, χρησιμοποιήθηκε η τεχνική της στρωματοποίησης (stratification), ώστε να διασφαλιστεί ότι η αναλογία του ποσοστού κάθε κλάσης της στήλης clarity_label διατηρείται ακριβώς η ίδια με εκείνη που προϋπήρχε στο αρχικό σύνολο, αποτρέποντας ενδεχόμενη μεροληψία του αλγορίθμου.

Τέλος, ορίστηκε μια σταθερή τιμή αρχικοποίησης (random_state=2004), προκειμένου να διασφαλιστεί η πλήρης επαναληψιμότητα των πειραμάτων. Ωστόσο, αξίζει να αναφερθεί πως, λόγω μη-ντετερμινιστικών παραγόντων χαμηλού επιπέδου (όπως το multi-threading κατά την εκτέλεση σε διαφορετικά περιβάλλοντα, για παράδειγμα τοπικά έναντι των servers του Kaggle), ενδέχεται να παρατηρηθούν ελάχιστες, στατιστικά μη σημαντικές, διαφοροποιήσεις στα δεκαδικά ψηφία των score.

### 2.4. Διανυσματική Αναπαράσταση Κειμένου

Η μετατροπή του φυσικού κειμένου σε αριθμητικά διανύσματα είναι, γενικότερα, απαραίτητη για την εκπαίδευση των αλγορίθμων μηχανικής μάθησης. Στην παρούσα εργασία, εφαρμόστηκαν δύο διαφορετικές προσεγγίσεις διανυσματοποίησης: η μέθοδος bag-of-words μέσω TF-IDF και η χρήση πυκνών διανυσμάτων λέξεων (Word Embeddings). Η διανυσματοποίηση αυτή εφαρμόστηκε στο ενοποιημένο κείμενο ([ΕΡΩΤΗΣΗ] `SEPTOKEN` [ΑΠΑΝΤΗΣΗ]), το οποίο αποτελεί την είσοδο του μοντέλου.

1. Αναπαράσταση με **TF-IDF (Term Frequency - Inverse Document Frequency):**

   Η μέθοδος αυτή υπολογίζει τη σπουδαιότητα κάθε λέξης (ή φράσης) με βάση το πόσο συχνά εμφανίζεται στο συγκεκριμένο δείγμα, αλλά και το πόσο σπάνια εντοπίζεται στο σύνολο του dataset, αντιμετωπίζοντας έτσι τις λέξεις που δεν προσφέρουν στη διάκριση των κλάσεων. Για τη βελτιστοποίηση του διανυσματικού χώρου και τη μείωση του θορύβου, ρυθμίστηκαν οι εξής υπερπαράμετροι:

   - ***N-grams (ngram_range=(1,2)):*** Εξήχθησαν τόσο μεμονωμένες λέξεις (unigrams) όσο και ζεύγη λέξεων (bigrams). Η χρήση bigrams είναι κρίσιμη στο συγκεκριμένο πρόβλημα, καθώς αιχμαλωτίζει εκφράσεις και μοτίβα άρνησης ή υπεκφυγής (όπως 'not sure', 'can't tell'), αλλά και συχνές φράσεις (όπως 'United States').

- Φιλτράρισμα Συχνοτήτων (***max_df=0.80, min_df=2):*** Αγνοήθηκαν όροι που εμφανίζονται σε περισσότερο από το 80% των κειμένων, καθώς δεν προσφέρουν διαχωριστική αξία, αλλά και οι όροι που εμφανίζονται σπανιότερα από 2 φορές στο σύνολο εκπαίδευσης, για αποφυγή overfitting σε σπάνιες λέξεις και εξειδικευμένες ορολογίες.
- Υπογραμμική Κλιμάκωση (***sublinear_tf=True***): Εφαρμόστηκε λογαριθμική κλιμάκωση στη συχνότητα των όρων ($1 + log(tf)$, αντί για $tf$), γεγονός το οποίο μειώνει την επίδραση των λέξεων που επαναλαμβάνονται υπερβολικά πολλές φορές μέσα στην απάντηση του πολιτικού.

2. Αναπαράσταση με Προεκπαιδευμένα **Word Embeddings (GloVe)**:

   Ως δεύτερη προσέγγιση, χρησιμοποιήθηκε το προεκπαιδευμένο μοντέλο glove-wiki-gigaword-100 μέσω της βιβλιοθήκης gensim, το οποίο μετατρέπει κάθε λέξη σε ένα πυκνό διάνυσμα 100 διαστάσεων. Η διαδικασία διανυσματοποίησης για κάθε ζεύγος ερωτοαπάντησης ακολούθησε τα εξής βήματα:

   - ***Tokenization***: Το κείμενο διασπάστηκε σε μεμονωμένα tokens (λέξεις), χρησιμοποιώντας την βιβλιοθήκη nltk.
   - Φιλτράρισμα ***OOV (Out-Of-Vocabulary):*** Λέξεις που δεν υπήρχαν στο λεξιλόγιο του προεκπαιδευμένου GloVe μοντέλου αγνοήθηκαν.
   - Άθροιση και Μέσος Όρος ***(Mean Pooling)***: Το τελικό διάνυσμα του κειμένου υπολογίστηκε παίρνοντας τον μέσο όρο των διανυσμάτων όλων των έγκυρων λέξεων που το συνθέτουν. Σε περίπτωση που ένα κείμενο δεν περιείχε καμία έγκυρη λέξη, αναπαραστάθηκε από ένα μηδενικό διάνυσμα (npżeros).
   - Κανονικοποίηση (***Scaling***): Επειδή τα διανύσματα που προκύπτουν περιέχουν θετικές και αρνητικές τιμές διαφόρων κλιμάκων, εφαρμόστηκε, πριν την τροφοδότησή τους στον ταξινομητή (Logistic Regression), κανονικοποίηση Min-Max (MinMaxScaler). Η μέθοδος αυτή περιορίζει τις τιμές κάθε χαρακτηριστικού στο διάστημα $[0, 1]$. Αυτό είναι ένα ιδιαίτερα κρίσιμο βήμα για τη Λογιστική Παλινδρόμηση, διότι διασφαλίζει ότι όλες οι διαστάσεις του διανύσματος συμμετέχουν ισότιμα, αποτρέποντας την κυριαρχία χαρακτηριστικών με απλώς μεγαλύτερες απόλυτες τιμές και εξασφαλίζοντας παράλληλα τη σωστή σύγκλιση του αλγορίθμου βελτιστοποίησης.

   Μετά το πέρας της παραπάνω διαδικασίας, το τελικό σύνολο δεδομένων εκπαίδευσης (train set) μετασχηματίστηκε σε έναν πίνακα διαστάσεων 3390x100.

## 3. Αλγόριθμοι και Πειραματική Διαδικασία

### 3.1. Πειραματική Διαδικασία

Η προσέγγιση του προβλήματος ξεκίνησε με αρχική δοκιμή (brute-force run), όπου τα δεδομένα χωρίστηκαν στατικά κατά 80%-20% (εκπαίδευση-αξιολόγηση) για λόγους ταχύτητας. Ωστόσο, κατά τη βελτιστοποίηση, διαπιστώθηκε πως αυτή η μέθοδος δεν παρείχε επαρκή αξιοπιστία, γεγονός που οδήγησε στην υιοθέτηση της διασταυρούμενης επικύρωσης (Cross-Validation).

Μία από τις μεγαλύτερες προκλήσεις ήταν η έντονη ανισορροπία των κλάσεων. Στην αρχική εκτέλεση, το μοντέλο εμφάνισε ισχυρή μεροληψία, "μαντεύοντας" διαρκώς την πλειοψηφική κλάση. Η εισαγωγή της παραμέτρου class_weight="balanced" στον ταξινομητή κρίθηκε απαραίτητη, καθώς ανάγκασε το μοντέλο να αποδώσει ίση σημασία σε όλες τις κλάσεις.
Όσον αφορά την επιλογή των χαρακτηριστικών και την επεξεργασία, πραγματοποιήθηκαν τα εξής πειράματα:

- (***Lemmatization***) ***vs*** (***Stemming***): Στο μοντέλο TF-IDF εφαρμόστηκε lemmatization, καθώς ο ίδιος παράγει υπαρκτές λέξεις και η λημματοποίηση βοηθάει δυνητικά τον αλγόριθμο. Αντίθετα, στην προσέγγιση GloVe, αποφεύχθηκε τόσο το stemming όσο και η λημματοποίηση, καθώς η αλλοίωση των καταλήξεων (π.χ. 'speaking' σε 'speaki') θα δημιουργούσε λέξεις εκτός λεξιλογίου για το προεκπαιδευμένο μοντέλο GloVe, οδηγώντας έτσι σε απώλεια κρίσιμης σημασιολογικής πληροφορίας (π.χ. θα χανόταν η διάκριση μεταξύ 'politician' και 'political' αν και τα δύο γραφόντουσαν ως 'politic').

- Εκπαίδευση ***GloVe***: Αρχικά, επιχειρήθηκε η εκπαίδευση ενός μοντέλου Word2Vec αποκλειστικά πάνω στο δοθέν dataset. Το πείραμα αυτό απέτυχε λόγω του μικρού μεγέθους του συνόλου δεδομένων και της δυσκολίας διαχείρισης ειδικών λέξεων. Τελικά, επιλέχθηκε το προεκπαιδευμένο μοντέλο glove-wiki-gigaword-100, το οποίο προσφέρει πλούσιες σημασιολογικές αναπαραστάσεις και ταχύτερη φόρτωση.

3.1.1. Πίνακας Πειραμάτων. Στον παρακάτω πίνακα (Πίνακας 2) συνοψίζονται οι σημαντικότερες πειραματικές μεταβάσεις των οποίων τα αποτελέσματα οδήγησαν στο τελικό μοντέλο.

| Πείραμα (**Trial**) | **TF-IDF Score** | **GloVe Score** | Παρατηρήσεις |
|---|---|---|---|
| Brute-Force (No Class Weights) | Χαμηλό | Χαμηλό | Αποτυχία λόγω imbalance |
| Προσθήκη class_weight="balanced" | Σημαντική Αύξηση | Σημαντική Αύξηση | Ισορροπημένη μάθηση |
| Word2Vec from scratch | - | Αποτυχία | Ανεπαρκή δεδομένα (OOV) |
| Pre-trained GloVe-100 | - | 0.4281 | Επιτυχής ενσωμάτωση |
| Περιορισμός max_features=5000 | $\approx 0.5000$ | 0.4281 | Πτώση απόδοσης στο TF-IDF |

Πίνακας 2: Σύνοψη βασικών πειραμάτων και επιπτώσεων στην απόδοση (Macro F1-score)

.

Επιπλέον, πραγματοποιήθηκε σειρά πειραμάτων με διαφορετικές ρυθμίσεις κανονικοποίησης (L1, L2) και διαφορετικούς επιλύτες (solvers) προκειμένου να βρεθεί η βέλτιστη αρχιτεκτονική. Διαπιστώθηκε πως ο solver `saga` αντιμετώπισε προβλήματα, ενώ ο `liblinear` σε συνδυασμό με `L1` penalty (Lasso) έδειξε την καλύτερη συμπεριφορά. Τα συγκριτικά αποτελέσματα (Macro F1-Score) για τα χειροκίνητα πειράματα των δύο προσεγγίσεων συνοψίζονται στον Πίνακα 3.

Πίνακας 3: Αποτελέσματα Πειραμάτων με Logistic Regression (TF-IDF & GloVe)

| Προσέγγιση | Πείραμα / Υπερπαράμετροι | **Mean Macro F1** |
|---|---|---|
| TF-IDF | Baseline (C=1.0, L2) | 0.5131 |
| TF-IDF | Grid Search Best (C=3.0) | 0.5213 |
| TF-IDF | Final Optimized (C=2.0, max_df=0.80) | 0.5309 |
| GloVe | Baseline (L2, C=1.0, solver="lbfgs") | 0.4112 |
| GloVe | L2, C=0.1, solver='lbfgs' | 0.3986 |
| GloVe | L1, C=1.0, solver='liblinear' | 0.4054 |
| GloVe | L1, C=0.1, solver='saga' (Απέτυχε) | 0.3523 |
| GloVe | L1, C=10.0, solver='liblinear' | 0.4235 |
| GloVe | L1, C=5.0, solver='liblinear' | 0.4279 |
| GloVe | L1, C=4.5, solver='liblinear' (**Best**) | 0.4281 |

### 3.2. Συντονισμός Υπερπαραμέτρων (**Hyper-parameter tuning**)

Κατά τη φάση της βελτιστοποίησης, διερευνήθηκε επιπλέον το αντίκτυπο των υπερπαραμέτρων στην απόδοση του μοντέλου.

Πίνακας 4: Επίδραση του μεγέθους λεξιλογίου (max_features) στο Macro F1

| Όριο Λεξιλογίου | **TF-IDF Score** | **GloVe Score** |
|---|---|---|
| 3.000 λέξεις | 0.4957 | 0.4281 |
| 5.000 λέξεις | $\approx$ 0.5000 | 0.4281 |
| Χωρίς όριο (**Full**) | 0.5213 | 0.4281 |

Πίνακας 5: Επίδραση της αποκοπής συχνών όρων (max_df)

| **max_df** | **TF-IDF Score** | **GloVe Score** |
|---|---|---|
| 0.80 | 0.5213 | 0.4281 |
| 0.90 | 0.5213 | 0.4281 |
| 0.95 | 0.5213 | 0.4279 |

Επιπλέον, ιδιαίτερο ενδιαφέρον παρουσίασε η ρύθμιση των n-grams. Η μετάβαση από ngram_range=(1,2) σε (1,3) αύξησε το τοπικό Macro F1-score στο σύνολο επικύρωσης (από 0.5213 σε 0.5242). Κατά την υποβολή, όμως, των προβλέψεων στο Kaggle, δηλαδή σε μη ιδωμένα δεδομένα, το score μειώθηκε από 0.60 σε 0.57. Αυτό αποδεικνύει ότι τα trigrams ανάγκασαν το μοντέλο να απομνημονεύσει εξειδικευμένες φράσεις του training set, χάνοντας την ικανότητα γενίκευσης. Συνεπώς, επιλέχθηκε οριστικά το ngram_range=(1,2).

Τέλος, όσον αφορά την επιλογή χαρακτηριστικών και τη βελτιστοποίηση του μοντέλου **GloVe**, πραγματοποιήθηκε ξεχωριστή αναζήτηση πλέγματος (GridSearchCV) για την εύρεση της ιδανικής τιμής της παραμέτρου κανονικοποίησης `C` με solver `liblinear` και penalty `L1`. Η διαδικασία εκτελέστηκε σε δύο φάσεις:

1. **Fine Search:** Δοκιμάστηκαν τιμές από 5.0 έως 15.0, όπου η τιμή C=5.0 έδωσε το καλύτερο αρχικό Macro F1 (0.4279).

2. **Extra Fine Search:** Η αναζήτηση επικεντρώθηκε γύρω από το 5.0 (από 2.5 έως 7.5), αναδεικνύοντας ως οριστικό νικητή την τιμή **C**=4.5 με Macro F1-score 0.4281.

Η επιλογή της κανονικοποίησης L1 αποδείχθηκε καθοριστική, καθώς μηδενίζει τα βάρη περιττών χαρακτηριστικών, μαθαίνοντας να τα αγνοεί, καθιστώντας έτσι περιττή την οποιαδήποτε περαιτέρω χειροκίνητη αφαίρεση. Παράλληλα, μειώνει τον κίνδυνο υπερεκπαίδευσης. Παρατηρήθηκε πως πολύ μικρές τιμές του C (π.χ. 0.1) προκαλούσαν υποεκπαίδευση, καθώς το μοντέλο γινόταν υπερβολικά απλό σε σχέση με την πολυπλοκότητα των δεδομένων (με το F1 να πέφτει κάτω από 0.35), ενώ το C=4.5 βρήκε τη χρυσή τομή μεταξύ bias και variance.

Εν κατακλείδι, οι βέλτιστες υπερπαράμετροι που προέκυψαν για τα δύο τελικά μοντέλα είναι οι εξής:

Πίνακας 6: Βέλτιστες Υπερπαράμετροι ανά Μοντέλο

| Μοντέλο | Υπερπαράμετρος | Τιμή |
|---|---|---|
| **TF-IDF + Logistic Regression** | C | 2.0 (Κανονικοποίηση L2) |
| | max_df | 0.80 |
| | min_df | 2 |
| | ngram_range | (1, 2) |
| **GloVe + Logistic Regression** | C | 4.5 |
| | penalty | L1 (Lasso) |
| | solver | liblinear |

### 3.3. Τεχνικές Βελτιστοποίησης

Για τη βελτιστοποίηση της απόδοσης, αξιοποιήθηκε ο επιλυτής L-BFGS, μια gradient-based μέθοδος, η οποία κρίνεται ιδανική για προβλήματα πολλαπλών κλάσεων. Παράλληλα, εφαρμόστηκε L2 κανονικοποίηση (Ridge Penalty). Η επιλογή της L2 αποτελεί βέλτιστη πρακτική για αραιά δεδομένα κειμένου (όπως αυτά που παράγει ο TF-IDF), καθώς εξασφαλίζει ότι τα διανύσματα διατηρούν κανονικοποιημένο μήκος, περιορίζοντας την προκατάληψη (bias) που θα προκαλούσε το διαφορετικό μήκος των συνεντεύξεων στον αλγόριθμο (π.χ. φλύαρες έναντι λακωνικών απαντήσεων).

Η στρατηγική εύρεσης των βέλτιστων υπερπαραμέτρων σχεδιάστηκε σε δύο στάδια. Αρχικά, πραγματοποιήθηκαν χειροκίνητες δοκιμές σε ακραίες καταστάσεις, προκειμένου να διερευνηθεί η συμπεριφορά των solvers και των penalties και να εντοπιστούν οι περιοχές τιμών που παρουσιάζουν το μεγαλύτερο ενδιαφέρον. Παρατηρήθηκε πως το μοντέλο βελτίωνε αισθητά την απόδοσή του όταν η αντίστροφη παράμετρος κανονικοποίησης (C) κυμαινόταν γύρω από την τιμή 10. Βασιζόμενοι σε αυτή τη γνώση, στο δεύτερο στάδιο εκτελέστηκε αναζήτηση πλέγματος (GridSearchCV) στοχευμένα γύρω από αυτή τη 'γειτονιά' τιμών. Η προσέγγιση αυτή μεγιστοποίησε την ακρίβεια της βελτιστοποίησης και την ταχύτητα υλοποίησης του αλγορίθμου.

### 3.4. Αξιολόγηση

Η επιλογή της κατάλληλης μετρικής για την αξιολόγηση αποτέλεσε απόφαση κρίσιμης σημασίας, λόγω της έντονης ανισορροπίας των κλάσεων. Ενώ πλατφόρμες όπως το Kaggle

ενδέχεται να υπολογίζουν το τελικό score βάσει του σταθμισμένου μέσου (Weighted F1-score), για την εσωτερική αξιολόγηση των πειραμάτων κρίθηκε ως καταλληλότερη και πιο 'αυστηρή' μετρική το Macro F1-score.

Στο Weighted F1, το τελικό αποτέλεσμα κυριαρχείται από την απόδοση της πλειοψηφικής κλάσης, γεγονός που μπορεί να δώσει μια ψευδαίσθηση υψηλής απόδοσης, κρύβοντας την αδυναμία του μοντέλου να εντοπίσει τις μειοψηφικές κλάσεις. Αντίθετα, το Macro F1-score εξάγει τον αδιαμόρφωτο μέσο όρο των F1-scores κάθε κλάσης. Αν το μοντέλο αποτύχει στην κλάση του 10.3%, το Macro F1 θα υποβαθμιστεί σημαντικά, καθιστώντας το την πιο αντιπροσωπευτική και 'ειλικρινή' μετρική για την παρούσα εργασία. Για τον λόγο αυτό δόθηκε μικρότερη βαρύτητα στο γενικό Accuracy ή τα Weighted Precision/Recall.

Για την πλήρη αξιολόγηση και σύγκριση των δύο προσεγγίσεων, παραθέτονται οι τελικές Macro μετρικές κατά την 5-μελή διασταυρούμενη επικύρωση (5-fold CV) και για τα δύο βελτιστοποιημένα μοντέλα:

Πίνακας 7: Συνολικά Αποτελέσματα (Όλες οι μετρικές είναι Macro)

| Μοντέλο | **Accuracy** | **Precision** | **Recall** | **F1-Score** |
|---|---|---|---|---|
| **TF-IDF + Log. Reg.** | 0.5850 | 0.5346 | 0.5277 | 0.5309 |
| GloVe + Log. Reg. | 0.5625 | 0.4462 | 0.4476 | 0.4281 |

3.4.1. Καμπύλη Μάθησης. Για την αξιολόγηση της συμπεριφοράς του μοντέλου **GloVe + Logistic Regression** συναρτήσει του όγκου των δεδομένων, εξήχθη η καμπύλη μάθησης, η οποία παρουσιάζεται στο Σχήμα 10.

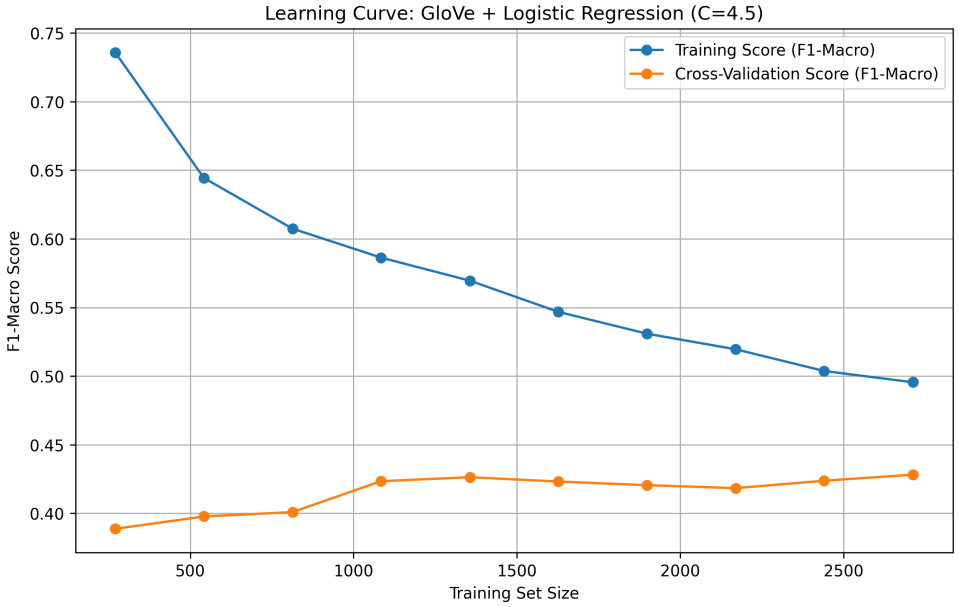


Σχήμα 10: Καμπύλη Μάθησης για το βέλτιστο μοντέλο GloVe (C=4.5, L1 penalty).

Παρατηρούμε, αρχικά, ότι με μικρό αριθμό δεδομένων εκπαίδευσης, η μπλε καμπύλη (Training Score) είναι υψηλή, ενώ η πορτοκαλί (Cross-validation Score) χαμηλή, υποδεικνύοντας αρχική τάση υπερεκπαίδευσης. Ωστόσο, καθώς ο όγκος των παραδειγμάτων

εκπαίδευσης αυξάνεται (προσεγγίζοντας τα 2500+ δείγματα), οι δύο καμπύλες ομαλοποιούνται και συγκλίνουν, αποδεικνύοντας ότι το μοντέλο μαθαίνει και γενικεύει καλύτερα. Η τελική σταθεροποίηση του Cross-validation Score γύρω στο 0.43, με την ύπαρξη ενός φυσιολογικού κενού από το Training Score, δείχνει ότι η κανονικοποίηση L1 λειτούργησε αποτελεσματικά, περιορίζοντας το overfitting. Ωστόσο, η αδυναμία του μοντέλου να ανταποκριθεί ακόμα και σε δείγματα του ίδιου του training set υποδηλώνει μια τάση **underfitting** (υψηλό **bias**). Συμπεραίνουμε πως η απλοϊκή προσέγγιση του μέσου όρου των διανυσμάτων οδηγεί σε απώλεια κρίσιμης σημασιολογικής πληροφορίας, εμποδίζοντας τον ταξινομητή να επιτύχει υψηλότερες αποδόσεις.

Συγκριτικά, η τελική και βελτιστοποιημένη Καμπύλη Μάθησης του TF-IDF (C=2.0, L2) παρουσιάζεται στην Ενότητα 4.1.3.

3.4.2. Πίνακας Σύγχυσης. Η αποτίμηση των προβλέψεων του βέλτιστου μοντέλου του **GloVe** ανά κλάση αποτυπώνεται οπτικά στον κανονικοποιημένο Πίνακα Σύγχυσης του Σχήματος 11. Συγκριτικά, ο αντίστοιχος Πίνακας Σύγχυσης του βέλτιστου μοντέλου TF-IDF παρατίθεται στην Ενότητα 4.1.2, όπου και αποτυπώνεται η σαφώς ανώτερη ικανότητά του να διαχωρίζει τις μειοψηφικές κλάσεις.

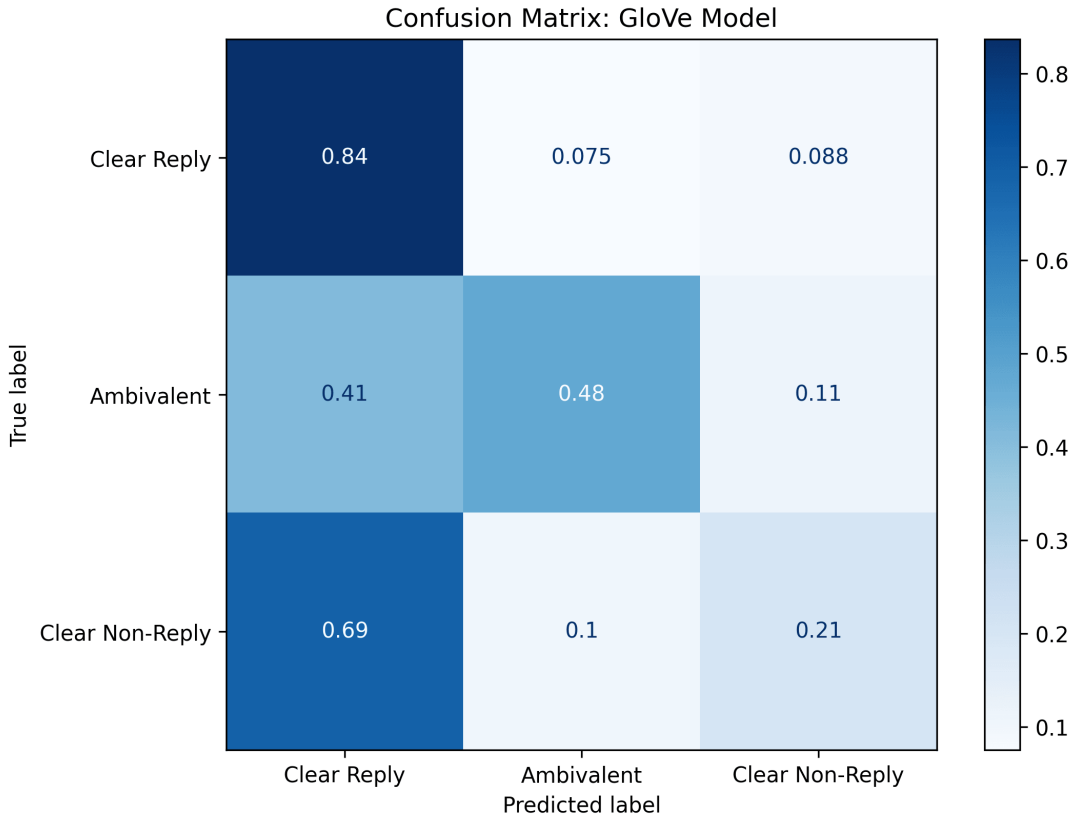


Σχήμα 11: Κανονικοποιημένος Πίνακας Σύγχυσης για το βέλτιστο μοντέλο του Γλοέ.

Αναλύοντας τα ποσοστά του πίνακα, εξάγουμε τα εξής συμπεράσματα για τη συμπεριφορά του μοντέλου:

- Υψηλή απόδοση στην κλάση **Clear Reply**: Το μοντέλο αναγνωρίζει με μεγάλη επιτυχία (84%) τις ξεκάθαρες απαντήσεις, κάνοντας ελάχιστα λάθη προς τις άλλες δύο κλάσεις. Η γενική τάση του μοντέλου είναι να 'υπερπροβλέπει'την κλάση Clear Reply,

χάνοντας τις λεπτές συντακτικές και υφολογικές αποχρώσεις που διαφοροποιούν μια αληθινή απάντηση από μια υπεκφυγή ή μια διφορούμενη τοποθέτηση.

- Σύγχυση στην κλάση **Ambivalent**: Ενώ προβλέπει σωστά το 48% των διφορούμενων απαντήσεων, ένα πολύ μεγάλο ποσοστό (41%) ταξινομείται λανθασμένα ως Clear Reply. Αυτό επιβεβαιώνει ότι, με τη χρήση απλού μέσου όρου διανυσμάτων, οι λέξεις που συνθέτουν μια ασαφή πολιτική απάντηση τείνουν να ταυτίζονται σημασιολογικά με εκείνες μιας ξεκάθαρης, μπερδεύοντας τον ταξινομητή.

- Αδυναμία στη μειοψηφική κλάση **Clear Non-Reply:** Η συγκεκριμένη κλάση αποτελεί τη μεγαλύτερη αδυναμία του μοντέλου. Προβλέπεται σωστά μόλις το 21% των περιπτώσεων, ενώ το 69% των πραγματικών Clear Non-Reply προβλέπονται λανθασμένα ως Clear Reply. Το γεγονός ότι το ποσοστό αυτό δεν μηδενίστηκε, οφείλεται στην παράμετρο `class_weight='balanced'`, η οποία απέτρεψε την πλήρη αγνόηση της κλάσης.

# 4. Αποτελέσματα και Συνολική Ανάλυση

## 4.1. Ανάλυση Αποτελεσμάτων

Αναλύοντας τα διαγράμματα και τα αποτελέσματα των μετρικών, εξάγονται σημαντικά συμπεράσματα για τη συμπεριφορά των δύο προσεγγίσεων:

- Συμπεριφορά ***TF-IDF*** (***Overfitting***): Παρότι το μοντέλο TF-IDF σημείωσε την καλύτερη συνολικά απόδοση, η ανάλυση της Καμπύλης Μάθησης αποκαλύπτει έντονα φαινόμενα υπερεκπαίδευσης. Το μοντέλο τείνει να 'αποστηθίζει' το σύνολο εκπαίδευσης, καθώς η υψηλής διαστατικότητας και αραιή φύση των διανυσμάτων TF-IDF αυξάνει τη διακύμανση (variance) του μοντέλου. Αυτό επιβεβαιώνεται και από τον Πίνακα Σύγχυσης των training data, όπου η ικανότητα ταξινόμησης είναι εξαιρετικά υψηλή (ειδικά για την κυρίαρχη κλάση Ambivalent), όμως το μοντέλο δυσκολεύεται να μεταφέρει αυτή την επιτυχία στα άγνωστα δεδομένα. Ωστόσο, είναι σημαντικό να παρατηρήσουμε τη σταθερά ανοδική πορεία της καμπύλης επικύρωσης στην καμπύλη μάθησης του μοντέλου (Σχήμα14). Αυτό υποδηλώνει ότι ο αλγόριθμος συνεχίζει να μαθαίνει και να γενικεύει καλύτερα καθώς προστίθενται νέα παραδείγματα, πράγμα που προτείνει ότι η παροχή μεγαλύτερου όγκου δεδομένων πιθανότατα θα βελτίωνε περαιτέρω την τελική του απόδοση.

- Συμπεριφορά ***GloVe*** (**Underfitting**): Αντίθετα, η προσέγγιση του GloVe εμφάνισε σαφή σημάδια υποεκπαίδευσης, αδυνατώντας να μοντελοποιήσει επαρκώς ακόμα και τα δεδομένα εκπαίδευσης. Αυτό το φαινόμενο υποδεικνύει αρχιτεκτονική ανεπάρκεια. Τα πυκνά και χαμηλής διαστατικότητας διανύσματα του GloVe επιβάλλουν μια ισχυρή μεροληψία. Αφενός, η γραμμική φύση του αλγορίθμου της Λογιστικής Παλινδρόμησης δεν αρκεί για να συλλάβει τις πολύπλοκες και μη-γραμμικές σημασιολογικές εξαρτήσεις των διανυσμάτων. Αφετέρου, όπως αναφέρθηκε στην Ενότητα 2.4, η τεχνική του Mean Pooling που χρησιμοποιήθηκε για την παραγωγή του τελικού διανύσματος τείνει να εξομαλύνει και να 'χάνει' το ισχυρό σήμα συγκεκριμένων λέξεων-κλειδιών (όπως τα yes, no, sorry). Αντίθετα, το TF-IDF διατηρεί και ενισχύει τη βαρύτητα αυτών των λέξεων, γεγονός που αποδείχθηκε κρίσιμο για το συγκεκριμένο πρόβλημα.

Συμπερασματικά, η επίδοση του τελικού μοντέλου (Weighted F1-score στο leaderboard του Kaggle: 0.60 σε μη ιδωμένα δεδομένα ) κρίνεται ως μια ιδιαίτερα ικανοποιητική και σταθερή βάση (baseline), δεδομένου ότι το μοντέλο βασίζεται αποκλειστικά σε συχνότητες λέξεων (TF-IDF) και σε ένα απλό γραμμικό μοντέλο (Logistic Regression). Αυτό το όριο στην απόδοση ήταν σε μεγάλο βαθμό αναμενόμενο. Η μέθοδος TF-IDF, αν και εξαιρετική στο να εντοπίζει συγκεκριμένες λέξεις-κλειδιά (όπως φάνηκε από την ανάλυση των σημαντικότερων χαρακτηριστικών), αγνοεί πλήρως τη σύνταξη, τη δομή του διαλόγου και το βαθύτερο σημασιολογικό πλαίσιο (context). Ειδικά στην κλάση των υπεκφυγών, οι πολιτικοί συχνά χρησιμοποιούν περίπλοκη δομή λόγου που ένα απλό bag-of-words μοντέλο αδυνατεί να αποκωδικοποιήσει. Για τον λόγο αυτό, αν υπήρχε η χρονική δυνατότητα για περισσότερους πειραματισμούς, μια υποσχόμενη πρακτική θα ήταν η εξαγωγή χαρακτηριστικών (Feature Engineering). Η εισαγωγή στοχευμένων χειροκίνητων μεταβλητών, όπως η αναλογία μήκους μεταξύ ερώτησης και απάντησης, καθώς και ο εντοπισμός συγκεκριμένων συντακτικών μοτίβων, αναμένεται να ενισχύσει σημαντικά τη διαχωριστική ικανότητα του μοντέλου, παρέχοντας πληροφορίες δομής που το TF-IDF δεν μπορεί να κατανοήσει.

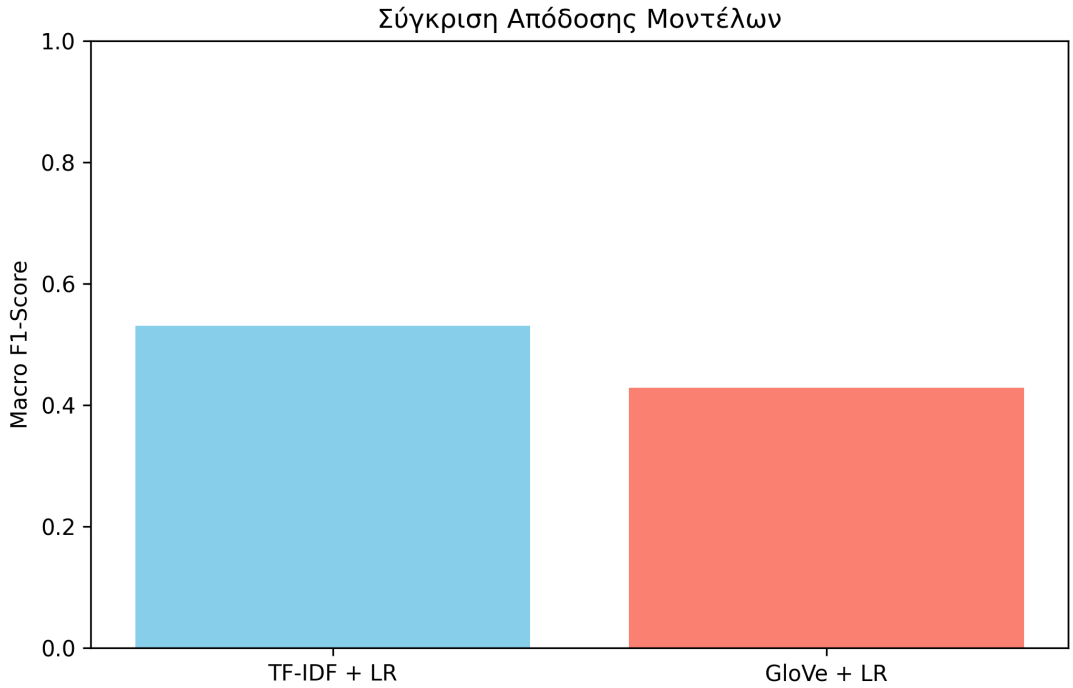


Σχήμα 12: Σύγκριση συνολικής απόδοσης (Macro F1-Score) των βέλτιστων μοντέλων TF-IDF και GloVe.

4.1.1. Βέλτιστη δοκιμή. Έπειτα από εκτενή πειραματισμό και ρύθμιση των υπερπαραμέτρων, η τελική μορφή του pipeline του βέλτιστου μοντέλου διαμορφώθηκε ως εξής:

- Ταξινομητής (**Logistic Regression**): Επιλέχθηκε η μέθοδος βελτιστοποίησης `lbfgs` (`max_iter=1000`) με ποινή κανονικοποίησης L2. Ο συντελεστής κανονικοποίησης ρυθμίστηκε στο **C**=2, μειώνοντας την αρχική τάση υπερεκπαίδευσης. Τέλος, για την αντιμετώπιση της ανισορροπίας των κλάσεων του dataset, εισήχθηκε η παράμετρος `class_weight=''balanced''`.

4.1.2. Πίνακας Σύγχυσης. Ο πίνακας σύγχυσης (Σχήμα 13) αποκαλύπτει τη συμπεριφορά του βέλτιστου μοντέλου (TF-IDF + Logistic Regression) ανά κλάση.

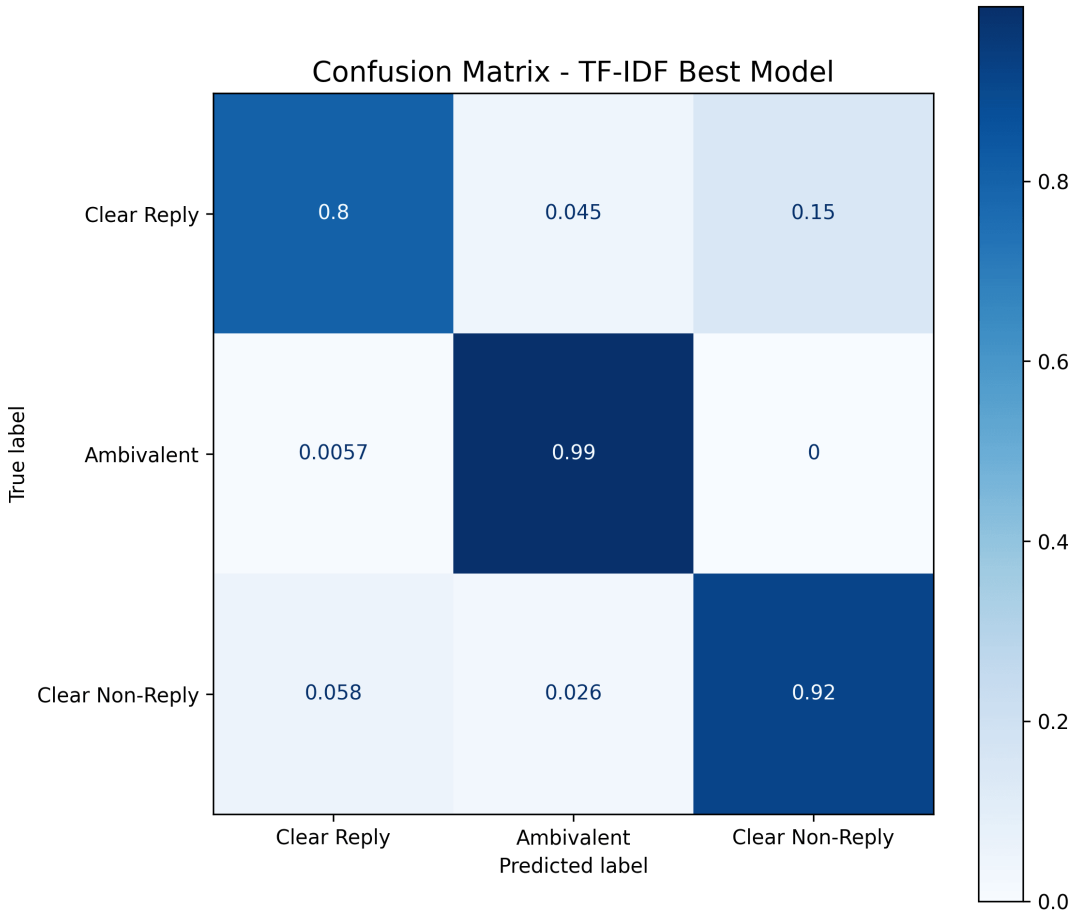


Σχήμα 13: Πίνακας Σύγχυσης Βέλτιστου Μοντέλου.

Αναλύοντας τα αποτελέσματα, προκύπτουν οι εξής παρατηρήσεις:

- Εξαιρετικά υψηλή απόδοση: Το μοντέλο αγγίζει την τέλεια ταξινόμηση στην κλάση *Ambivalent* (αναγνωρίζει το 99%) και πολύ υψηλή απόδοση στην *Clear Non-Reply* (92%). Επιπλέον, δεν μπερδεύει σχεδόν ποτέ μια πραγματική *Ambivalent* απάντηση με *Clear Non-Reply* (ποσοστό 0%).

- Δυσκολίες: Η κλάση *Clear Reply* παρουσιάζει το χαμηλότερο ποσοστό σωστών προβλέψεων (80%), καθώς το 15% αυτών συγχέεται λανθασμένα με την *Clear Non-Reply*.

Τα ποσοστά αυτά επιβεβαιώνουν την ισχυρή τάση του TF-IDF να υπερπροσαρμόζεται, 'αποστηθίζοντας' το συγκεκριμένο λεξιλόγιο των δεδομένων εκπαίδευσης. Ωστόσο, βοηθούμενο και από την παράμετρο `class_weight = 'balanced'`, έμαθε τελικά να απομονώνει με ακρίβεια τις χαρακτηριστικές λέξεις-κλειδιά των υπεκφυγών.

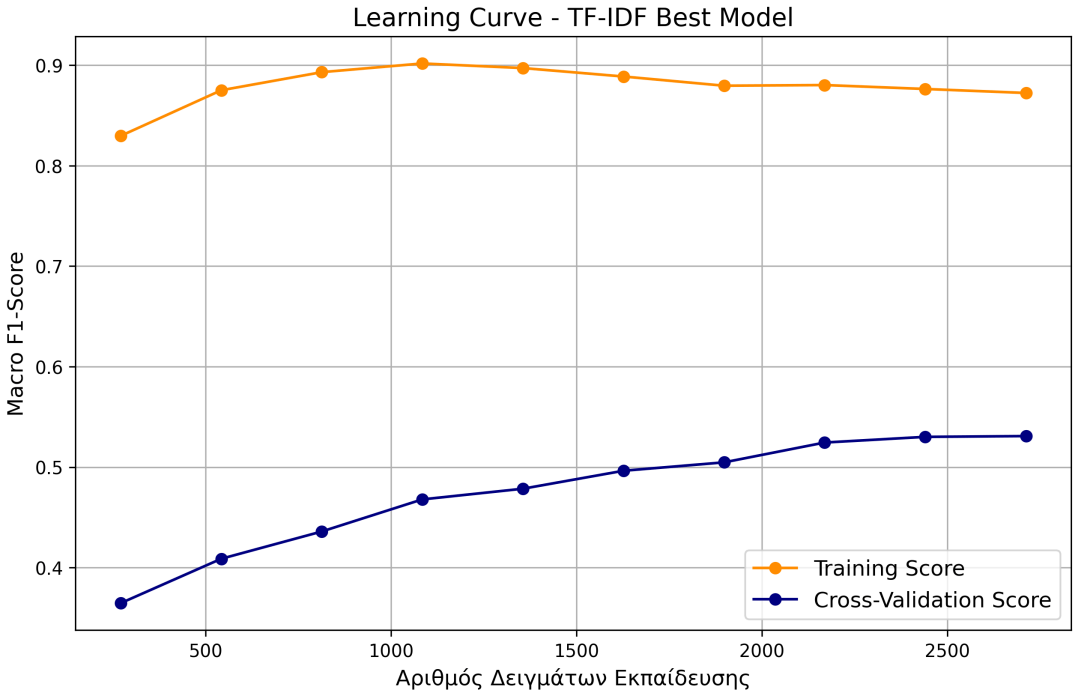


Σχήμα 14: Learning Curve του τελικού μοντέλου.

4.1.3. Καμπύλες Μάθησης. Όπως φαίνεται στο Σχήμα 14, η μεγάλη απόκλιση μεταξύ του Training Score (άνω του 0.85) και του Cross-Validation Score (κάτω του 0.55) επιβεβαιώνει την τάση υπερεκπαίδευσης του TF-IDF. Αξίζει να σημειωθεί πως παρόμοια μορφή με έντονο χάσμα παρουσίασαν και οι καμπύλες μάθησης κατά τα ενδιάμεσα στάδια βελτιστοποίησης. Το φαινόμενο αυτό είναι αναπόφευκτο και οφείλεται στη φύση του TF-IDF, καθώς η δημιουργία πολλών αραιών features σε σχέση με τον περιορισμένο όγκο δειγμάτων επιτρέπει στο μοντέλο να διαχωρίζει σχεδόν τέλεια το set εκπαίδευσης, καθιστώντας την τάση για overfitting κύριο χαρακτηριστικό της συγκεκριμένης προσέγγισης, παρά τις παρεμβάσεις της κανονικοποίησης L2.

## 4.2. Συγκριτική Ανάλυση Σφαλμάτων

(Σημείωση: Στο Παράρτημα Β παρατίθεται μια εκτενής λίστα με τα σοβαρά λάθη ταξινόμησης του βέλτιστου μοντέλου).

Συγκρίνοντας τις προβλέψεις των δύο μοντέλων, εντοπίστηκαν τα δυνατά και τα αδύναμα σημεία της κάθε προσέγγισης:

- Περιπτώσεις όπου το ***GloVe*** ήταν σωστό και το ***TF-IDF*** έκανε λάθος (657 παραδείγματα): Το GloVe τα πηγαίνει καλύτερα όταν η απάντηση δεν έχει τις ίδιες ακριβώς λέξεις με την ερώτηση, καθώς κατανοεί τη σημασιολογική συνάφεια. Αντίθετα, το TF-IDF συχνά μπερδευόταν περιμένοντας ακριβές ταίριασμα λέξεων, όπως στο παρακάτω παράδειγμα όπου 'ξεγελάστηκε' από την επανάληψη του όρου 'human right':
  ΚΕΙΜΕΝΟ: 'putting strategic interest human right vietnam SEPTOKEN inaudibleabove human right ive raised every person met withthank'
  ΠΡΑΓΜΑΤΙΚΟΤΗΤΑ: Ambivalent | ΛΑΘΟΣ ΠΡΟΒΛΕΨΗ TF-IDF: Clear Reply

- Περιπτώσεις όπου το **TF-IDF** ήταν σωστό και το **GloVe** έκανε λάθος (454 παραδείγματα): Το TF-IDF υπερτερεί στα μεγάλα κείμενα επειδή εντοπίζει συγκεκριμένες σπάνιες

λέξεις-κλειδιά. Αντίθετα, το GloVe χρησιμοποιεί τον μέσο όρο των διανυσμάτων, με αποτέλεσμα σε μεγάλες απαντήσεις το νόημα να 'αραιώνεται' και να χάνονται οι σημαντικές λέξεις. Στο παρακάτω παράδειγμα, το GloVe 'έχασε' τις λέξεις δισταγμού ('still open', 'let see'):
ΚΕΙΜΕΝΟ: 'envisioning possibility permanent military base finland [SEP] like told discussing dca defense cooperation agreement lot element still open but open negotiation know counterpart also open let see'
ΠΡΑΓΜΑΤΙΚΟΤΗΤΑ: Ambivalent | ΛΑΘΟΣ ΠΡΟΒΛΕΨΗ GloVe: Clear Non-Reply

Το γεγονός ότι το GloVe διόρθωσε 657 λάθη του TF-IDF, ενώ αυτό είναι το βέλτιστο μοντέλο, αλλά το TF-IDF διόρθωσε μόνο 454 λάθη του GloVe, εξηγείται από την έντονη ανισορροπία των κλάσεων. Το GloVe είναι ικανό στο να εντοπίζει σωστά τα δείγματα της πλειοψηφικής κλάσης, κερδίζοντας έτσι σε απόλυτο αριθμό σωστών προβλέψεων, αλλά δυσκολεύεται στις μειοψηφικές κλάσεις, στις οποίες το TF-IDF παρουσιάζει σχετική άνεση. Επειδή η μετρική Macro F1 δίνει την ίδια ακριβώς βαρύτητα σε όλες τις κλάσεις, το TF-IDF επιτυγχάνει το καλύτερο συνολικό score.

## 5. Προτάσεις για Μελλοντική Έρευνα

Η παρούσα εργασία θα μπορούσε να επεκταθεί, με στόχο τη μεγιστοποίηση της απόδοσης και της ικανότητας γενίκευσης, στις εξής κατευθύνσεις:

- Χρήση Μη-Γραμμικών Ταξινομητών για το ***GloVe***: Δεδομένου ότι η Λογιστική Παλινδρόμηση οδήγησε σε υποεκπαίδευση στην περίπτωση του GloVe, θα είχε αρκετό ερευνητικό ενδιαφέρον η δοκιμή πιο περίπλοκων, μη-γραμμικών αλγορίθμων, όπως ένα πολυστρωματικό νευρωνικό δίκτυο (Multi-Layer Perceptron - MLP) ή Μηχανές Διανυσμάτων Υποστήριξης (SVM) με μη-γραμμικούς πυρήνες (RBF kernel).

- Αξιολόγηση Μοντέλων **Transformer** (**BERT**): Μια εξαιρετικά υποσχόμενη μελλοντική έρευνα θα ήταν η αντικατάσταση του TF-IDF με σύγχρονα, προεκπαιδευμένα γλωσσικά μοντέλα, όπως το BERT. Η εκπαίδευση ενός τέτοιου μοντέλου (το οποίο κατανοεί το βαθύτερο πλαίσιο μέσω contextualized embeddings) στα ίδια δεδομένα και η άμεση σύγκριση των αποτελεσμάτων με αυτά των μεθόδων που παρουσιάστηκαν και αναλύθηκαν στην παρούσα εργασία θα μπορούσε να αποφέρει ενδιαφέροντα συμπεράσματα.

- Προηγμένη Διαχείριση Ανισορροπίας (**Data Augmentation & SMOTE**): Πέραν της χρήσης της class_weights, θα μπορούσαν να εφαρμοστούν τεχνικές συνθετικής υπερδειγματοληψίας (π.χ. SMOTE, με χρήση κατάλληλων μαθηματικών μεθόδων) ή τεχνικές επαύξησης κειμένου (text augmentation), όπως η μετάφραση με επιστροφή (back-translation), για τον τεχνητό εμπλουτισμό των παραδειγμάτων της αδύναμης κλάσης Clear Non-Reply.

- Συνδυαστικά Μοντέλα (**Ensemble Learning**): Η δημιουργία ενός ταξινομητή ψηφοφορίας (Voting Classifier) που θα συνδυάζει την ισχυρή λεξιλογική αναγνώριση του TF-IDF με τις σημασιολογικές αναπαραστάσεις του GloVe, με στόχο την επίτευξη ενός αρτιότερου αποτελέσματος.

## 6. Βιβλιογραφία

[1] Διαφάνειες Διαλέξεων - Artificial Intelligence 2: Deep Learning for Natural Language Processing, 2026. Εαρινό Εξάμηνο 2025-2026, SemEval 2026 Task 6.

[2] Jeffrey Pennington and Richard Socher and Christopher D. Manning. GloVe: Global Vectors for Word Representation. In *Empirical Methods in Natural Language Processing (EMNLP)*, pages 1532–1543, 2014.

[3] Jurafsky, Daniel and Martin, James H. Speech and Language Processing (3rd ed. draft). https://web.stanford.edu/~jurafsky/slp3/, 2024. Chapters 4–5 and 7.

[4] Pedregosa, F. and Varoquaux, G. and Gramfort, A. and Michel, V. and Thirion, B. and Grisel, O. and Blondel, M. and Prettenhofer, P. and Weiss, R. and Dubourg, V. and Vanderplas, J. and Passos, A. and Cournapeau, D. and Brucher, M. and Perrot, M. and Duchesnay, E. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.

[5] Wes McKinney. Data Structures for Statistical Computing in Python. In Stéfan van der Walt and Jarrod Millman, editor, *Proceedings of the 9th Python in Science Conference*, pages 56 – 61, 2010.

## 7. Παραρτήματα - Πρόσθετες Θεωρήσεις

Παράρτημα Α: Η Επίδραση της Στάθμισης Κλάσεων (**Class Weights**) και το Παράδοξο της Ακρίβειας

Κατά τα αρχικά πειράματα με το μοντέλο TF-IDF και τον αλγόριθμο της Λογιστικής Παλινδρόμησης (με χρήση 5-fold Cross Validation), η εκπαίδευση πραγματοποιήθηκε χωρίς καμία διόρθωση της ανισορροπίας των δεδομένων (brute-force). Το μοντέλο απέδωσε Accuracy 0.6014 και Macro Precision 0.6353, ωστόσο εμφάνισε εξαιρετικά χαμηλό Macro Recall, 0.4081, οδηγώντας σε Macro F1-score μόλις 0.4127.

Η συμπεριφορά αυτή αποτελεί 'παράδοξο της ακρίβειας': λόγω της συντριπτικής πλειοψηφίας της κλάσης Ambivalent, το μοντέλο είχε μάθει να 'κλέβει', προβλέποντας διαρκώς την πλειοψηφική κλάση. Έτσι, ενώ είχε ικανοποιητική συνολική ακρίβεια (αφού προέβλεπε σωστά το ≈60% των συνολικών περιπτώσεων), ήταν ένα 'δειλό' μοντέλο που αγνοούσε εντελώς τις δύο μικρότερες κλάσεις, μειώνοντας την ανάκληση (Recall) και το F1-score.

Για την αντιμετώπιση του προβλήματος, εισήχθη η παράμετρος class_weight="balanced". Αυτό ανάγκασε το μοντέλο να 'τιμωρείται' περισσότερο όταν κάνει λάθος στις μειοψηφικές κλάσεις και, ως αποτέλεσμα, το Macro Recall αυξήθηκε στο 0.5190, υποδηλώνοντας ότι το μοντέλο πλέον επιχειρεί να εντοπίσει δείγματα από όλες τις κατηγορίες. Παράλληλα, το Accuracy μειώθηκε στο 53.82%. Η πτώση αυτή είναι απόλυτα λογική και αναμενόμενη, καθώς το μοντέλο σταμάτησε να μεροληπτεί υπέρ της ασφαλούς επιλογής του Ambivalent. Αν και κάνει περισσότερα συνολικά λάθη, αποτελεί πλέον ένα πολύ πιο δίκαιο, ισορροπημένο και αξιόπιστο μοντέλο ταξινόμησης, ικανό να αναγνωρίσει ουσιαστικά μοτίβα σε όλες τις κλάσεις.

Παράρτημα Β: Λίστα σοβαρών Σφαλμάτων Ταξινόμησης του βασικού μοντέλου

Για την καλύτερη κατανόηση των ορίων του βέλτιστου μοντέλου, πραγματοποιήθηκε στοχευμένη ανάλυση σφαλμάτων. Συγκεκριμένα, απομονώθηκαν τα 71 πιο 'σοβαρά λάθη' (severe errors) κατά τη διαδικασία του Cross-Validation. Πρόκειται για περιπτώσεις όπου η πραγματική ετικέτα ήταν *Clear Non-Reply*, αλλά το μοντέλο προέβλεψε *Clear Reply*. Παραθέτονται τρία χαρακτηριστικά παραδείγματα:

- Παράδειγμα 1: Επίκληση Εμπιστευτικότητας
  Κείμενο: 'tell five republican senator SEPTOKEN sure kidding maintain confidentiality'
  Αιτία Σφάλματος: Ο ομιλητής αρνείται να απαντήσει επικαλούμενος το απόρρητο ('maintain confidentiality'). Ωστόσο, το μοντέλο, αγνοώντας το βαθύτερο σημασιολογικό πλαίσιο της άρνησης, αντιλαμβάνεται τη λέξη 'confidentiality' απλώς ως μια απλή λέξη μιας ξεκάθαρης απάντησης.

- Παράδειγμα 2: Επανάληψη του λεξιλογίου της ερώτησης
  Κείμενο: 'couldif chemical weapon used ukraine would trigger military response nato SEPTOKEN would trigger response kind whether notyoure asking whether nato would cross wed make decision timeus humanitarian assistance'
  Αιτία Σφάλματος: Ο πολιτικός χρησιμοποιεί ακριβώς το ίδιο λεξιλόγιο με την ερώτηση, γεγονός που παράγει τεράστιο βάρος στον TF-IDF Vectorizer. Η τελική του φράση, η οποία αποτελεί ξεκάθαρη υπεκφυγή ('we"d make decision time'), περνάει εντελώς απαρατήρητη από το Bag-of-Words μοντέλο.

- Παράδειγμα 3: Αποφυγή και αλλαγή θέματος
  Κείμενο: 'confident oil price cap russian export would bring price american driver SEPTOKEN let hear thethe second part question would bring price'
  Αιτία Σφάλματος: Ο ομιλητής υπεκφεύγει πλήρως ζητώντας να ακούσει 'το δεύτερο μισό της ερώτησης'. Το TF-IDF μοντέλο αδυνατεί να αναγνωρίσει τον χαρακτήρα αυτής της φράσης και ξεγελιέται από την επανάληψη λέξεων όπως 'price'.

Η πρακτική αυτή ανάλυση επιβεβαιώνει ότι οι πολιτικές υπεκφυγές συχνά 'μεταμφιέζονται' συντακτικά, χρησιμοποιώντας το λεξιλόγιο της ερώτησης. Μοντέλα που βασίζονται αποκλειστικά σε συχνότητες λέξεων αδυνατούν να αποκωδικοποιήσουν τέτοιου είδους επικοινωνίες χωρίς τη βοήθεια πιο σύγχρονων γλωσσικών μοντέλων που να κατανοούν το σημασιολογικό πλαίσιο (context).

Παράρτημα Γ: Παράδειγμα Κειμένου Πριν και Μετά την Προεπεξεργασία:

Στα αρχικά δεδομένα περιλαμβάνεται η ερώτηση του δημοσιογράφου και η απάντηση, ενώ ακολουθεί το καθαρισμένο κείμενο. Όπως καθίσταται σαφές, ο αλγόριθμος αφαίρεσε επιτυχώς σημεία στίξης, κεφαλαία γράμματα και περιττές λέξεις κοινής χρήσης, διατηρώντας αποκλειστικά τους όρους που φέρουν το σημασιολογικό βάρος, καθώς και τον διαχωριστή SEPTOKEN.

- Παράδειγμα:
  - Αρχική Ερώτηση & Απάντηση:
    'How would you respond to the accusation that the United States is containing China while pushing for diplomatic talks?
    Well, look, first of all, theI am sincere about getting the relationship right. And one of the things that is going on now is, China is beginning to change some of the rules of the game, in terms of trade and other issues.And so one of the things we talked about, for example, is that they're now talking about making sure that no Chineseno one in the Chinese Government can use a Western cell phone. Those kinds of things.And so, really, what this trip was aboutit was less about containing China. I don"t want to contain China. I just want to make sure that we have a relationship with China that is on the up and up, squared away, everybody knows what it"s all about. And one of the ways you do that is, you make sure that we are talking about the same things.And I think that one of the things we"ve doneI"ve tried to do, and I"ve talked with a number of my staff about this for the last, I guess, 6 monthsis, we have an opportunity to strengthen alliances around the world to maintain stability.That"s what this trip was all about: having India cooperate much more with the United States, be closer with the United States, Vietnam being closer with the United States. It"s not about containing China; it"s about having a stable base, a stable base in the Indo-Pacific.And it"sfor example, when I was spending a lot of time talking with President Xi, he asked why we were doingwhy was I going to have the Quad, meaning Australia, India, Japan, and the United States? And I said, To maintain stability. It"s not about isolating China. It"s about making sure the rules of the roadeverything from airspace and space in the ocean isthe international rules of the road are abided by.And soand I hope thatI think that Prime Minister XiI mean, Xi has somesome difficulties right now. All countries end

up with difficulties, and he had some economic difficulties he“s working his way through. I want to see China succeed economically, but I want to see them succeed by the rules.The next question was to Bloomberg.’‘

– Καθαρισμένο (*Cleaned*):
‘would respond accusation united states containing china pushing diplomatic talks SEPTOKEN well look first thei sincere getting relationship right one things going china beginning change rules game terms trade issuesand one things talked example theyre talking making sure chineseno one chinese government use western cell phone kinds thingsand really trip aboutit less containing china dont want contain china want make sure relationship china squared away everybody knows one ways make sure talking thingsand think one things weve doneive tried ive talked number staff last guess monthsis opportunity strengthen alliances around world maintain stabilitythats trip india cooperate much united states closer united states vietnam closer united states not containing china stable base stable base indopacificand itsfor example spending lot time talking president asked doingwhy going quad meaning australia india japan united states said maintain stability not isolating china making sure rules roadeverything airspace space ocean isthe international rules road abided byand soand hope thati think prime minister xii mean somesome difficulties right countries end difficulties economic difficulties hes working way want see china succeed economically but want see succeed rulesthe next question bloomberg’‘