Εθνικό και Καποδιστριακό Πανεπιστήμιο Αθηνών
Τμήμα Πληροφορικής και Τηλεπικοινωνιών

Deep Learning for NLP

Όνομα Φοιτητή: Αγάπη Καλλίνικου
ΑΜ: *sma*2200210

Μάθημα: Τεχνητή Νοημοσύνη ΙΙ (*YS19* M*226* M*262* M*325* M*405*)
Εξάμηνο: Εαρινό Εξάμηνο 2025-2026

Περιεχόμενα

1 Περίληψη 2

2 Σύνδεσμοι Κώδικα (**Kaggle Notebooks**) 3

3 Επεξεργασία και Ανάλυση Δεδομένων 3
3.1 Προεπεξεργασία . . . 3
3.2 Ανάλυση . . . 4
3.3 Διαχωρισμός Δεδομένων (train, test και validation) . . . 6
3.4 Διανυσματική Αναπαράσταση και Μηχανισμός Προσοχής (Self-Attention) . 6

4 Αλγόριθμοι και Πειραματική Διαδικασία 7
4.1 Πειραματική Διαδικασία . . . 7
4.1.1 Πίνακας Πειραμάτων . . . 7
4.2 Συντονισμός Υπερπαραμέτρων (Hyper-parameter tuning) . . . 8
4.3 Τεχνικές Βελτιστοποίησης . . . 9
4.4 Αξιολόγηση . . . 9
4.4.1 Καμπύλες ROC . . . 10
4.4.2 Καμπύλη Μάθησης . . . 12
4.4.3 Πίνακας Σύγχυσης . . . 15

5 Αποτελέσματα και Συνολική Ανάλυση 17
5.1 Ανάλυση Αποτελεσμάτων . . . 17
5.1.1 Βέλτιστη δοκιμή (DeBERTa-v3) . . . 17
5.1.2 Πίνακας Σύγχυσης . . . 18
5.1.3 ROC Curve . . . 19
5.1.4 Καμπύλες Μάθησης . . . 20
5.2 Συγκριτική Ανάλυση Σφαλμάτων . . . 21

6 Προτάσεις για Μελλοντική Έρευνα 25

7 Βιβλιογραφία 26

8 Παραρτήματα - Πρόσθετες Θεωρήσεις 27
8.1 Παράρτημα Α: Δειγματοληπτικό Error Analysis . . . 27

1. Περίληψη

Στην παρούσα εργασία αναπτύσσεται ένα σύστημα ταξινόμησης για την αξιολόγηση της σαφήνειας των απαντήσεων στον πολιτικό λόγο, βασισμένο στο σύνολο δεδομένων CLARITY του διαγωνισμού SemEval 2026 (Task 6). Το πρόβλημα εστιάζει στην κατηγοριοποίηση ζευγών ερώτησης-απάντησης σε τρεις κλάσεις: Ξεκάθαρη Απάντηση (Clear Reply), Αμφίσημη (Ambivalent) και Ξεκάθαρη Άρνηση (Clear Non-Reply).

Για την επίλυση του προβλήματος, πραγματοποιήθηκε εξειδίκευση (fine-tuning) τριών σύγχρονων γλωσσικών μοντέλων αρχιτεκτονικής Transformer: BERT, DistilBERT και DeBERTa-v3. Η πειραματική διαδικασία υλοποιήθηκε μέσω προσαρμοσμένου βρόχου εκπαίδευσης (custom training loop) στο PyTorch. Η έντονη ανισορροπία των κλάσεων αντιμετωπίστηκε μέσω της ενσωμάτωσης σταθμισμένων βαρών (class weights) στη συνάρτηση απώλειας, ενώ η βελτιστοποίηση των υπερπαραμέτρων πραγματοποιήθηκε τόσο μέσα από στοχευμένα χειροκίνητα πειράματα όσο και αυτοματοποιημένα, με χρήση της βιβλιοθήκης Optuna.

Η συγκριτική αξιολόγηση κατέδειξε ότι, ενώ όλα τα μοντέλα διαθέτουν ισχυρή ικανότητα στην αναγνώριση των άμεσων αρνήσεων, η κλάση της αμφισημίας παραμένει η πλέον απαιτητική. Το DeBERTa-v3 αναδείχθηκε ως το βέλτιστο μοντέλο, επιτυγχάνοντας τη μέγιστη ικανότητα γενίκευσης με Score 0.66 στο leaderboard του Kaggle. Αξιοποιώντας το μέγιστο επιτρεπτό μήκος ακολουθίας (512 tokens), το DeBERTa-v3 κατάφερε να αποκωδικοποιήσει αποτελεσματικότερα τις μακροσκελείς πολιτικές υπεκφυγές, αποφεύγοντας τα φαινόμενα υποεκπαίδευσης του DistilBERT και της ελαφριάς υπερπροσαρμογής που παρατηρήθηκε στο BERT. Τέλος, η εκτενής συγκριτική ανάλυση σφαλμάτων ανέδειξε τους περιορισμούς των δικτύων απέναντι σε παραπλανητικές εισαγωγές και σύνθετες διπλωματικές τοποθετήσεις, επιβεβαιώνοντας την εγγενή δυσκολία της σημασιολογικής ανάλυσης του πολιτικού λόγου.

2. Σύνδεσμοι Κώδικα (**Kaggle Notebooks**)

Ο κώδικας για την ανάπτυξη και την αξιολόγηση των μοντέλων είναι διαθέσιμος στους παρακάτω συνδέσμους:

- **BERT Implementation**: https://www.kaggle.com/code/agapikallinikou/sma2200210-bert-base-uncased
- **DeBERTa-v3 Implementation**: https://www.kaggle.com/code/agapikallinikou/sma2200210-microsoft-deberta-v3-base
- **DistilBERT Implementation**: https://www.kaggle.com/code/agapikallinikou/sma2200210-distilbert-base-uncased

3. Επεξεργασία και Ανάλυση Δεδομένων

3.1. Προεπεξεργασία

Αν και η κατάλληλη προεπεξεργασία των δεδομένων αποτελεί ένα πρωταρχικό, εξαιρετικά κρίσιμο στάδιο, δεδομένου ότι η ποιότητα των δεδομένων της εισόδου καθορίζει σε μεγάλο βαθμό την απόδοση των προβλεπτικών μοντέλων, τα σύγχρονα γλωσσικά μοντέλα αρχιτεκτονικής Transformer (BERT, DistilBERT, DeBERTa) δεν την απαιτούν, σε αντίθεση με τις παραδοσιακές μεθόδους μηχανικής μάθησης. Συνεπώς, η στρατηγική διαχείρισης των δεδομένων επικεντρώθηκε στη διασφάλιση της δομικής ακεραιότητας και στη σωστή μορφοποίηση της εισόδου, διατηρώντας το φυσικό κείμενο σχεδόν αυτούσιο.

1. Προπαρασκευή κειμενικών δεδομένων:
   Πριν από την εφαρμογή οποιασδήποτε τεχνικής καθαρισμού δεδομένων, πραγματοποιήθηκε αυστηρός έλεγχος δομικής ακεραιότητας, με σκοπό την αφαίρεση προβληματικών εγγραφών. Πιο συγκεκριμένα, η διαδικασία επικεντρώθηκε σε δύο άξονες:

   (α′) Διαγραφή Ελλιπών Τιμών:
   Πραγματοποιήθηκε έλεγχος για εγγραφές που παρουσίαζαν κενές τιμές σε κάποιο από τα δοσμένα πεδία, με στόχο την αποφυγή ασυνεπειών κατά την επεξεργασία των δεδομένων της εισόδου και, εν γένει, τη μείωση ρίσκου μελλοντικών αστοχιών. Δεν εντοπίστηκε καμία τέτοια εγγραφή.

   (β′) Αφαίρεση Διπλότυπων Εγγραφών:
   Αφού αφαιρέθηκαν τα εσωτερικά διπλότυπα τόσο από το σύνολο εκπαίδευσης (training set) όσο και από το σύνολο επικύρωσης (validation set), πραγματοποιήθηκε διασταυρούμενος έλεγχος μεταξύ των δύο συνόλων. Ο έλεγχος αυτός κρίθηκε αναγκαίος, καθώς η αφαίρεση των διπλότυπων εγγραφών πραγματοποιήθηκε κατόπιν του static split. Σε περίπτωση που εντοπιζόταν, λοιπόν, ίδια εγγραφή η οποία να ανήκει και στα δύο σύνολα, διαγραφόταν από το validation set και διατηρούνταν μόνο στο train set. Το βήμα αυτό είναι εξαιρετικά κρίσιμο, καθώς αποτρέπει το φαινόμενο της διαρροής δεδομένων (data leakage), διασφαλίζοντας ότι το μοντέλο δεν θα αξιολογηθεί σε δείγματα που έχει ήδη δει κατά την εκπαίδευση.

(γ′) Μορφοποίηση Εισόδου:
Με στόχο την αξιοποίηση του σημασιολογικού πλαισίου, η ερώτηση και η απάντηση ενοποιήθηκαν σε μια δομή ζεύγους κειμένων, όπου ο tokenizer εισάγει αυτόματα το διαχωριστικό σύμβολο [SEP] ανάμεσα στην ερώτηση και την απάντηση, επεξεργασία η οποία ανατέθηκε εξ ολοκλήρου στον AutoTokenizer της βιβλιοθήκης Hugging Face. Ο tokenizer αναλαμβάνει αυτόματα να εισάγει, επιπλέον, τα κατάλληλα ειδικά σύμβολα (special tokens, όπως `[CLS]` και `[SEP]`), προσαρμοσμένα στις απαιτήσεις του εκάστοτε μοντέλου. Παράλληλα, εφαρμόστηκε η παράμετρος `truncation=True`, προκειμένου κείμενα που ξεπερνούν το μέγιστο επιτρεπτό όριο (π.χ. 512 tokens) να περικόπτονται με ασφάλεια. Τέλος, οι κατηγορικές ετικέτες (labels) του συνόλου μετατράπηκαν σε ακέραιες αριθμητικές τιμές (0, 1, 2) μέσω της διαδικασίας label mapping, ώστε να είναι συμβατές με τη συνάρτηση απώλειας του PyTorch.

(δ′) Τροφοδότηση Δεδομένων (**Data Loaders**):
Κατά τη δημιουργία των αντικειμένων DataLoader του PyTorch, ορίστηκε η παράμετρος `shuffle=True` αποκλειστικά για το σύνολο εκπαίδευσης. Η τυχαιοποίηση της σειράς των δειγμάτων σε κάθε εποχή είναι αρκετή ώστε να αποφέρει σημαντική βελτίωση στα αποτελέσματα, καθώς αποτρέπει το μοντέλο από το να απομνημονεύσει την ακολουθία των δεδομένων, αναγκάζοντάς το να εστιάσει στην ουσία των γλωσσικών μοτίβων.

(ε′) Απουσία χειροκίνητου (**Feature Engineering**):
Αρχικά εξετάστηκε η προοπτική εξαγωγής δομικών χαρακτηριστικών (π.χ. μήκος απάντησης, ταυτοποίηση της πρώτης λέξης). Η προσέγγιση αυτή τελικά απορρίφθηκε, καθώς τα μοντέλα Transformer εκτελούν ανταποκρίνονται σε αυτό από τη φύση τους. Μέσω του μηχανισμού Self-Attention που σταθμίζει δυναμικά τη σημασία κάθε token βάσει της θέσης του και του ευρύτερου context,το ίδιο το δίκτυο μαθαίνει να αναγνωρίζει τα διάφορα δομικά στοιχεία αποτελεσματικότερα από οποιονδήποτε χειροκίνητο κανόνα.

3.2. Ανάλυση

Προκειμένου να κατανοηθεί σε βάθος η δομή και οι ιδιαιτερότητες του συνόλου δεδομένων, η διαδικασία της προεπεξεργασίας πραγματοποιήθηκε στηριζόμενη στα συμπεράσματα που αποκτήθηκαν μέσω της Εξερευνητικής Ανάλυσης Δεδομένων (Exploratory Data Analysis - EDA) που πραγματοποιήθηκε στην πρώτη εργασία. Αξίζει να σημειωθεί ότι η ανάλυση της κατανομής των κλάσεων και του μήκους των κειμένων είχε πραγματοποιηθεί στα αρχικά, ακατέργαστα δεδομένα. Αυτό κρίθηκε ως η βέλτιστη πρακτική, προκειμένου να αποτυπωθεί η πραγματική δομή του dataset πριν υποστεί την οποιαδήποτε αλλοίωση. Παρακάτω παρουσιάζονται μερικά συμπεράσματα της πρώτης εργασίας που βοήθησαν στην υλοποίηση της παρούσας.

Αρχικά, στην ανάλυση εξετάστηκε η προέλευση των δηλώσεων, με το σύνολο των 3.448 δειγμάτων να μοιράζεται σε τέσσερις προέδρους των ΗΠΑ: Donald J. Trump (1.325), Barack Obama (1.010), George W. Bush (714) και Joseph R. Biden (399). Επίσης, πραγματοποιήθηκε ανάλυση του μήκους των κειμένων για την κατανόηση της δομής τους. Τα αποτελέσματα παρουσιάζονται αναλυτικά στον Πίνακα 1, όπου και διαφαίνεται η γενικότερη τάση των πολιτικών προσώπων για σύντομες και περιεκτικές δηλώσεις κατά τη διάρκεια των συνεντεύξεων. Σημειώνουμε ότι η υψηλή τυπική απόκλιση υποδηλώνει μεγάλη μεταβλητότητα

στην έκταση του πολιτικού λόγου, όπως άλλωστε ήταν αναμενόμενο.

Πίνακας 1: Στατιστικά στοιχεία μήκους κειμένων (word count) σε στρογγυλοποίηση

Στατιστικό Μέγεθος	Τιμή
Πλήθος Δειγμάτων Λέξεων (Count)	3.390
Μέσος Όρος (Mean)	294,02
Τυπική Απόκλιση (Std)	300,96
Ελάχιστο (Min)	1
25% (Πρώτο Τεταρτημόριο)	58,25
Διάμεσος (50%)	208
75% (Τρίτο Τεταρτημόριο)	440
Μέγιστο (Max)	2.117

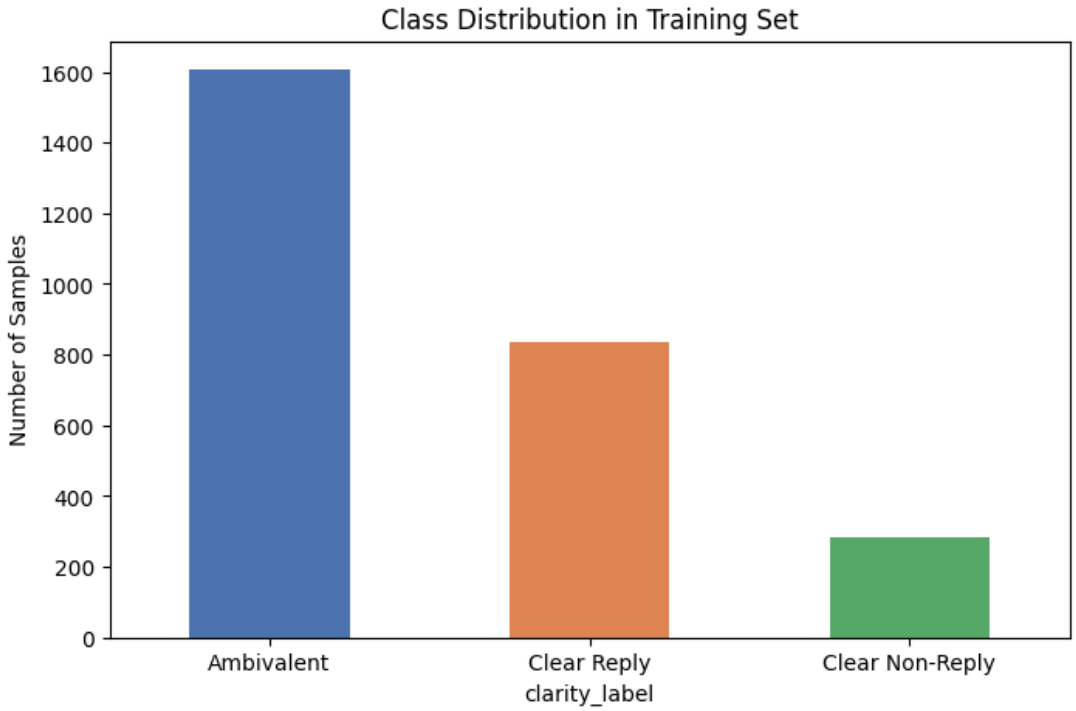

Σχήμα 1: Ανισορροπία κλάσεων.

Σύμφωνα με το παραπάνω σχήμα, παρατηρείται έντονη ανισορροπία (class imbalance) στα δεδομένα, γεγονός το οποίο φαίνεται και από τη σημαντική διαφορά μεταξύ των βαρών που δίνει το μοντέλο στις τρείς κλάσεις αντίστοιχα. Η συντριπτική κυριαρχία της αμφίσημης κατηγορίας αντανακλά τη φύση του πολιτικού λόγου, όπου τα πολιτικά πρόσωπα συχνά επιλέγουν έμμεσες ή διπλωματικές τοποθετήσεις αντί για ευθείες απαντήσεις.

Για την αντιμετώπιση του class imbalance κατά τη φάση της εκπαίδευσης, ενσωματώθηκαν βάρη (class weights) απευθείας στη συνάρτηση Cross Entropy Loss του PyTorch. Αυτή επιβάλλει μικρή ποινή σε λανθασμένες προβλέψεις με χαμηλή σιγουριά, αλλά τιμωρεί αυστηρά το μοντέλο όταν απαντά λανθασμένα με υψηλή βεβαιότητα. Εισάγοντας τα βάρη (τα οποία είναι αντιστρόφως ανάλογα της συχνότητας των κλάσεων), το μοντέλο δέχεται πολύ μεγαλύτερη ποινή αν κάνει λάθος σε μια μειοψηφική κλάση (όπως η Clear Non-Reply).

Αυτή η τεχνική αποτρέπει το μοντέλο από το να 'τεμπελιάσει' και να προβλέπει διαρκώς τη δημοφιλέστερη κατηγορία (Ambivalent) προκειμένου να μειώσει τεχνητά το σφάλμα του.

Φυσικά, επειδή κατά την εκπαίδευσή του το μοντέλο θα εκτίθεται διαρκώς σε παραδείγματα της κατηγορίας `Ambivalent`, ενδέχεται να αναπτύξει μεροληψία (bias) και να αρχίσει να προβλέπει συνεχώς τη συγκεκριμένη κλάση, αγνοώντας, για παράδειγμα, την κατηγορία `Clear Non-Reply` η οποία διαθέτει πολύ λιγότερα παραδείγματα. Έτσι επιβεβαιώνεται και η αναγκαιότητα για τη χρήση εντολής στρωματοποιημένης δειγματοληψίας (`stratify`), προκειμένου να διατηρηθεί αυτή η αναλογία αυτούσια και στο εκάστοτε validation set.

3.3. Διαχωρισμός Δεδομένων (**train**, **test** και **validation**)

Για την ανάπτυξη και την αξιολόγηση των μοντέλων, αξιοποιήθηκε το επίσημο σύνολο δεδομένων του διαγωνισμού SemEval 2026 (Task 6). Η βασική κατάτμηση σε σύνολο εκπαίδευσης (train set) και σύνολο δοκιμής (test set) διατηρήθηκε όπως καθορίστηκε από τους διοργανωτές. Επομένως, η αξιολόγηση κατά τη διάρκεια της ανάπτυξης βασίστηκε στο σύνολο εκπαίδευσης. Ωστόσο, αν και στην προηγούμενη εργασία είχε αξιοποιηθεί η μέθοδος της διασταυρούμενης επικύρωσης 5 επιπέδων (5-fold Cross-Validation), το fine-tuning βαριών μοντέλων όπως το DeBERTa-v3 είναι εξαιρετικά χρονοβόρο και απαιτητική σε υπολογιστικούς πόρους. Ως εκ τούτου, για την παρούσα εργασία, επιλέχθηκε ένας στατικός διαχωρισμός του αρχικού συνόλου εκπαίδευσης σε ποσοστό 80% για εκπαίδευση (training) και 20% για επικύρωση (validation).

Τέλος, ορίστηκε μια σταθερή τιμή αρχικοποίησης (random_state=42), προκειμένου να διασφαλιστεί η πλήρης επαναληψιμότητα των πειραμάτων. Ωστόσο, αξίζει να αναφερθεί πως, λόγω μη-ντετερμινιστικών παραγόντων χαμηλού επιπέδου (όπως η φύση του hardware αλλά και των ίδιων των μοντέλων), ενδέχεται να παρατηρηθούν ελάχιστες, στατιστικά μη σημαντικές, διαφοροποιήσεις στα δεκαδικά ψηφία των score μεταξύ διαφορετικών εκτελέσεων.

3.4. Διανυσματική Αναπαράσταση και Μηχανισμός Προσοχής (**Self-Attention**)

Στην παρούσα εργασία, η μετατροπή του φυσικού κειμένου σε αριθμητικά διανύσματα παρουσιάζει μια θεμελιώδη διαφορά συγκριτικά με τις παραδοσιακές προσεγγίσεις οι οποίες χρησιμοποιήθηκαν στην πρώτη εργασία (TF-IDF και GloVe). Στις αρχιτεκτονικές Transformer, η διανυσματοποίηση αποτελεί ένα δυναμικό μέρος του ίδιου του νευρωνικού δικτύου. Η διαδικασία αυτή εκτελείται ως εξής:

1. **Subword Tokenization**:

   Αντί να διασπάται το κείμενο σε ολόκληρες λέξεις, τα μοντέλα αξιοποιούν προηγμένους αλγορίθμους. Συγκεκριμένα:

   - Τα μοντέλα BERT και DistilBERT χρησιμοποιούν τον αλγόριθμο **WordPiece**.
   - Το μοντέλο DeBERTa-v3 χρησιμοποιεί μια παραλλαγή του **SentencePiece**.

   Η προσέγγιση αυτή επιτρέπει τον διαχωρισμό άγνωστων λέξεων (Out-Of-Vocabulary) σε μικρότερα, γνωστά κομμάτια (π.χ. ρίζες, καταλήξεις). Έτσι, το πρόβλημα των λέξεων που 'αγνοούνταν' στο μοντέλο GloVe εξαλείφεται πλήρως, καθώς τα μοντέλα μπορούν να συνθέσουν νόημα ακόμα και από λέξεις που δεν έχουν ξαναδεί.

2. **Contextualized Embeddings**:

Στη μέθοδο GloVe, κάθε λέξη διέθετε μοναδικό στατικό διάνυσμα, ανεξάρτητα από το ότι πιθανώς να έχει 2 ή και περισσότερες ερμηνείες ως λέξη. Αντίθετα, τα μοντέλα Transformer παράγουν δυναμικές αναπαραστάσεις. Μέσω του μηχανισμού Self-Attention, το διάνυσμα κάθε token αναπροσαρμόζεται διαρκώς σε κάθε layer του δικτύου, λαμβάνοντας υπόψη όλα τα υπόλοιπα tokens της ακολουθίας (τόσο της ερώτησης όσο και της απάντησης). Έτσι, το μοντέλο αντιλαμβάνεται το πραγματικό συντακτικό και σημασιολογικό πλαίσιο (context) της συζήτησης.

3. Εξαγωγή Χαρακτηριστικών Ταξινόμησης (Το **[CLS] Token**):

   Για την τελική ταξινόμηση της ακολουθίας, τα μοντέλα δεν απαιτούν τη λήψη μέσου όρου (Mean Pooling), όπως συνέβαινε και στα στατικά embeddings. Αντιθέτως, κατά την είσοδο του κειμένου, ο tokenizer προσθέτει αυτόματα ένα ειδικό token ταξινόμησης στην αρχή της ακολουθίας (το `[CLS]`). Καθώς η πληροφορία διατρέχει τα επίπεδα του Transformer, το διάνυσμα αυτού του ειδικού token φορτώνεται με τη συνολική σημασιολογία ολόκληρου του κειμένου. Το τελικό συμπυκνωμένο διάνυσμα του `[CLS]` αποτελεί την τελική αναπαράσταση της ερωτοαπάντησης. Αυτό το διάνυσμα περνάει εν τέλει από ένα πλήρως συνδεδεμένο επίπεδο ταξινόμησης (Linear Classification Head), το οποίο, σε συνδυασμό με τη συνάρτηση ενεργοποίησης Softmax (ή την CrossEntropyLoss κατά την εκπαίδευση), εξάγει τις τελικές πιθανότητες για τις τρεις κλάσεις του προβλήματος.

4. Αλγόριθμοι και Πειραματική Διαδικασία

4.1. Πειραματική Διαδικασία

Η υλοποίηση και η εκπαίδευση των μοντέλων (BERT, DistilBERT, DeBERTa-v3) πραγματοποιήθηκε με χρήση της βιβλιοθήκης PyTorch. Προκειμένου να αποτραπεί η μεροληψία προς την πλειοψηφική κλάση, ενσωματώθηκαν αντίστροφα βάρη κλάσεων (Class Weights) απευθείας στη συνάρτηση απώλειας CrossEntropyLoss. Συγκεκριμένα, εφαρμόστηκαν τα εξής βάρη: Clear Reply: 3.26, Ambivalent: 1.70 και Clear Non-Reply: 9.69.

4.1.1. Πίνακας Πειραμάτων. Για τη βελτιστοποίηση της απόδοσης, πραγματοποιήθηκε αρχικά μια σειρά στοχευμένων χειροκίνητων πειραμάτων, εξετάζοντας την επίδραση των διάφορων υπερπαραμέτρων. Τα αποτελέσματα στο Validation Set (σε Macro F1) συνοψίζονται στον παρακάτω πίνακα:

Πίνακας 2: Σύνοψη Βασικών Χειροκίνητων Πειραμάτων (Validation Macro F1-score)

Πείραμα / Ρύθμιση	**DistilBERT**	**BERT**	**DeBERTa-v3**	Παρατηρήσεις
Baseline (LR=$2e-5$, Drop=0.1)	0.5620	0.5827	0.3473	Αρχική υπεροχή του BERT. Υποεκπαίδευση στο DeBERTa.
Α: **Regularization** (Drop=0.2, WD=0.1)	0.5426	0.5829	0.3564	Πτώση στο DistilBERT λόγω απώλειας χωρητικότητας.
Β: **LR**=$1e-5$, **Epochs**=4	0.5819	0.5658	0.3473	Βελτίωση στο DistilBERT, πιο σταθερή σύγκλιση.
Γ: **Batch Size** = 8	0.6057	OOM	OOM	Βέλτιστο για DistilBERT. Out of Memory για τα base μοντέλα.
Δ: **Adafactor Optimizer**	0.5710	0.5946	0.5643	Σημαντική σταθεροποίηση και άνοδος στο DeBERTa.
Ε: **Max Len** = 256 / 512	0.5532	0.6054	0.5953	Αύξηση στο BERT (256) και στο DeBERTa (512).

4.2. Συντονισμός Υπερπαραμέτρων (**Hyper-parameter tuning**)

Παράλληλα με τα χειροκίνητα πειράματα, αξιοποιήθηκε η βιβλιοθήκη Optuna για τον αυτοματοποιημένο συντονισμό των υπερπαραμέτρων. Πραγματοποιήθηκαν 5 δοκιμές για κάθε μοντέλο. Τα αποτελέσματα συνοψίζονται παρακάτω:

Πίνακας 3: Βέλτιστες Υπερπαράμετροι βάσει Optuna

Μοντέλο	**Learning Rate**	**Weight Decay**	**Dropout**	**Optuna Macro F1**
DistilBERT	2.62×10^{-5}	0.024	0.13	0.5784
BERT-base	3.08×10^{-5}	0.024	0.13	0.6037
DeBERTa-v3	2.66×10^{-5}	0.011	0.29	0.5496

Ενδιαφέρον παρουσιάζει το γεγονός ότι στα μοντέλα BERT και DeBERTa, η χειροκίνητη δοκιμή (Πείραμα Ε) ξεπέρασε οριακά τα αποτελέσματα του Optuna. Αυτό εξηγείται από τον περιορισμένο αριθμό δοκιμών (5 trials λόγω Kaggle GPU) που δεν επέτρεψε στον αλγόριθμο να χαρτογραφήσει πλήρως τον χώρο, ενώ αντίθετα οι χειροκίνητες τιμές προήλθαν από δοκιμασμένες διεθνείς βιβλιογραφικές πρακτικές, οπότε αποτελούσαν εξ' αρχής ισχυρό baseline.

Επιπλέον, αξίζει να σημειωθεί ότι στην αρχική υλοποίηση του κάθε μοντέλου υπήρχε ένα κελί επανεκπαίδευσης, στο τέλος όλων των πειραμάτων, ώστε να κρατηθούν στη μνήμη οι βέλτιστες τιμές των υπερπαραμέτρων. Από τις πρώτες εκτελέσεις του κώδικα παρατηρήθηκε μια κατακόρυφη πτώση της απόδοσης στο τελικό στάδιο επανεκπαίδευσης. Το φαινόμενο αυτό οφειλόταν, εν τέλει, στη διατήρηση της κατάστασης του μοντέλου στη μνήμη, όπου η διαδοχική εκτέλεση πειραμάτων στο ίδιο αντικείμενο του PyTorch προκαλούσε ακούσια

σώρευση των ενημερώσεων στα βάρη (weight contamination), οδηγώντας έτσι σε ακραία υπερεκπαίδευση. Συνεπώς, το κελί αφαιρέθηκε.

4.3. Τεχνικές Βελτιστοποίησης

Για τη βελτιστοποίηση των βαρών, το τελικό pipeline στηρίχθηκε στον επιλυτή AdamW, ο οποίος διαχωρίζει τον υπολογισμό του Weight Decay από την ενημέρωση της κλίσης, εξασφαλίζοντας ισχυρότερη κανονικοποίηση. Παράλληλα, κατά τη διάρκεια των εποχών εφαρμόστηκε μηχανισμός αποθήκευσης του βέλτιστου μοντέλου βασισμένος αποκλειστικά στο τοπικό Macro F1-score του Validation Set, ώστε να αποτραπεί η ακούσια επιλογή ενός υπερεκπαιδευμένου υποδείγματος. Το στήσιμο των πειραμάτων έγινε με τρόπο δομημένο, αλλάζοντας μια μια τις τιμές των υπερπαραμέτρων κάθε φορά, με σκοπό να φανούν καθαρά οι αλλαγές που θα επιφέρει η αλλαγή αυτή στην συνολική απόδοση του μοντέλου.

4.4. Αξιολόγηση

Λόγω της έντονης ανισορροπίας των κλάσεων, το Accuracy ή το Weighted F1-score μπορούν να δώσουν την ψευδαίσθηση υψηλής απόδοσης, επισκιάζοντας την αδυναμία του μοντέλου να εντοπίσει τις μειοψηφικές κλάσεις. Για τον λόγο αυτόν, επιλέχθηκε ως κύρια μετρική αξιολόγησης (και, εν τέλει, της μεταξύ τους σύγκρισης) το Macro F1-score, το οποίο υπολογίζει τον αδιαμόρφωτο μέσο όρο των F1-scores κάθε κλάσης, τιμωρώντας αυστηρά το μοντέλο εάν αποτύχει σε μικρότερες κλάσεις Clear Non-Reply. Ωστόσο, παρατίθεται ο εξής συγκεντρωτικός πίνακας μετρικών:

Πίνακας 4: Αναλυτικές Μετρικές (Precision, Recall, F1-Score) ανά Κλάση και Μοντέλο στο σύνολο επικύρωσης

Μοντέλο	Κλάση	**Precision**	**Recall**	**F1-Score**
DistilBERT	Clear Reply	0.4286	0.5050	0.4636
	Ambivalent	0.6735	0.5863	0.6269
	Clear Non-Reply	0.5294	0.6429	0.5806
BERT-base	Clear Reply	0.5419	0.4802	0.5092
	Ambivalent	0.7125	0.7107	0.7116
	Clear Non-Reply	0.5319	0.7143	0.6098
DeBERTa-v3	Clear Reply	0.5570	0.4109	0.4729
	Ambivalent	0.7042	0.7310	0.7173
	Clear Non-Reply	0.4907	0.7571	0.5955

Όπως αποτυπώνεται στον πίνακα, η εφαρμογή σταθμισμένων βαρών (class weights) οδήγησε σε ένα σαφές trade-off, αυξάνοντας δραστικά το Recall στη μειοψηφική κλάση Clear Non-Reply, με αναμενόμενο τίμημα την πτώση του Precision. Ανάμεσα στις τρεις αρχιτεκτονικές, το DeBERTa-v3 επιτυγχάνει τη βέλτιστη ισορροπία, σημειώνοντας την υψηλότερη συνολική επίδοση (F1-Score 0.7173) στην κυρίαρχη και πλέον απαιτητική κλάση της αμφισημίας (Ambivalent).

Πίνακας 5: Συνολικές Μετρικές Αξιολόγησης (Accuracy, Weighted F1, Macro F1) ανά Μοντέλο στο Σύνολο Επικύρωσης

Μοντέλο	Συνολικό **Accuracy**	**Weighted F1-Score**	**Macro F1-Score**
DistilBERT	0.5676	0.5725	0.5570
BERT-base	0.6411	0.6395	0.6102
DeBERTa-v3	0.6366	0.6304	0.5953

Όπως προκύπτει, το BERT-base σημειώνει την υψηλότερη επίδοση στο τοπικό σύνολο επικύρωσης, αφήνοντας οριακά πίσω το DeBERTa-v3, ενώ το DistilBERT υστερεί αισθητά, επιβεβαιώνοντας πως η συμπιεσμένη του αρχιτεκτονική δυσκολεύεται με την πολυπλοκότητα των δεδομένων. Το σημαντικότερο, ωστόσο, εύρημα είναι η σταθερή απόκλιση μεταξύ Weighted και Macro F1-Score σε όλες τις δοκιμές. Το γεγονός ότι το Macro F1 είναι συστηματικά χαμηλότερο αποδεικνύει την επιρροή της πλειοψηφικής κλάσης (Ambivalent) στο συνολικό σκορ και δικαιολογεί απόλυτα την επιλογή της Macro προσέγγισης ως του πιο αυστηρού και αντικειμενικού κριτηρίου αξιολόγησης.

Ακολουθεί η οπτική αξιολόγηση των μοντέλων DistilBERT και DeBERTa-v3 μέσω των αντίστοιχων διαγραμμάτων (Η αναλυτική μελέτη του βέλτιστου τοπικού μοντέλου DeBERTa-v3 παρατίθεται στην επόμενη ενότητα).

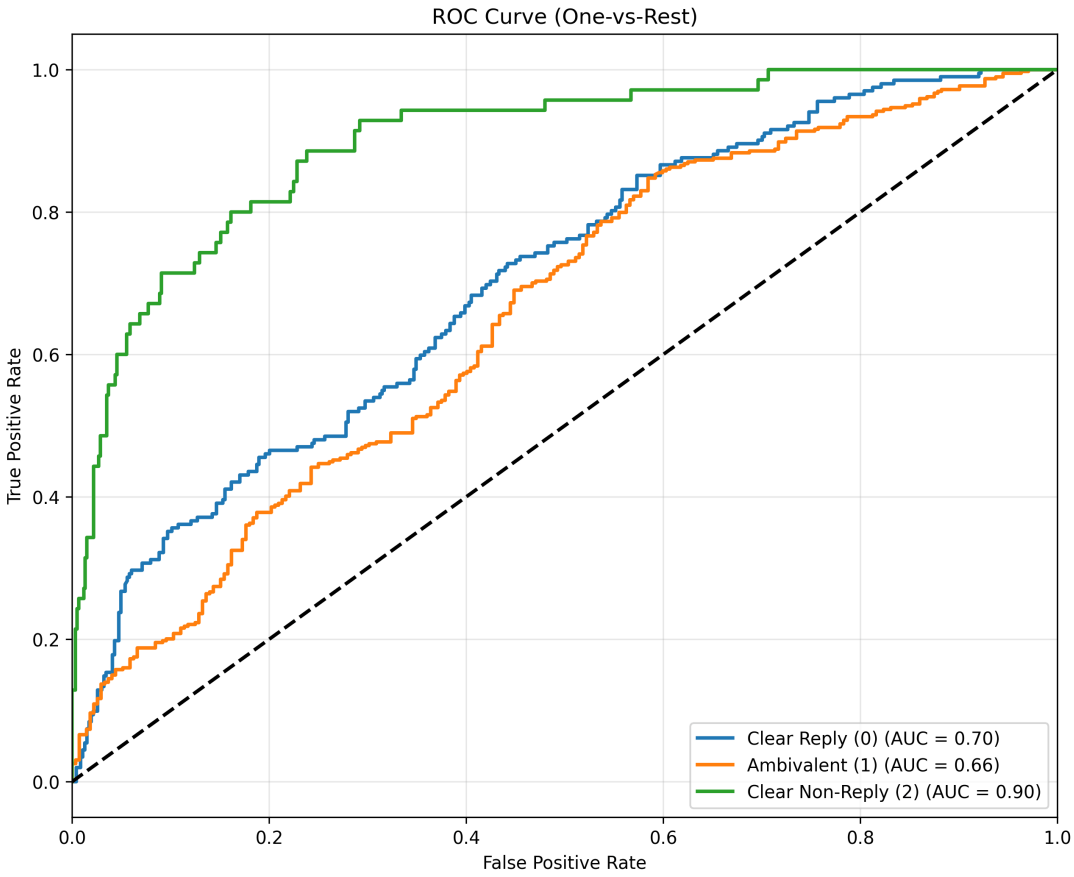

Σχήμα 2: Καμπύλη ROC (One-vs-Rest) για το μοντέλο DistilBERT.

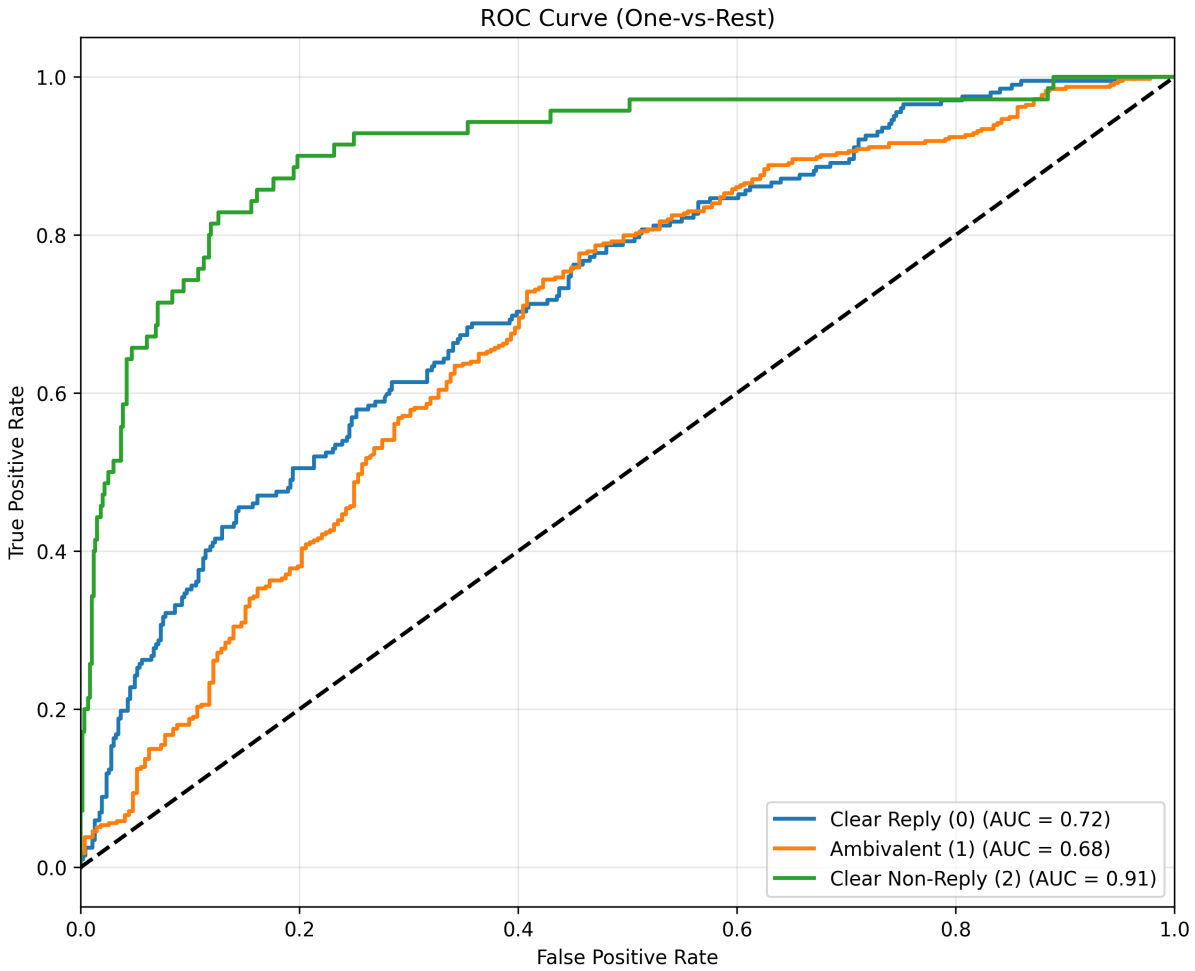

Σχήμα 3: Καμπύλη ROC (One-vs-Rest) για το μοντέλο BERT.

4.4.1. Καμπύλες ***ROC***. Από τη συγκριτική ανάλυση των καμπυλών εξάγονται τρία βασικά συμπεράσματα:

- Εντοπισμός Άμεσων Αρνήσεων: Και τα δύο μοντέλα επιδεικνύουν εξαιρετική ικανότητα αναγνώρισης της κλάσης Clear Non-Reply, επιτυγχάνοντας υψηλές τιμές AUC. Αυτό υποδηλώνει ότι οι ξεκάθαρες αρνήσεις απάντησης διαθέτουν έντονα και διακριτά γλωσσικά μοτίβα (π.χ. συγκεκριμένες φράσεις άρνησης), τα οποία συλλαμβάνονται εύκολα από την αρχιτεκτονική των Transformers.

- Η Πρόκληση της Αμφισημίας: Αντίθετα, η κλάση Ambivalent αποδεικνύεται η πλέον απαιτητική, καταγράφοντας το χαμηλότερο AUC. Το γεγονός αυτό είναι αναμενόμενο, καθώς οι πολιτικές υπεκφυγές συχνά 'μεταμφιέζονται' σημασιολογικά ως έγκυρες απαντήσεις, καθιστώντας τον διαχωρισμό τους από την κλάση Clear Reply ιδιαίτερα δύσκολο.

- Υπεροχή του BERT: Συγκρίνοντας τα δύο μοντέλα, παρατηρείται ότι το BERT εμφανίζει σταθερά μια ελαφρά υπεροχή σε όλες τις κλάσεις. Η διαφορά αυτή επιβεβαιώνει ότι η μεγαλύτερη αρχιτεκτονική του BERT του προσδίδει ελαφρώς καλύτερη διαχωριστική ικανότητα σε σχέση με την πιο ελαφριά έκδοσή του.

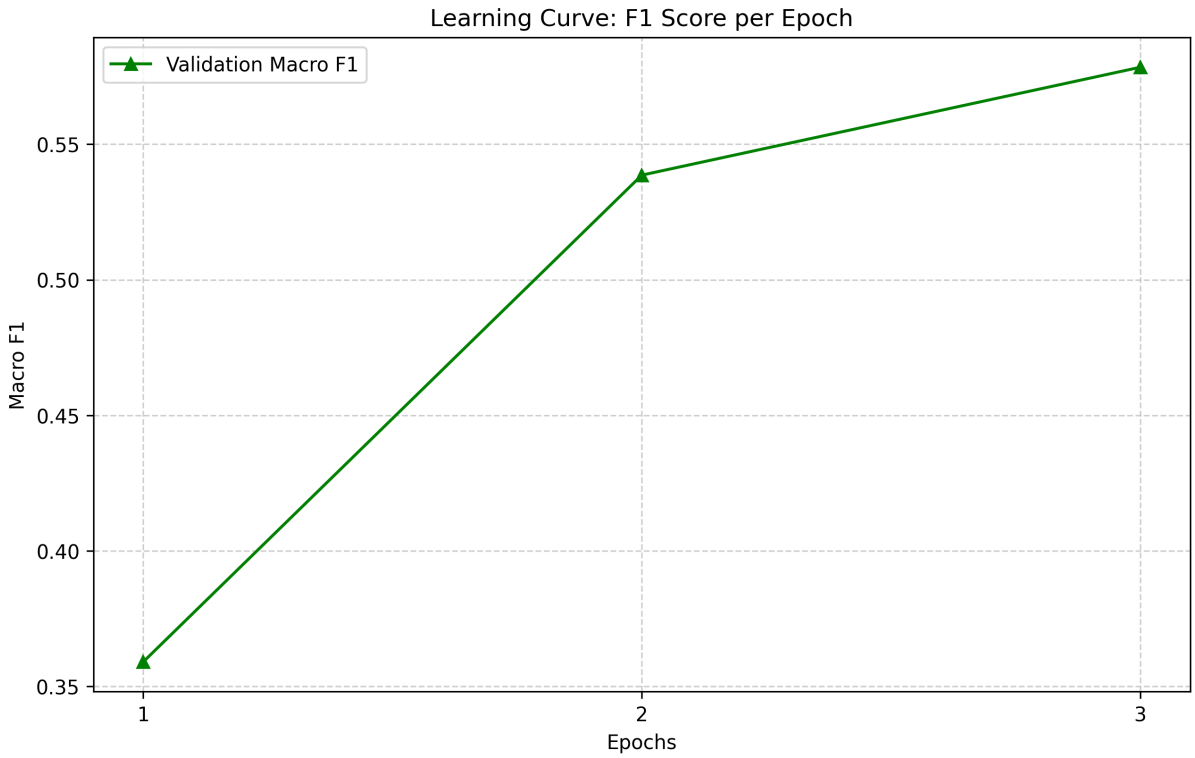

Σχήμα 4: Καμπύλη Μάθησης (Learning Curve) για το μοντέλο DistilBERT - Εξέλιξη του F1-score ανά εποχή.

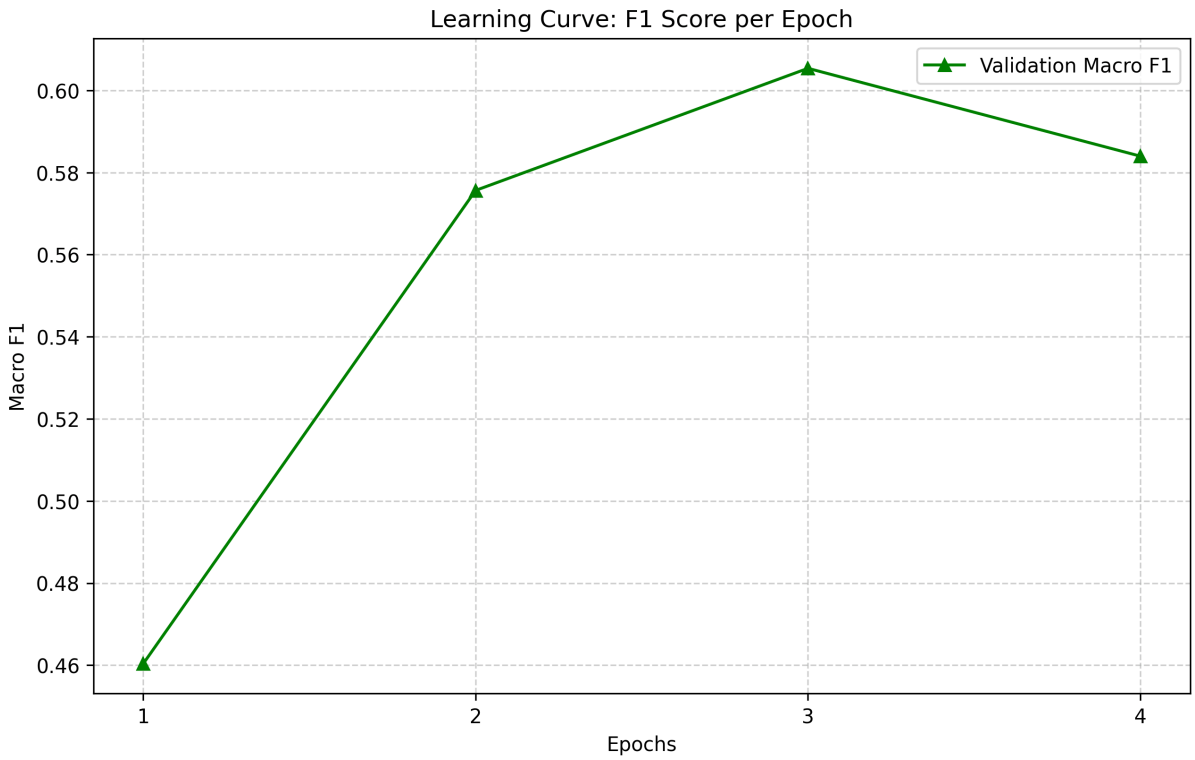

Σχήμα 5: Καμπύλη Μάθησης (Learning Curve) για το μοντέλο BERT - Εξέλιξη του F1-score ανά εποχή.

4.4.2. Καμπύλη Μάθησης. Από τα παραπάνω σχήματα συμπεραίνουμε ότι:

- Ταχύτητα Προσαρμογής και Αφετηρία: Το μοντέλο BERT εκκινεί από υψηλότερη αφετηρία κατά την πρώτη εποχή (περίπου 0.46) συγκριτικά με το DistilBERT (0.36). Εντούτοις, και τα δύο δίκτυα επιδεικνύουν ταχεία προσαρμογή στο dataset, σημειώνοντας μια απότομη και εντυπωσιακή αύξηση της απόδοσής τους μέχρι τη δεύτερη εποχή.
- Σταθερότητα έναντι (**Overfitting**): Το DistilBERT εμφανίζει μια σταθερά ανοδική και ομαλή πορεία μέχρι την 3η εποχή, σχεδόν γραμμική. Αντίθετα, η καμπύλη του BERT αποκαλύπτει πως το μοντέλο κορυφώνει την απόδοσή του κατά την 3η εποχή (με F1-score ≈ 0.61), ωστόσο στην 4η εποχή καταγράφεται αισθητή πτώση της επίδοσής του στο σύνολο επικύρωσης (στα επίπεδα του 0.58).
- Αναγκαιότητα (**Early Stopping**): Η παρατηρούμενη πτώση στην 4η εποχή του BERT αποτελεί κλασική ένδειξη υπερπροσαρμογής (overfitting). Το μοντέλο αρχίζει να εξειδικεύεται υπερβολικά στα δεδομένα εκπαίδευσης, χάνοντας την ικανότητα γενίκευσης. Το γεγονός αυτό καθιστά επιβεβλημένη τη χρήση τεχνικών όπως το Early Stopping, προκειμένου να διασωθούν και να αξιολογηθούν τα βέλτιστα βάρη (weights) που επιτεύχθηκαν στο τέλος της 3ης εποχής.

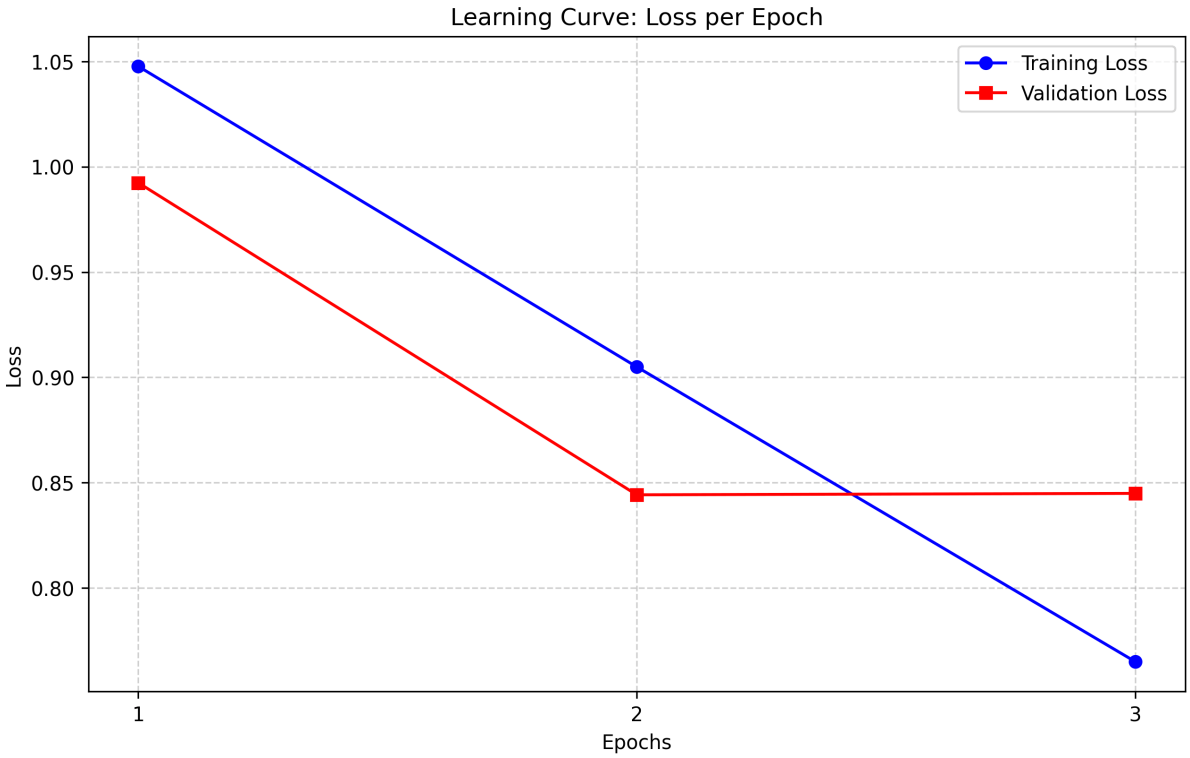

Σχήμα 6: Καμπύλη Μάθησης (Learning Curve) για το μοντέλο DistilBERT - Εξέλιξη της απώλειας (Loss) ανά εποχή.

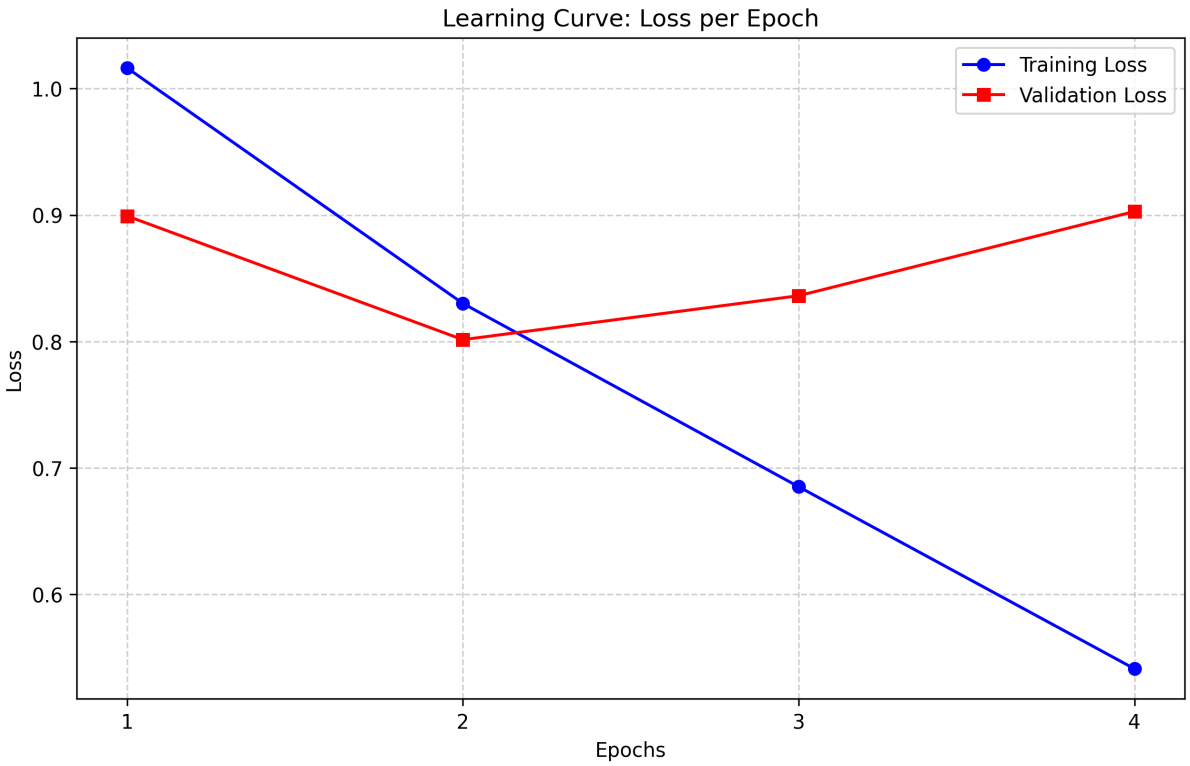

Σχήμα 7: Καμπύλη Μάθησης (Learning Curve) για το μοντέλο BERT - Εξέλιξη της απώλειας (Loss) ανά εποχή.

Στα παραπάνω σχήματα παρουσιάζονται οι καμπύλες απωλειών (Loss Curves) για τα μοντέλα DistilBERT και BERT, αποτυπώνοντας την εξέλιξη της απώλειας εκπαίδευσης (Training Loss) και επικύρωσης (Validation Loss). Η ανάλυσή τους προσφέρει μια ξεκάθαρη εικόνα για την εκπαίδευση:

- Ομαλή Σύγκλιση του **DistilBERT**: Στο μοντέλο DistilBERT, η απώλεια επικύρωσης (κόκκινη γραμμή) παρουσιάζει σημαντική πτώση μέχρι τη 2η εποχή και έπειτα σταθεροποιείται, τη στιγμή που η απώλεια εκπαίδευσης συνεχίζει την πτωτική της πορεία. Η συμπεριφορά αυτή δείχνει ότι το μοντέλο συγκλίνει ομαλά, φτάνοντας στη μέγιστη ικανότητα γενίκευσής του χωρίς να εκδηλώνει έντονα σημάδια υπερπροσαρμογής.

- Ξεκάθαρη Υπερπροσαρμογή στο **BERT**: Στην καμπύλη του BERT, παρατηρείται η κλασική ένδειξη υπερπροσαρμογής. Ενώ η απώλεια εκπαίδευσης μειώνεται συνεχώς και σχεδόν γραμμικά (φτάνοντας στο $\sim$0.55), η απώλεια επικύρωσης ¨χτυπάει' το ελάχιστό της στη 2η εποχή ($\sim$0.80) και στη συνέχεια αρχίζει να αυξάνεται σταθερά στην 3η και 4η εποχή (προσεγγίζοντας το 0.90). Το δίκτυο έχει αρχίσει να απομνημονεύει τις ιδιαιτερότητες του training set, χάνοντας την ικανότητα πρόβλεψης σε νέα, αθέατα δεδομένα.

Όπως καταγράφηκε στο μοντέλο BERT, το F1-score επικύρωσης (61.02) ξεπέρασε το αντίστοιχο της εκπαίδευσης (60.04). Το φαινόμενο αυτό δεν αποτελεί σφάλμα, αλλά εξηγείται από τον μηχανισμό κανονικοποίησης Dropout. Κατά τη φάση της εκπαίδευσης, το Dropout απενεργοποιεί τυχαία ένα ποσοστό των νευρώνων, προσθέτοντας τεχνητή δυσκολία στο δίκτυο. Κατά τη φάση της αξιολόγησης, η κανονικοποίηση αυτή απενεργοποιείται, επιτρέποντας στο μοντέλο να αξιοποιήσει την πλήρη χωρητικότητά του. Επιπλέον, το σκορ

εκπαίδευσης αποτελεί μέσο όρο κατά τη διάρκεια της εποχής, ενώ το validation υπολογίζεται στο τέλος, έχοντας ενσωματώσει πλήρως τη μάθηση της τρέχουσας εποχής.

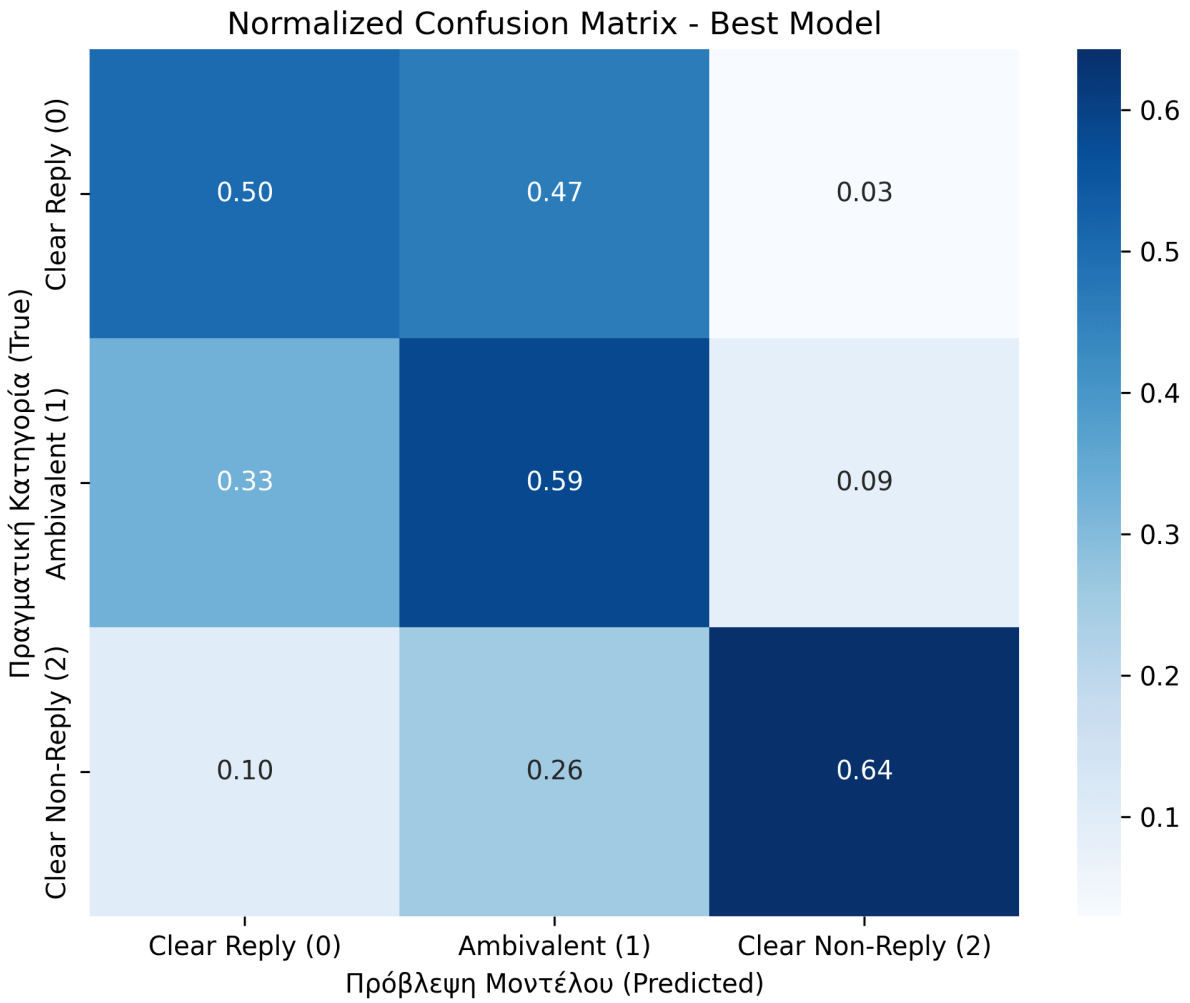

Σχήμα 8: Κανονικοποιημένος Πίνακας Σύγχυσης (Normalized Confusion Matrix) για το μοντέλο DistilBERT.

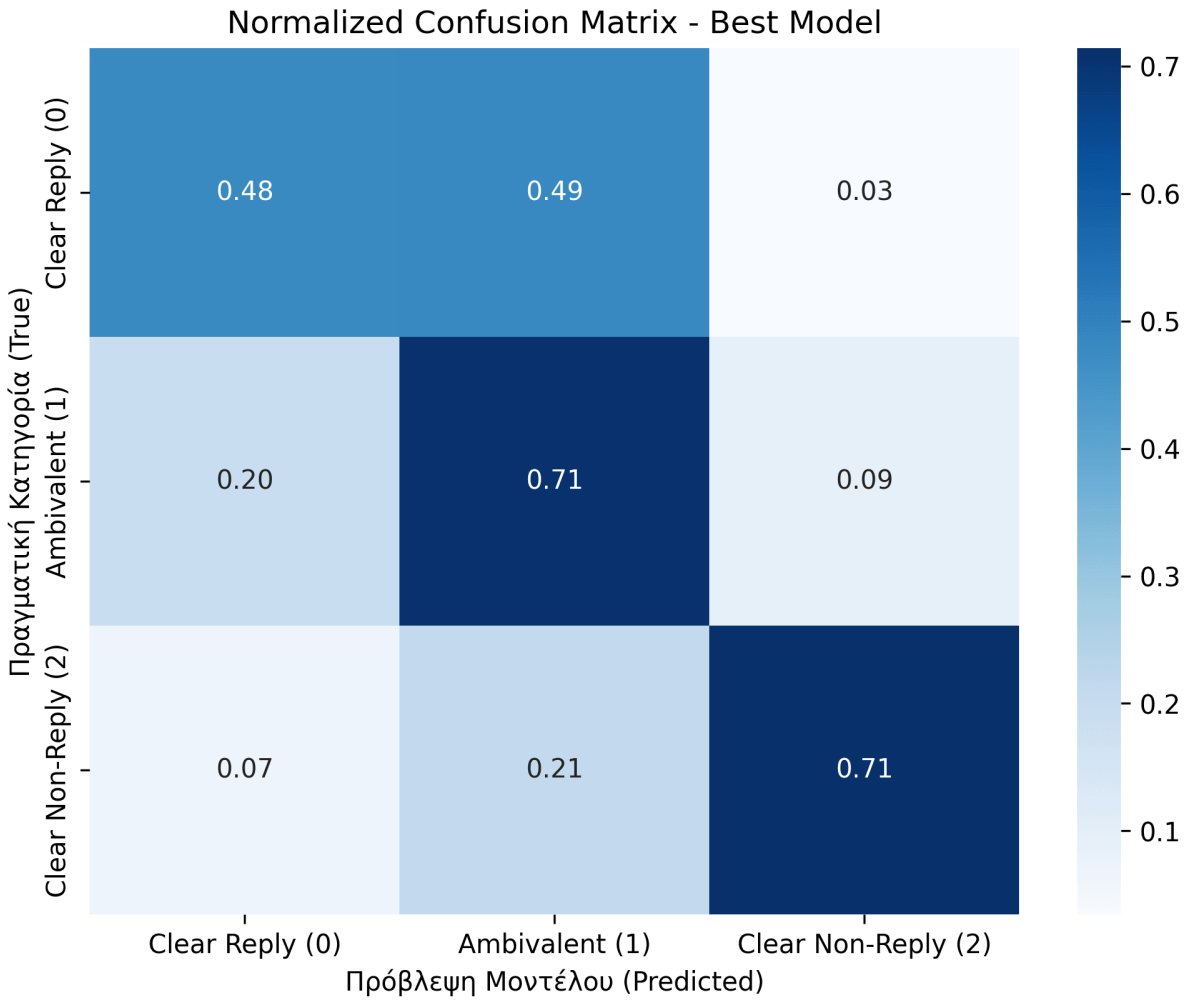

Σχήμα 9: Κανονικοποιημένος Πίνακας Σύγχυσης (Normalized Confusion Matrix) για το μοντέλο BERT.

4.4.3. Πίνακας Σύγχυσης. Η ανάλυση της κατανομής των προβλέψεων αποκαλύπτει τις εξής πληροφορίες για τη συμπεριφορά των μοντέλων:

- Καθαρή Απάντηση εναντίον Υπεκφυγής: Το πιο ενδιαφέρον εύρημα εντοπίζεται στην κλάση Clear Reply. Και τα δύο μοντέλα παρουσιάζουν τεράστια σύγχυση, ταξινομώντας λανθασμένα σχεδόν τις μισές πραγματικές απαντήσεις ως Ambivalent (47% το DistilBERT και 49% το BERT). Αυτό επιβεβαιώνει την εγγενή δυσκολία του πολιτικού λόγου, όπου τα σημασιολογικά όρια μεταξύ μιας ξεκάθαρης απάντησης και μιας υπεκφυγής είναι ιδιαίτερα δυσδιάκριτα.

- Εντυπωσιακή Βελτίωση του **BERT** στην Αμφισημία: Παρά τη δυσκολία στην πρώτη κλάση, το BERT υπερέχει συντριπτικά στην αναγνώριση της κλάσης Ambivalent. Ενώ το DistilBERT εντοπίζει σωστά μόνο το 59% των αμφίσημων απαντήσεων, το BERT εκτοξεύει το ποσοστό του στο 71%. Η μεγαλύτερη χωρητικότητά του του επιτρέπει να αναγνωρίζει πολύ καλύτερα τα μοτίβα του ασαφούς πολιτικού λόγου.

- Σταθερότητα στις Ξεκάθαρες Αρνήσεις: Στην κλάση Clear Non-Reply, το BERT επιδεικνύει ανωτερότητα, επιτυγχάνοντας καλύτερο ποσοστό. Αξίζει να σημειωθεί ότι και στα δύο μοντέλα, το συνηθέστερο σφάλμα για αυτή την κλάση είναι η σύγχυσή της

με την Ambivalent, γεγονός απολύτως αναμενόμενο, καθώς και οι δύο κατηγορίες συνιστούν μορφές μη-απάντησης.

5. Αποτελέσματα και Συνολική Ανάλυση

5.1. Ανάλυση Αποτελεσμάτων

Η τελική αξιολόγηση των μοντέλων πραγματοποιήθηκε σε δύο επίπεδα: στο τοπικό υποσύνολο αξιολόγησης (Validation Set) και στο leaderboard του Kaggle. Τα αποτελέσματα συνοψίζονται στον ακόλουθο πίνακα:

Πίνακας 6: Τελικά Συνολικά Αποτελέσματα (Βέλτιστα Μοντέλα)

Μοντέλο	**Accuracy (Val)**	**Macro F1 (Val)**	**Kaggle Score**
DistilBERT	0.5676	0.5570	0.5800
BERT-base	0.6411	0.6102	0.6400
DeBERTa-v3	0.6366	0.5953	0.6600

Επιλογή Βέλτιστου Μοντέλου και το Φαινόμενο της Γενίκευσης:

Παρατηρώντας αποκλειστικά το τοπικό Validation Score, το BERT-base φαίνεται να υπερτερεί (0.6102 έναντι 0.5953 του DeBERTa-v3). Ωστόσο, ως το απόλυτο βέλτιστο μοντέλο αναδεικνύεται το **DeBERTa-v3**, καθώς πέτυχε τη μέγιστη απόδοση (0.66) στο leaderboard του διαγωνισμού Kaggle.

Η ασυμφωνία αυτή δείχνει ότι το BERT προσμόστηκε (overfit) ελαφρώς στις ιδιαιτερότητες του τοπικού διαχωρισμού (validation split). Αντίθετα, η προηγμένη αρχιτεκτονική του DeBERTa-v3 το απέτρεψε από το να 'παπαγαλίσει' το training set. Μαθαίνοντας βαθύτερα και πιο σταθερά σημασιολογικά μοτίβα, το DeBERTa-v3 κατάφερε να γενικεύσει με ακρίβεια σε εντελώς νέα δεδομένα, κερδίζοντας έτσι την πρώτη θέση. Τέλος, το DistilBERT επέδειξε σαφείς ενδείξεις υποεκπαίδευσης (underfitting), καθώς, ως συμπιεσμένη έκδοση, η μειωμένη χωρητικότητά του (model capacity) αποδείχθηκε ανεπαρκής για την αποκωδικοποίηση περίπλοκων πολιτικών υπεκφυγών.

5.1.1. Βέλτιστη δοκιμή (***DeBERTa-v3***).

Το τελικό pipeline του βέλτιστου μοντέλου (DeBERTa-v3) διαμορφώθηκε έπειτα από τις δοκιμές με τις εξής υπερπαράμετρους: Learning Rate 2×10^{-5}, Batch Size 8, Weight Decay 0.01 και Dropout 0.1, εκπαιδευμένο για 3 εποχές. Η κρίσιμη ρύθμιση που μεγιστοποίησε την απόδοσή του (Πείραμα E) ήταν η αύξηση του μέγιστου μήκους ακολουθίας (Max Len) στα 512 tokens, η οποία του επέτρεψε να ανακτήσει περισσότερη πληροφορία από τις απαντήσεις. Αυτό, δεδομένου ότι είμαστε σε ένα πλαίσιο πολιτικών συζητήσεων, είναι πολύ σημαντικό για να καταλάβει κανείς όσα περισσότερα γίνεται, αφού σε τέτοιες συνεντεύξεις σχεδόν όλοι οι πολιτικοί πλατιαζουν, είτε για να κερδίσουν χρόνο να σκεφτούν αρμόζουσα απάντηση, είτε για να δείξουν την οπτική τους γωνία. Ως αποτέλεσμα, ακόμα και αν εν τέλει απαντήσουν με σχετική ακρίβεια στην ερώτηση του δημοσιογράφου, χρησιμοποιώντας max_length μικρότερο του μέγιστου δυνατού ορίου, το μοντέλο δεν θα προλάβει να δει αυτήν την απάντηση και θα επισημάνει το συγκεκριμένο παράδειγμα ως Ambivalent.

5.1.2. Πίνακας Σύγχυσης. Ο πίνακας σύγχυσης αποκαλύπτει τη συμπεριφορά του βέλτιστου μοντέλου (DeBERTa-v3) ανά κλάση στο σύνολο επικύρωσης και αναδεικνύει τα εξής:

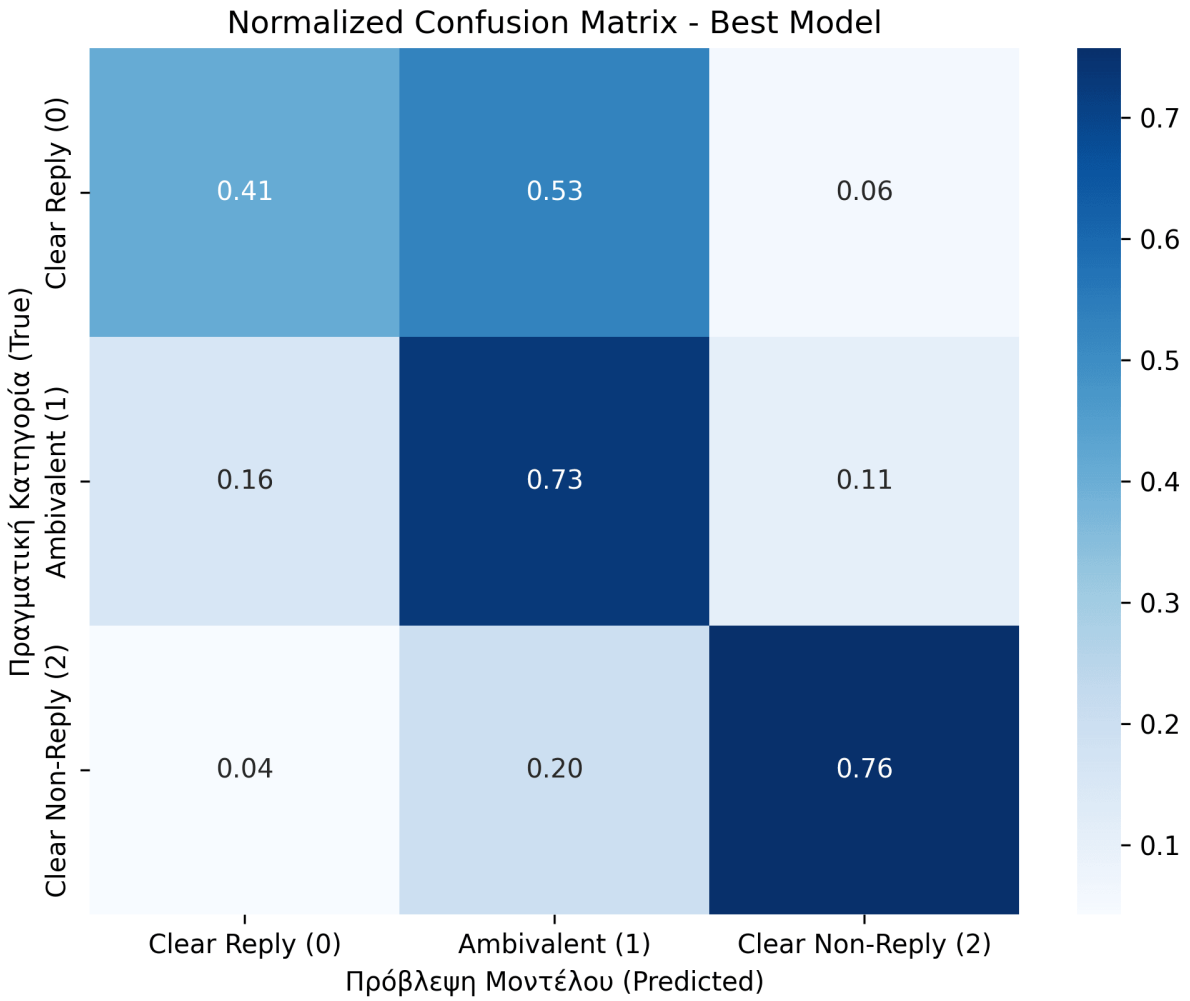

Σχήμα 10: Πίνακας Σύγχυσης Βέλτιστου Μοντέλου (DeBERTa-v3).

:

- Κυριαρχία στην Αμφισημία: Το μοντέλο επιτυγχάνει το υψηλότερο ποσοστό αναγνώρισης (73%) στην κρίσιμη κλάση Ambivalent, μειώνοντας δραματικά τη διαρροή προς την κλάση Clear Reply στο μόλις 16% (έναντι 33% του DistilBERT και 20% του BERT). Η προηγμένη αρχιτεκτονική του DeBERTa αποδεικνύεται ικανότατη στην αποκωδικοποίηση των περίπλοκων γλωσσικών δομών της πολιτικής υπεκφυγής.
- Ενίσχυση της Μειοψηφικής Κλάσης: Η εφαρμογή του βάρους (9.69) λειτούργησε σωστά στην κλάση Clear Non-Reply, επιτρέποντας στο μοντέλο να εντοπίσει σωστά το 76% των περιπτώσεων.
- Το Τίμημα της 'Αυστηρότητας': Η αυξημένη ευαισθησία του μοντέλου στον εντοπισμό υπεκφυγών και αρνήσεων είχε κόστος στην κλάση Clear Reply, όπου ταξινομεί σωστά το 41% των δειγμάτων, θεωρώντας το 53% αυτών ως Ambivalent. Ουσιαστικά, το DeBERTa-v3 υιοθετεί μια σκεπτικιστική στάση απέναντι στον πολιτικό λόγο. Στο πλαίσιο, ωστόσο, της ανάλυσης πολιτικών κειμένων, αυτή η αυστηρότητα είναι συχνά προτιμότερη από την αφελή αποδοχή μιας ασαφούς δήλωσης ως έγκυρης απάντησης.

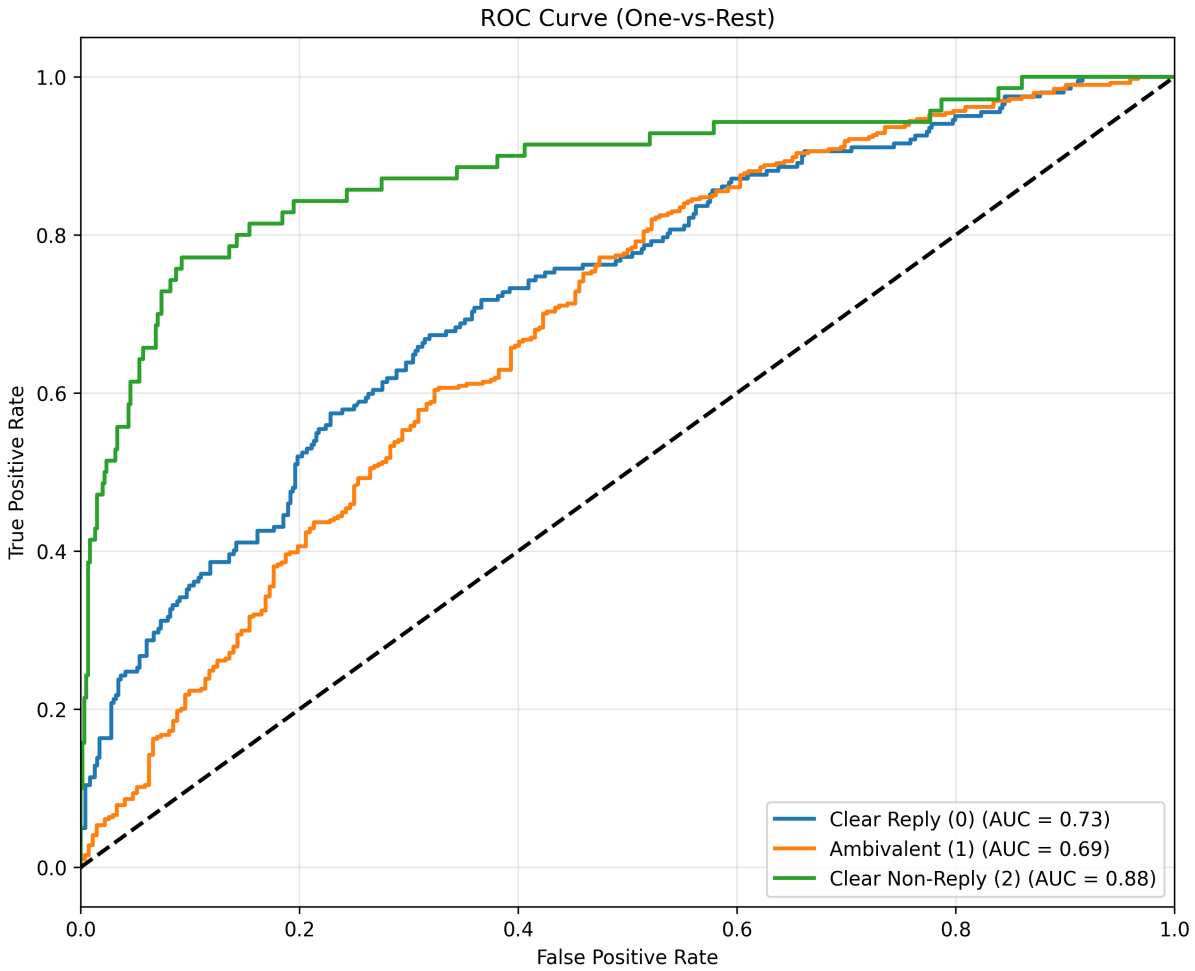

Σχήμα 11: ROC Curve του βέλτιστου μοντέλου (DeBERTa-v3).

5.1.3. ***ROC Curve***. Από την καμπύλη ROC για το βέλτιστο μοντέλο DeBERTa-v3, εξάγονται σημαντικά συμπεράσματα σχετικά με τη διαχωριστική του ικανότητα ανά κλάση:

- Ισχυρή Διάκριση στις Ξεκάθαρες Αρνήσεις: Το μοντέλο επιτυγχάνει την κορυφαία επίδοσή του με AUC 0.88 στην κλάση Clear Non-Reply. Το εντυπωσιακό αυτό σκορ αποδεικνύει ότι, παρά την πτώση στο Precision που προκλήθηκε από την εφαρμογή του βάρους (9.69), η ικανότητα του δικτύου να διαχωρίζει, σε επίπεδο πιθανοτήτων, τις ευθείες αρνήσεις από τον υπόλοιπο λόγο παραμένει εξαιρετικά ισχυρή.

- Ικανοποιητική Αναγνώριση των Απαντήσεων: Στην κλάση Clear Reply, το σκορ AUC διαμορφώνεται στο 0.73. Παρότι στον Πίνακα Σύγχυσης παρατηρήθηκε μια 'αυστηρότητα' (με πολλές έγκυρες απαντήσεις να ταξινομούνται ως αμφίσημες), το εμβαδόν κάτω από την καμπύλη επιβεβαιώνει ότι το μοντέλο κατανοεί σε ικανοποιητικό βαθμό τα δομικά χαρακτηριστικά μιας πραγματικής απάντησης.

- Η Εγγενής Πρόκληση της Αμφισημίας: Το χαμηλότερο AUC (0.69) καταγράφεται στην κλάση Ambivalent. Το γεγονός αυτό λειτουργεί ως επιβεβαίωση της κεντρικής διαπίστωσης πως η αμφισημία στον πολιτικό λόγο ενσωματώνει χαρακτηριστικά τόσο από τις ξεκάθαρες απαντήσεις όσο και από τις υπεκφυγές. Κατά συνέπεια, η δημιουργία ενός αυστηρού διαχωριστικού ορίου για αυτή την κλάση αποτελεί απαιτητικό έργο, ακόμη και για την προηγμένη αρχιτεκτονική του DeBERTa-v3.

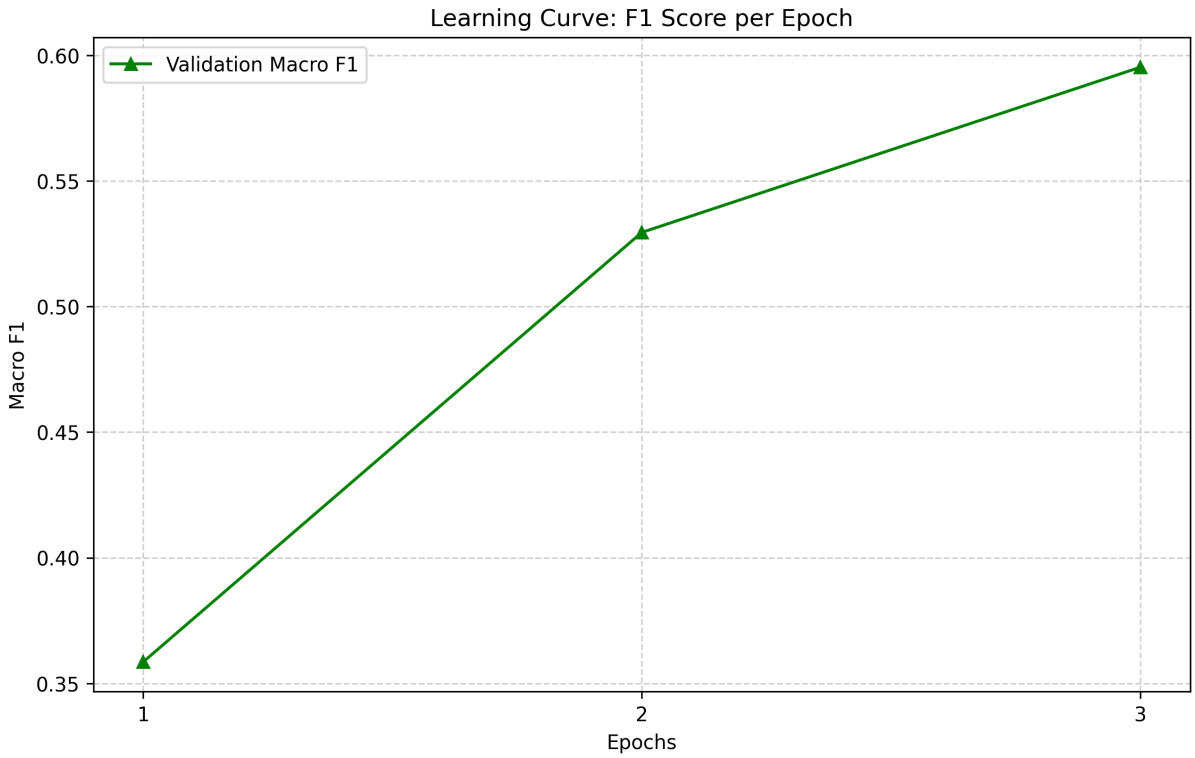

Σχήμα 12: Learning Curve του βέλτιστου μοντέλου (DeBERTa-v3) - F1 Score per epoch.

5.1.4. Καμπύλες Μάθησης. Η καμπύλη μάθησης του DeBERTa-v3 επιβεβαιώνει την ευρωστία του, αποδεικνύοντας πώς η βελτιστοποίηση των υπερπαραμέτρων οδήγησε σε σταθερή σύγκλιση, αποφεύγοντας τα φαινόμενα έντονης υπερεκπαίδευσης που παρατηρούνται συνήθως στα απλούστερα μοντέλα. Όπως αποτυπώνεται στο διάγραμμα, το Validation Macro F1 παρουσιάζει σταθερή και σημαντική αύξηση, φτάνοντας σχεδόν το 0.60 στην τρίτη εποχή, επιβεβαιώνοντας έτσι τη διαρκή βελτίωση της γενικευτικής ικανότητας του δικτύου.

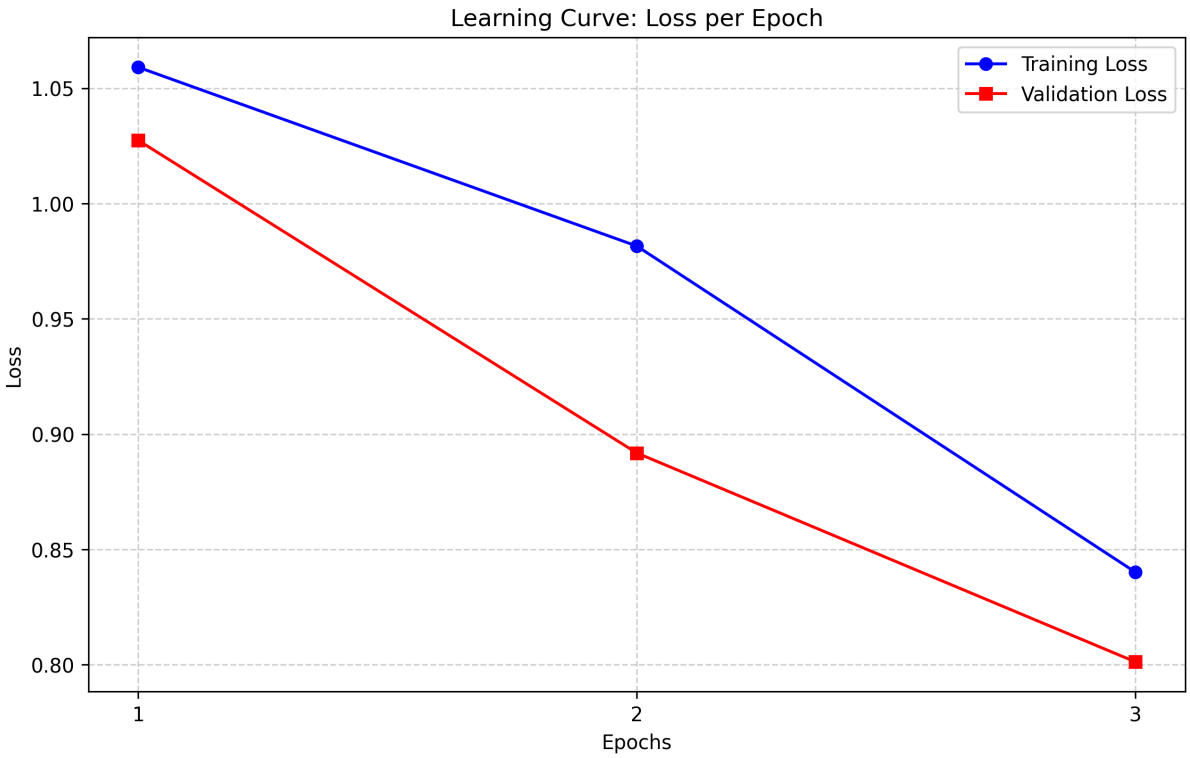

Σχήμα 13: Learning Curve του βέλτιστου μοντέλου (DeBERTa-v3) - Loss per epoch.

Αντίστοιχη σταθερότητα αποτυπώνεται και στην καμπύλη της συνάρτησης απώλειας (Loss per Epoch). Τόσο η απώλεια εκπαίδευσης (Training Loss) όσο και η απώλεια επαλήθευσης (Validation Loss) μειώνονται ομαλά και συντονισμένα κατά τη διάρκεια των τριών εποχών. Η παράλληλη αυτή πτωτική πορεία, χωρίς ιδιαίτερο σημάδι απόκλισης μεταξύ των δύο καμπυλών, αποτελεί την απόλυτη επιβεβαίωση για την υγιή σύγκλιση του μοντέλου και την πλήρη απουσία υπερπροσαρμογής (overfitting).

5.2. Συγκριτική Ανάλυση Σφαλμάτων

Προκειμένου να κατανοηθούν οι περιορισμοί των μοντέλων, πραγματοποιήθηκε ενδελεχής μελέτη των λανθασμένων προβλέψεων, όπως εξήχθησαν από τα πειράματα (242 σφάλματα για το DeBERTa-v3, 239 για το BERT και 288 για το DistilBERT). Αντιπροσωπευτικά παραδείγματα από την ανάλυση αυτή παρατίθενται αναλυτικά στο Παράρτημα Α.

Εξετάζοντας τα δεδομένα, εντοπίζονται συγκεκριμένα γλωσσικά και σημασιολογικά μοτίβα όπου οι Transformers αποτυγχάνουν να συλλάβουν τη δομή της πολιτικής συνέντευξης. Οι κύριες κατηγορίες σφαλμάτων συνοψίζονται ως εξής:

- Παραπλανητικές εισαγωγές: Συχνά, ένας πολιτικός ξεκινά την απάντησή του με μια άμεση λέξη (π.χ. '*Well, no, Major...*'). Τα μοντέλα (BERT, DistilBERT) εντοπίζουν αμέσως τη λέξη άρνησης ή κατάφασης και βιάζονται να ταξινομήσουν το δείγμα ως Clear Non-Reply ή, αντίστοιχα, Clear Reply. Αδυνατούν δηλαδή να αντιληφθούν ότι ο ομιλητής στη συνέχεια αναπτύσσει μια μακροσκελή υπεκφυγή, γεγονός που θα απαιτούσε βαθύτερη κατανόηση του ευρύτερου πλαισίου εκ μέρους τους.

- Μακροσκελείς Απαντήσεις: Σε ερωτήσεις όπου η απάντηση δίνεται άμεσα αλλά ακολουθείται από έναν τεράστιο μονόλογο (π.χ. η απάντηση για τον Judge Kavanaugh:

'*It wouldn't bother me...*'), τα μοντέλα με μικρότερη χωρητικότητα τείνουν να ξεχνούν την αρχική ξεκάθαρη τοποθέτηση. Λόγω του περιορισμένου παραθύρου προσοχής (attention span), καταλήγουν να ταξινομούν το κείμενο ως Ambivalent, αγνοώντας την αρχική πρόθεση του ομιλητή, καθώς η πληροφορία στο τέλος της ακολουθίας τείνει να επισκιάζει το αρχικό καθαρό σήμα.

- Αδυναμία διάκρισης μεταξύ Αμυντικής Στάσης και Πλήρους Υπεκφυγής: Όταν ο πολιτικός χρησιμοποιεί φράσεις κλεισίματος ή αμυντικής στάσης, όπως '*I will be rendering no opinion from the podium*', τα μοντέλα (όπως παρατηρήθηκε στο DeBERTa) παρερμηνεύουν αυτή την ένταση ως απόλυτη άρνηση απάντησης (Clear Non-Reply). Στην πραγματικότητα, η συνολική τοποθέτηση είναι συχνά διφορούμενη (Ambivalent), αλλά το δίκτυο υπερ-εστιάζει στη φράση άρνησης.

Για την πληρέστερη κατανόηση της συμπεριφοράς του δικτύου (model behavior) DeBERTa, κρίθηκε σκόπιμη η εξέταση των πιθανοτήτων που εξάγει η συνάρτηση Softmax πριν την τελική ταξινόμηση. Όπως φαίνεται στον παρακάτω πίνακα, αποκαλύπτεται μια εξαιρετικά ενδιαφέρουσα πτυχή της διαδικασίας λήψης αποφάσεων του μοντέλου:

Πίνακας 7: Ανάλυση Κατανομής Πιθανοτήτων (Softmax Probabilities) σε επιλεγμένα δείγματα - DeBERTA

Δείγμα	Πραγματική Κλάση	Τελική Πρόβλεψη	Πιθανότητες Μοντέλου			Αποτέλεσμα
			Clear Reply	**Ambivalent**	**Non-Reply**	
1	Ambivalent	Clear Reply	49.51%	47.23%	3.26%	Λάθος
2	Clear Reply	Ambivalent	37.23%	57.70%	5.07%	Λάθος
3	Ambivalent	Ambivalent	44.15%	51.87%	3.98%	Σωστό
4	Clear Reply	Ambivalent	40.13%	55.91%	3.96%	Λάθος
5	Clear Reply	Clear Reply	80.41%	17.35%	2.24%	Σωστό

- Οριακές Αποφάσεις (**Borderline Cases**): Στα Δείγματα 1 και 3, παρατηρούμε ότι το μοντέλο είναι βαθιά 'διχασμένο' μεταξύ των κλάσεων Clear Reply και Ambivalent, δίνοντας πιθανότητες που αγγίζουν το 50-50 (π.χ. 49.51% έναντι 47.23% στο Δείγμα 1). Αυτό αποδεικνύει ότι τα λάθη του δικτύου δεν είναι τυχαία, αλλά αντικατοπτρίζουν την πραγματική σημασιολογική ασάφεια των δεδομένων, όπου τα διαχωριστικά όρια των δύο αυτών κλάσεων είναι εξαιρετικά ρευστά.

- Σιγουριά στις ξεκάθαρες δομές: Αντίθετα, όταν ο πολιτικός λόγος είναι πράγματι άμεσος και σαφής (Δείγμα 5), το μοντέλο δεν διστάζει, συγκεντρώνοντας πάνω από 80% της πιθανότητας στη σωστή κλάση.

- Η επίδραση της 'Αυστηρότητας': Στα Δείγματα 2 και 4, ενώ η πραγματική κλάση είναι Clear Reply, το δίκτυο αποδίδει ελαφρώς μεγαλύτερη πιθανότητα στην Ambivalent (περίπου 55-57%). Αυτό εξηγεί την 'αυστηρότητα' που παρατηρήθηκε νωρίτερα στον Πίνακα Σύγχυσης, καθώς το μοντέλο, έχοντας εκπαιδευτεί να είναι καχύποπτο απέναντι σε μακροσκελείς ή πολύπλοκες απαντήσεις, τείνει να 'γέρνει' οριακά προς την υπεκφυγή, ακόμα και όταν τελικά απαντάται η ερώτηση.

Αντίστοιχες παρατηρήσεις έχουμε και για τα 2 άλλα μοντέλα:

Πίνακας 8: Ανάλυση Κατανομής Πιθανοτήτων (Softmax Probabilities) σε επιλεγμένα δείγματα για το μοντέλο DistilBERT

Δείγμα	Πραγματική Κλάση	Τελική Πρόβλεψη	Πιθανότητες Μοντέλου			Αποτέλεσμα
			Clear Reply	**Ambivalent**	**Non-Reply**	
1	Ambivalent	Clear Reply	75.29%	22.55%	2.16%	Λάθος
2	Clear Reply	Ambivalent	42.21%	53.67%	4.12%	Λάθος
3	Ambivalent	Ambivalent	41.39%	54.50%	4.11%	Σωστό
4	Clear Reply	Ambivalent	37.20%	59.47%	3.33%	Λάθος
5	Clear Reply	Clear Reply	77.45%	19.20%	3.35%	Σωστό

- Λανθασμένες προβλέψεις με υψηλή βεβαιότητα: Χαρακτηριστικό παράδειγμα αποτελεί το Δείγμα 1. Αν και η πραγματική κλάση είναι Ambivalent, το DistilBERT ταξινομεί το κείμενο ως Clear Reply με υπερβολική σιγουριά (75.29%). Αυτή η 'αφελής' βεβαιότητα υποδηλώνει ότι το μοντέλο παραπλανάται εύκολα από επιφανειακά χαρακτηριστικά (π.χ. την ύπαρξη λέξεων κατάφασης στην αρχή της πρότασης), αδυνατώντας να συλλάβει την ευρύτερη υπεκφυγή που ακολουθεί.

- Σύγχυση μεταξύ Απάντησης και Υπεκφυγής: Στα Δείγματα 2 και 4, το δίκτυο αποτυγχάνει να αναγνωρίσει τις ξεκάθαρες απαντήσεις, αποδίδοντάς τες στην κλάση Ambivalent (με πιθανότητες 53.67% και 59.47% αντίστοιχα). Φαίνεται πως οι μακροσκελείς ή συντακτικά πολύπλοκες απαντήσεις εξαντλούν το 'παράθυρο προσοχής' (attention span) του συμπιεσμένου μοντέλου, οδηγώντας το στην πιο 'ασφαλή', ενδιάμεση επιλογή της αμφισημίας.

- Ανασφάλεια στις ορθές προβλέψεις Αμφισημίας: Ακόμα και όταν το μοντέλο προβλέπει σωστά την κλάση Ambivalent (Δείγμα 3), το πράττει με οριακή πλειοψηφία (54.50% έναντι 41.39% της κλάσης Clear Reply). Σε αντίθεση με τις ορθές προβλέψεις της κλάσης Clear Reply όπου εμφανίζει υψηλή βεβαιότητα (77.45% στο Δείγμα 5), το DistilBERT δυσκολεύεται δομικά να δημιουργήσει ένα αυστηρό διαχωριστικό όριο (decision boundary) για τις υπεκφυγές.

Πίνακας 9: Ανάλυση Κατανομής Πιθανοτήτων (Softmax Probabilities) σε επιλεγμένα δείγματα για το μοντέλο BERT

Δείγμα	Πραγματική Κλάση	Τελική Πρόβλεψη	Πιθανότητες Μοντέλου			Αποτέλεσμα
			Clear Reply	**Ambivalent**	**Non-Reply**	
1	Ambivalent	Clear Reply	77.11%	22.32%	0.58%	Λάθος
2	Clear Reply	Ambivalent	44.53%	52.35%	3.12%	Λάθος
3	Ambivalent	Ambivalent	37.30%	60.57%	2.13%	Σωστό
4	Clear Reply	Ambivalent	29.42%	68.71%	1.87%	Λάθος
5	Clear Reply	Clear Reply	90.38%	9.04%	0.58%	Σωστό

- Απόλυτη βεβαιότητα σε ξεκάθαρα μοτίβα: Σε αντίθεση με το DistilBERT, όταν το BERT συναντά μια πραγματικά άμεση απάντηση (Δείγμα 5), η πλήρης αρχιτεκτονική του επιτρέπει να πάρει την απόφαση με εντυπωσιακή σιγουριά, ξεπερνώντας το 90% (90.38%). Αυτό υποδεικνύει βαθύτερη κατανόηση των αμιγώς καταφατικών συντακτικών δομών.

- Υπερβολική κλίση προς την Αμφισημία: Παρατηρώντας τα Δείγματα 2 και 4 (όπου πραγματικές απαντήσεις ταξινομούνται λανθασμένα ως Ambivalent), διαπιστώνεται μια κλιμακούμενη πεποίθηση υπέρ της υπεκφυγής (52.35% και 68.71% αντίστοιχα). Το μοντέλο, έχοντας εκπαιδευτεί στο εξαιρετικά πολύπλοκο πλαίσιο του πολιτικού λόγου, φαίνεται να αναπτύσσει μια 'υπερδιόρθωση', αναζητώντας διαρκώς υπεκφυγή πίσω από τις λέξεις, θυσιάζοντας έτσι την ικανότητά του να αναγνωρίζει τις περιπτώσεις όπου ο ομιλητής πράγματι απαντά στο ερώτημα.

- Εμμονή στις παραπλανητικές εισαγωγές: Παρά την ανώτερη χωρητικότητά του σε σχέση με το DistilBERT, το BERT εξακολουθεί να πέφτει στην παγίδα των παραπλανητικών εισαγωγών (Δείγμα 1). Αποδίδοντας 77.11% στην κλάση Clear Reply για ένα κείμενο που στην πραγματικότητα είναι Ambivalent, αποδεικνύεται ότι η προσοχή του (attention) μονοπωλείται έντονα από συγκεκριμένες λέξεις-κλειδιά στην αρχή της πρότασης, παραβλέποντας το σημασιολογικό πλαίσιο (context) που ακολουθεί.

6. Προτάσεις για Μελλοντική Έρευνα

Αν και η χρήση προεκπαιδευμένων μοντέλων Transformer βελτίωσε αισθητά την κατανόηση του φυσικού κειμένου σε σχέση με τις παραδοσιακές μεθόδους, η παρούσα έρευνα θα μπορούσε να επεκταθεί στις εξής κατευθύνσεις:

- Συνδυαστική Μάθηση (***Ensemble Learning***): Δεδομένου ότι εκπαιδεύτηκαν τρία διαφορετικά αρχιτεκτονικά μοντέλα (BERT, DistilBERT, DeBERTa-v3), ένα επόμενο βήμα θα ήταν η δημιουργία ενός μηχανισμού συνδυασμού τους. Ένας ταξινομητής πλειοψηφίας ή ένας μηχανισμός σταθμισμένου μέσου όρου των πιθανοτήτων θα μπορούσε να συνδυάσει τα δυνατά σημεία του κάθε μοντέλου ενώ, ταυτόχρονα, μειώνει τα επιμέρους σφάλματά τους.

- Βελτιστοποίηση Χρονοπρογραμματισμού (***Learning Rate Scheduling***): Μια σημαντική βελτίωση θα ήταν η εισαγωγή ενός (Learning Rate Scheduler), όπως ο Linear Decay με Warmup. Η χρήση ενός τέτοιου μηχανισμού, ειδικά σε συνδυασμό με μεγαλύτερο αριθμό εποχών, θα επέτρεπε στο μοντέλο να συγκλίνει με μεγαλύτερη ακρίβεια σε ένα βέλτιστο τοπικό ελάχιστο, αποφεύγοντας τις απότομες διακυμάνσεις κατά τα τελευταία στάδια της εκπαίδευσης.

- Αξιολόγηση Μεγαλύτερων Αρχιτεκτονικών: Στην παρούσα εργασία εξετάστηκαν, λόγω περιορισμένου χρόνου, οι βασικές (base) εκδόσεις των μοντέλων. Θα είχε ερευνητικό ενδιαφέρον η δοκιμή των αντίστοιχων μεγαλύτερων παραλλαγών τους (π.χ. BERT-large ή DeBERTa-v3-large). Αν και τα μοντέλα αυτά απαιτούν σημαντικά αυξημένους υπολογιστικούς πόρους, η μεγαλύτερη χωρητικότητά τους ίσως επιτρέψει την καλύτερη αναγνώριση περίπλοκων γλωσσικών μοτίβων και έμμεσων υπεκφυγών.

- Διασταυρούμενη Επικύρωση (***k-fold Cross-Validation***): Όπως αναφέρθηκε σε προηγούμενη ενότητα, ο περιορισμός των διαθέσιμων πόρων της GPU μας περιόρισε σε έναν στατικό διαχωρισμό του train set. Σε ένα υπολογιστικά δυνατότερο περιβάλλον, η εφαρμογή της 5-fold Cross-Validation θα παρείχε μια πιο αντικειμενική εικόνα για την ικανότητα γενίκευσης των μοντέλων. Ειδικότερα, θα μπορούσε κανείς να συνδυάσει αυτήν την προσέγγιση με μια εκτενέστερη αναζήτηση στο Optuna (με ένα grid search για batch size, learning rate, dropout, weight decay κ.α.) αλλά και, ενδεχομένως, με τη χρήση Early Stopping σε συνδυασμό με τεχνικές όπως Learning Rate Warmup. Μέσω αυτής της πρακτικής, η εκπαίδευση θα ξεκινούσε με έναν ελάχιστο ρυθμό εκμάθησης ο οποίος θα αυξανόταν σταδιακά, επιτρέποντας στο δίκτυο να ¨χαρτογραφήσει' ομαλά τον χώρο, χωρίς να διαταράξει απότομα τα ευαίσθητα προεκπαιδευμένα του βάρη (catastrophic forgetting).

- Επαύξηση Δεδομένων με Παραγωγική ΤΝ (***Generative Data Augmentation***): Μια πιθανή μελλοντική προσέγγιση θα ήταν η χρήση σύγχρονων Μεγάλων Γλωσσικών Μοντέλων (LLMs) για τη δημιουργία ρεαλιστικών δειγμάτων με στόχο την (πληθική) ενίσχυση των μειοψηφικών κλάσεων, ενισχύοντας το μοντέλο και τροφοδοτώντας το, εν τέλει, με μεγαλύτερο σύνολο εκπαίδευσης.

7. Βιβλιογραφία

[1] Διαφάνειες Διαλέξεων - Artificial Intelligence 2: Deep Learning for Natural Language Processing, 2026. Εαρινό Εξάμηνο 2025-2026, SemEval 2026 Task 6.

[2] Devlin, Jacob and Chang, Ming-Wei and Lee, Kenton and Toutanova, Kristina. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *arXiv preprint arXiv:1810.04805*, 2018.

[3] He, Pengcheng and Gao, Jianfeng and Chen, Weizhu. DeBERTaV3: Improving DeBERTa using ELECTRA-Style Pre-Training with Gradient-Disentangled Embedding Sharing. *arXiv preprint arXiv:2111.09543*, 2021.

[4] Jurafsky, Daniel and Martin, James H. Speech and Language Processing (3rd ed. draft). https://web.stanford.edu/~jurafsky/slp3/, 2024. Chapters 4–5 and 7.

[5] Paszke, Adam and others. PyTorch: An Imperative Style, High-Performance Deep Learning Library. In *Advances in Neural Information Processing Systems 32*, 2019.

[6] Pedregosa, F. and Varoquaux, G. and Gramfort, A. and Michel, V. and Thirion, B. and Grisel, O. and Blondel, M. and Prettenhofer, P. and Weiss, R. and Dubourg, V. and Vanderplas, J. and Passos, A. and Cournapeau, D. and Brucher, M. and Perrot, M. and Duchesnay, E. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.

[7] Sanh, Victor and Debut, Lysandre and Chaumond, Julien and Wolf, Thomas. DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. *arXiv preprint arXiv:1910.01108*, 2019.

[8] Wolf, Thomas and others. Transformers: State-of-the-Art Natural Language Processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 2020.

[9] Wes McKinney. Data Structures for Statistical Computing in Python. In Stéfan van der Walt and Jarrod Millman, editor, *Proceedings of the 9th Python in Science Conference*, pages 56 – 61, 2010.

8. Παραρτήματα - Πρόσθετες Θεωρήσεις

8.1. Παράρτημα Α: Δειγματοληπτικό **Error Analysis**

Στον παρακάτω πίνακα παρατίθεται ένα αντιπροσωπευτικό δείγμα από το συνολικό αρχείο των λανθασμένων προβλέψεων των μοντέλων, το οποίο επιβεβαιώνει τα συμπεράσματα της Ενότητας 'Συγκριτική Ανάλυση Σφαλμάτων'.

Πίνακας 10: Αντιπροσωπευτικά παραδείγματα λανθασμένων ταξινομήσεων των μοντέλων

Ερώτηση (**Question**)	Απάντηση (**Answer**)	Πραγματική Κλάση	Πρόβλεψη Μοντέλου
"Thank you, Mr. President. As you well know, sir, finding votes for the debt ceiling can sometimes be complicated..."	*"Well, no, Major, I think if you look at the history, getting votes for the debt ceiling is always difficult..."*	Ambivalent	Clear Reply (BERT)
"What would be the problem with the FBI reopening their background investigation into Judge Kavanaugh? Would you support such a thing?"	*"It wouldn't bother me, other than the FBI, Jon, said that they really don't do that... I feel so badly for him..."*	Clear Reply	Ambivalent (DistilBERT)
"Why can't you say yes or no about the tapes and their destruction?"	*"It sounds pretty clear to me when I say I have – the first recollection is when Mike Hayden briefed me... I will be rendering no opinion from the podium."*	Ambivalent	Clear Non-Reply (DeBERTa)
"To follow on a question that was asked yesterday... do you believe that the United States should refer to Pakistan as a terrorist state?"	*"With respect to Kashmir, obviously, this is a longstanding dispute between India and Pakistan..."*	Clear Reply	Ambivalent (DistilBERT)

Παρατηρήσεις επί του πίνακα:

- Στο 1ο παράδειγμα, το μοντέλο παραπλανάται από την άμεση εισαγωγή ('Well, no') αγνοώντας τη συνέχεια της υπεκφυγής.
- Στο 2ο και 4ο παράδειγμα, τα μοντέλα DistilBERT συγχέουν τη μακροσκελή, διπλωματική απάντηση με διφορούμενη (Ambivalent) στάση, παρά την αρχική σαφήνεια.
- Στο 3ο παράδειγμα, η άρνηση περαιτέρω σχολιασμού ('no opinion') αναγκάζει το DeBERTa να ταξινομήσει λανθασμένα την απάντηση ως Clear Non-Reply.