

Deep Learning for NLP

Όνομα Φοιτητή: **Αγάπη Καλλίνικου**

AM: **sma2200210**

Μάθημα: Τεχνητή Νοημοσύνη II (YS19 M226 M262 M325 M405)

Εξάμηνο: Εαρινό Εξάμηνο 2025-2026

Περιεχόμενα

1	Σύνδεσμοι Κώδικα (Kaggle Notebooks)	3
2	Επεξεργασία και Ανάλυση Δεδομένων	3
2.1	Προεπεξεργασία	3
2.2	Ανάλυση	3
2.3	Διαχωρισμός Δεδομένων	4
2.4	Διανυσματική Αναπαράσταση και Few-Shot Selection	5
3	Αλγόριθμοι και Πειραματική Διαδικασία	6
3.1	Πειραματική Διαδικασία	6
3.2	Σχεδιασμός Προτροπών (Prompt Design) και Οδηγίες	6
3.2.1	Πίνακας Πειραμάτων	7
3.3	Inference Settings και Περιορισμοί	7
3.4	Τεχνικές Βελτιστοποίησης και Εξαγωγής Αποτελεσμάτων (Output Parsing)	8
3.5	Αξιολόγηση και Ανάλυση Πειραμάτων	9
4	Αποτελέσματα και Συνολική Ανάλυση	10
4.1	Ανάλυση Αποτελεσμάτων	10
4.1.1	Βέλτιστη δοκιμή	15
4.1.2	Πίνακας Σύγχυσης	15
4.2	Ανάλυση Σφαλμάτων και Συγκριτική Αξιολόγηση	17
4.3	Ιδανικό Αρχιτεκτονικό Σύστημα	18
5	Προτάσεις για Μελλοντική Έρευνα	20
6	Βιβλιογραφία	21
7	Παραρτήματα - Πρόσθετες Θεωρήσεις	22

Περίληψη

Η παρούσα εργασία εστιάζει στην ανάπτυξη ενός συστήματος ταξινόμησης πολιτικού λόγου, με στόχο την αξιολόγηση της σαφήνειας των απαντήσεων σε πολιτικές συνεντεύξεις (**Clear Reply**, **Ambivalent**, **Clear Non-Reply**). Η προσέγγιση βασίστηκε αποκλειστικά σε τεχνικές μηχανικής προτροπών (**Prompt Engineering**), αξιοποιώντας γλωσσικά μοντέλα διάφορων μεγεθών της οικογένειας **Qwen3.5** (0.8B, 2B, 4B).

Μέσα από τη συστηματική σύγκριση διαφορετικών στρατηγικών (**Zero-Shot**, **Few-Shot**, **Chain-of-Thought**), αναδείχθηκε ως βέλτιστη διαμόρφωση το μοντέλο **Qwen3.5-2B** υπό τη στρατηγική **Zero-Shot**, επιτυγχάνοντας το υψηλότερο και πιο ισορροπημένο **Macro F1-Score** (≈ 0.44). Η συγκεκριμένη αρχιτεκτονική επέδειξε την ιδανική ισορροπία μεταξύ υπολογιστικής αποδοτικότητας και γλωσσικής κατανόησης, αποφεύγοντας τη γνωστική υπερφόρτωση (**thinking loops**) που έπληξε το μοντέλο **0.8B** και τους περιορισμούς μνήμης που περιόρισαν το μεγαλύτερο μοντέλο των **4B**.

Επιπλέον, η ανάλυση σφαλμάτων ανέδειξε κρίσιμες διαφορές συμπεριφοράς μεταξύ παραγωγικών και διαχωριστικών μοντέλων. Ενώ τα **discriminative** μοντέλα εμφανίζουν ταξινομική «καχυποψία», τα **generative base** μοντέλα τείνουν προς μια εγγενή «επιείκεια», εκλαμβάνοντας συχνά τις διπλωματικές γενικολογίες και τις λέξεις-γεμίσματα ως ξεκάθαρες απαντήσεις, γεγονός το οποίο φαίνεται από την τάση υπερ-πρόβλεψης του **Clear Reply** στο 68.9% των λαθών. Παράλληλα, η στρατηγική υπερανάλυσης (**CoT**) αποδείχθηκε επιζήμια, καθώς οδήγησε τα μοντέλα στο να «δικαιολογούν» τις πολιτικές υπεκφυγές, καθιστώντας την κλάση **Clear Non-Reply** την πιο απαιτητική στην αναγνώριση.

Συμπερασματικά, η μελέτη καταδεικνύει ότι, ενώ τα **LLMs** διαθέτουν εξαιρετικές ικανότητες κατανόησης σημασιολογίας, τους λείπει η απαραίτητη λογική για την αποκωδικοποίηση των στρατηγικών και των τεχνασμάτων του πολιτικού λόγου.

1. Σύνδεσμοι Κώδικα (Kaggle Notebooks)

Ο κώδικας για την ανάπτυξη και την αξιολόγηση των μοντέλων είναι διαθέσιμος στον παρακάτω σύνδεσμο:

- **Implementation:** <https://www.kaggle.com/code/agapikallinikou/sma2200210-homework-3-prompting>

2. Επεξεργασία και Ανάλυση Δεδομένων

2.1. Προεπεξεργασία

Η διαδικασία προεπεξεργασίας των δεδομένων του **dataset** σχεδιάστηκε με γνώμονα τη διασφάλιση της ποιότητας των δεδομένων και την αποφυγή φαινομένων που αλλοιώνουν την αξιοπιστία της αξιολόγησης. Σε αντίθεση με την 1η και τη 2η εργασία, όπου η προεπεξεργασία περιελάμβανε **text normalization**, μορφοποίηση εισόδου ή και **stemming**, εδώ εστιάζουμε στη δομική ακεραιότητα του κειμένου, καθώς η συντακτική δομή και τα σημεία στίξης φέρουν κρίσιμη σημασιολογική πληροφορία για τον εντοπισμό πιθανής υπεκφυγής και, εν γένει, για την ζητούμενη ταξινόμηση.

- Αφαίρεση Διπλοτύπων: Πραγματοποιήθηκε έλεγχος και αφαίρεση διπλότυπων καταχωρίσεων στο **Training Set** με βάση τον μοναδικό συνδυασμό της πολιτικής ερώτησης και της αντίστοιχης απάντησης. Η διαδικασία αυτή απέκλεισε την πιθανότητα υπερ-εκπαίδευσης του μοντέλου σε επαναλαμβανόμενα μοτίβα κατά τη διαδικασία του **few-shot selection**.
- Κενές εγγραφές: Από την ανάλυση του **dataset** σε προηγούμενες εργασίες συμπεραίνουμε ότι δεν υπάρχουν κενές εγγραφές, οπότε στην παρούσα δεν πραγματοποιούμε αντίστοιχο έλεγχο.
- Έλεγχος **Data Leakage**: Υλοποιήθηκε έλεγχος προκειμένου να διαπιστωθεί αν δείγματα του **Train Set** συνυπάρχουν στο **Test Set**. Στην περίπτωση του **prompting**, η διαρροή δεδομένων μπορεί να οδηγήσει σε τεχνητή μνήμη αντί για πραγματική ικανότητα γενίκευσης βάσει του **context**, γεγονός που διαφοροποιείται από το **gradient-based fine-tuning** της 2ης εργασίας, όπου η διαρροή προκαλεί άμεση αλλοίωση των βαρών του δικτύου.

2.2. Ανάλυση


Προκειμένου να κατανοηθεί σε βάθος η δομή και οι ιδιαιτερότητες του συνόλου δεδομένων, η διαδικασία της προεπεξεργασίας πραγματοποιήθηκε στηριζόμενη στα συμπεράσματα που αποκτήθηκαν μέσω της Εξερευνητικής Ανάλυσης Δεδομένων (Exploratory Data Analysis - EDA) που πραγματοποιήθηκε στην πρώτη εργασία. Αξίζει να σημειωθεί ότι η ανάλυση της κατανομής των κλάσεων και του μήκους των κειμένων είχε πραγματοποιηθεί στα αρχικά, ακατέργαστα δεδομένα. Αυτό κρίθηκε ως η βέλτιστη πρακτική, προκειμένου να αποτυπωθεί η πραγματική δομή του **dataset** πριν υποστεί την οποιαδήποτε αλλοίωση. Παρακάτω παρουσιάζονται μερικά από τα συμπεράσματα της πρώτης εργασίας.

Αρχικά, στην ανάλυση εξετάστηκε η προέλευση των δηλώσεων, με το σύνολο των 3.448 δειγμάτων να μοιράζεται σε τέσσερις προέδρους των ΗΠΑ: Donald J. Trump (1.325), Barack

Obama (1.010), George W. Bush (714) και Joseph R. Biden (399). Επίσης, πραγματοποιήθηκε ανάλυση του μήκους των κειμένων για την κατανόηση της δομής τους. Τα αποτελέσματα παρουσιάζονται αναλυτικά στον Πίνακα 1, όπου και διαφαίνεται η γενικότερη τάση των πολιτικών προσώπων για σύντομες και περιεκτικές δηλώσεις κατά τη διάρκεια των συνεντεύξεων. Σημειώνουμε ότι η υψηλή τυπική απόκλιση υποδηλώνει μεγάλη μεταβλητότητα στην έκταση του πολιτικού λόγου, όπως άλλωστε ήταν αναμενόμενο.

Πίνακας 1: Στατιστικά στοιχεία μήκους κειμένων (word count) σε στρογγυλοποίηση

Στατιστικό Μέγεθος	Τιμή
Πλήθος Δειγμάτων Λέξεων (Count)	3.390
Μέσος Όρος (Mean)	294,02
Τυπική Απόκλιση (Std)	300,96
Ελάχιστο (Min)	1
25% (Πρώτο Τεταρτημόριο)	58,25
Διάμεσος (50%)	208
75% (Τρίτο Τεταρτημόριο)	440
Μέγιστο (Max)	2.117



Σχήμα 1: Ανισορροπία κλάσεων.

Σύμφωνα με το παραπάνω σχήμα, παρατηρείται έντονη ανισορροπία (class imbalance) στα δεδομένα. Η συντριπτική κυριαρχία της αμφίσημης κατηγορίας αντανακλά τη φύση του πολιτικού λόγου, όπου τα πολιτικά πρόσωπα συχνά επιλέγουν έμμεσες ή διπλωματικές τοποθετήσεις αντί για ευθείες απαντήσεις.

2.3. Διαχωρισμός Δεδομένων

Για την ανάπτυξη και την αξιολόγηση των μοντέλων, αξιοποιήθηκε το επίσημο σύνολο δεδομένων του διαγωνισμού SemEval 2026 (Task 6). Η βασική κατάτμηση σε σύνολο εκπαίδευσης (**train set**) και σύνολο δοκιμής (**test set**) διατηρήθηκε όπως καθορίστηκε από τους διοργανωτές. Ωστόσο, αν και στις προηγούμενες εργασίες είχαν αξιοποιηθεί οι μέθοδοι **5-fold Cross-Validation** (1η εργασία) και στατικός διαχωρισμός του αρχικού συνόλου εκπαίδευσης σε ποσοστό 80% για **training** και 20% για **validation** (2η εργασία), στην παρούσα εργασία δεν υπάρχει η ανάγκη για δημιουργία συνόλου επικύρωσης αφού δεν υφίσταται εκπαίδευση. Συγκεκριμένα, ακολουθήθηκε η εξής μέθοδος:

Για την εκτέλεση αξιόπιστων πειραμάτων χωρίς την εξάντληση των υπολογιστικών πόρων, εφαρμόστηκε **Stratified Split** στο αρχικό **Training Set**. Απομονώθηκε ένα αντιπροσωπευτικό σύνολο αξιολόγησης 400 δειγμάτων, το οποίο θεωρήσαμε **Evaluation Subset**, διατηρώντας αυστηρά την αρχική αναλογία των κλάσεων. Ο διαχωρισμός αυτός είναι θεμιτός καθώς δεν απαιτείται **training**, οπότε είναι εύλογη η χρήση υποσυνόλου του συνόλου των δεδομένων με στόχο τη σύγκριση μοντέλων και μεθόδων. Η επιλογή του μεγέθους έγινε σκόπιμα, καθώς (το 400) αποτελεί έναν πρακτικό και ελεγχόμενο αριθμό που εξασφαλίζει επαρκή στατιστική σημαντικότητα για την εξαγωγή αξιόπιστων μετρικών. Το σύνολο αυτό εμφανίζει έντονη ταξινομική ανισορροπία, η οποία επηρεάζει άμεσα τη συμπεριφορά των μοντέλων:

- **Ambivalent:** 59.25% (237 δείγματα).
- **Clear Reply:** 30.50% (122 δείγματα).
- **Clear Non-Reply:** 10.25% (41 δείγματα).

Η συγκεκριμένη κατανομή καθιστά το **Accuracy** ως μετρική εξαιρετικά παραπλανητική. Όπως θα αναλυθεί στα αποτελέσματα, ένα μοντέλο μπορεί να επιτύχει υψηλό **Accuracy** απλά αποκτώντας **bias** προς την κυρίαρχη κλάση (**Ambivalent**), γεγονός που καθιστά το **Macro F1-Score** τη μοναδική αξιόπιστη μετρική για την αξιολόγηση των συστημάτων μας, όπως ακριβώς ίσχυε και στις προηγούμενες εργασίες ταξινόμησης.

Το εναπομείνον τμήμα των δεδομένων αποθηκεύτηκε ως **fewshot_pool**. Αυτή η δεξαμενή δεδομένων χρησιμοποιήθηκε αποκλειστικά για την άντληση δειγμάτων που χρειάστηκαν στη μέθοδο **FewShot Prompting**.

Τέλος, ορίστηκε μια σταθερή τιμή αρχικοποίησης (**random_state=42**), προκειμένου να διασφαλιστεί η πλήρης επαναληψιμότητα των πειραμάτων. Ωστόσο, αξίζει να αναφερθεί πως, λόγω μη-ντετερμινιστικών παραγόντων χαμηλού επιπέδου (όπως η φύση του **hardware** αλλά και των ίδιων των μοντέλων), ενδέχεται να παρατηρηθούν ελάχιστες, στατιστικά μη σημαντικές, διαφοροποιήσεις στα δεκαδικά ψηφία των **score** μεταξύ διαφορετικών εκτελέσεων.

2.4. Διανυσματική Αναπαράσταση και **Few-Shot Selection**

Στην παρούσα εργασία δεν υφίσταται κλασική διανυσματική αναπαράσταση (όπως οι πίνακες **TF-IDF** ή τα **contextualized embeddings** που χρησιμοποιήθηκαν σε προηγούμενες εργασίες), καθώς τα μοντέλα επεξεργάζονται το κείμενο στην εγγενή του μορφή μέσω του **Tokenizer**.

Ωστόσο, η επιλογή των παραδειγμάτων για τη στρατηγική **Few-Shot** βασίστηκε στην εξής προσέγγιση: Με τη χρήση σταθερού **seed** (42), ο αλγόριθμος επιλέγει τυχαία αλλά ισορροπημένα $k = 3$ δείγματα από κάθε μία από τις 3 κλάσεις (δηλαδή συνολικά 9 δειγματικά **shots**). Η εξασφάλιση της ταξινομικής ισορροπίας είναι κρίσιμη, καθώς αποτρέπει το μοντέλο από το να αναπτύξει **bias** προς την πλειοψηφική κλάση λόγω συχνότητας εμφάνισης ή θέσης μέσα στο **prompt**.

3. Αλγόριθμοι και Πειραματική Διαδικασία

3.1. Πειραματική Διαδικασία

Η πειραματική διαδικασία βασίστηκε στην αξιολόγηση της οικογένειας μοντέλων **Qwen3.5** σε τρεις διαφορετικές αρχιτεκτονικές μεγέθους: 0.8B, 2B, και 4B. Για κάθε μοντέλο σχεδιάστηκε ένα ενοποιημένο **inference pipeline** το οποίο υποστηρίζει τρεις **prompt engineering** στρατηγικές:

1. **Zero-Shot**: Άμεση ανάθεση της ταξινόμησης.
2. **Few-Shot**: Ενσωμάτωση των 9 ισορροπημένων παραδειγμάτων.
3. **Chain-of-Thought (CoT)**: Χρήση οδηγίας για προπαρασκευαστική ανάλυση της στρατηγικής του πολιτικού πριν την εξαγωγή του **label**.

3.2. Σχεδιασμός Προτροπών (**Prompt Design**) και Οδηγίες

Για την αποτελεσματική καθοδήγηση των μοντέλων **Qwen-3.5** και την επιβολή αυστηρών περιορισμών στην έξοδο, σχεδιάστηκε ένα ενιαίο σύστημα προτροπών. Η οδηγία συστήματος (**system instruction**) περιγράφει την ταξινόμηση κατηγοριοποίησης με επαγγελματικό τρόπο, μαζί με κρίσιμες κατευθυντήριες οδηγίες για συγκεκριμένες περιπτώσεις, με σκοπό τον μετριασμό της προκατάληψης του μοντέλου.

Η βασική προτροπή συστήματος (**base system prompt**) είναι δομημένη ως εξής:

You are a nonpartisan fact-checking analyst. Your task is to analyze political interviews and classify the politician's response based on the following taxonomy:

- Clear Reply: Directly answers the question.
- Ambivalent: Partially evades, gives a vague answer, or shifts the topic.
- Clear Non-Reply: Completely avoids answering or refuses to answer.

CRITICAL RULES:

1. Do not penalize brevity. Short, direct answers are a 'Clear Reply'.
2. If the politician corrects a false premise made by the interviewer (e.g., 'That is factually incorrect'), classify it as a 'Clear Reply', NOT as dodging.

Ανάλογα με τη στρατηγική πειραματισμού, η προτροπή αυτή προσαρμόζεται για να ελέγξει τις διαδικασίες συλλογιστικής του μοντέλου και το μήκος της παραγωγής κειμένου:

- Λειτουργίες **Zero-Shot / Few-Shot**: Τροποποιείται προσθέτοντας το εξής κείμενο: 'CRITICAL: Output ONLY the exact label from the taxonomy. No explanations, no numbering, absolutely nothing else.' Για την αποφυγή δομικής απόκλισης, το παράθυρο παραγωγής περιορίζεται αυστηρά χρησιμοποιώντας τη ρύθμιση `max_new_tokens = 20`.
- Λειτουργία **Chain-of-Thought (CoT)**: Τροποποιείται προσθέτοντας το εξής κείμενο: 'Analyze the speaker's strategy first, and then provide the classification label in the format 'Label: <your_label>'. ' Ο αριθμός για το πλαίσιο αυξάνεται σε `max_new_tokens = 512` ώστε να επιτραπεί η παραγωγή των ενδιάμεσων βημάτων συλλογιστικής.

3.2.1. Πίνακας Πειραμάτων. Στον Πίνακα 2 αποτυπώνονται συγκεντρωτικά τα αποτελέσματα όλων των πειραματικών δοκιμών που εκτελέστηκαν τοπικά στο **Evaluation Subset**.

Πίνακας 2: Συγκεντρωτικά Αποτελέσματα Πειραμάτων (Qwen3.5)

Μοντέλο	Στρατηγική	Accuracy	Precision	Recall	Macro F1	Invalid Rate (%)
Qwen3.5-0.8B	Zero-Shot	0.0000	0.0000	0.0000	0.0000	99.75%
Qwen3.5-0.8B	Few-Shot	0.0200	0.1053	0.0164	0.0284	94.75%
Qwen3.5-0.8B	CoT	0.2450	0.3535	0.3694	0.2463	0.00%
Qwen3.5-2B	Zero-Shot	0.4775	0.4900	0.4658	0.4320	0.00%
Qwen3.5-2B	Few-Shot	0.3650	0.3523	0.2922	0.3009	23.50%
Qwen3.5-2B	CoT	0.4425	0.3807	0.3965	0.3548	0.00%
Qwen3.5-4B*	Zero-Shot	0.5175	0.3245	0.2664	0.2720	4.25%
Qwen3.5-4B*	Few-Shot	0.3100	0.2694	0.1902	0.2151	35.25%
Qwen3.5-4B*	CoT	0.3500	0.2795	0.2965	0.2230	1.00%

*Σημείωση: Το μοντέλο 4B εκτελέστηκε υπό συνθήκες 4-bit Quantization.

3.3. Inference Settings και Περιορισμοί

Κατά τον σχεδιασμό και την ανάπτυξη του **inference pipeline** για τα Base μοντέλα, μελετήθηκε εκτενώς η επίσημη τεκμηρίωση (**documentation**) της Qwen. Παρότι η βιβλιογραφία προτείνει συγκεκριμένες στοχαστικές παραμέτρους δειγματοληψίας (**sampling parameters**), όπως **temperature=1.0**, και εκτεταμένα όρια παραγωγής κειμένου (έως και 32.768 tokens) προκειμένου να δοθεί επαρκής χώρος για αναλυτική συλλογιστική, η προσέγγιση αυτή κρίθηκε θεμελιωδώς ασύμβατη με το πειραματικό μας περιβάλλον.

Συγκεκριμένα, οι αυστηροί περιορισμοί υλικού της δωρεάν έκδοσης της πλατφόρμας **Kaggle** (GPUs τύπου T4/P100 με μέγιστο όριο διαθεσιμότητας τις 30 ώρες εβδομαδιαίως), σε συνδυασμό με τον αυστηρό χαρακτήρα ενός προβλήματος ταξινόμησης (**classification**), επέβαλαν μια πιο ελεγχόμενη προσέγγιση. Ο συνδυασμός αυτών με την αυξημένη ευαισθησία σε σφάλματα έλλειψης μνήμης (**Out-Of-Memory - OOM**), γεγονός που παρατηρήθηκε έντονα στα πρώτα δοκιμαστικά μας πειράματα, οδήγησε στη συνειδητή απόφαση να παρακαμφθούν οι προτεινόμενες ρυθμίσεις. Με στόχο τη δραστηκή μείωση του χρόνου εκτέλεσης (**runtime**), την πλήρη αποφυγή ατέρμονων βρόγχων (**infinite loops**) και τη βελτιστοποίηση της απόδοσης μέσω **prompt engineering**, οι τεχνικοί περιορισμοί αντιμετωπίστηκαν με τις εξής στρατηγικές ρυθμίσεις:

- **Quantization:** Αρχικά, η προσπάθεια φόρτωσης των μοντέλων έγινε με την προεπιλεγμένη ακρίβεια **bfloat16** (16-bit) και τη χρήση της παραμέτρου `device_map="auto"`, προκειμένου να κατανεμηθεί το μοντέλο και στις δύο διαθέσιμες GPUs. Ωστόσο, για το μοντέλο Qwen3.5-4B, η πλήρης αναπαράσταση ήταν αδύνατο να φορτωθεί χωρίς να προκαλέσει άμεσα σφάλμα **Out-of-Memory (OOM)**. Εφαρμόστηκε, λοιπόν, **4-bit quantization**. Η τεχνική αυτή συμπιέζει δραστηκά τις απαιτήσεις μνήμης στο 1/4, στρογγυλοποιώντας «βίαια» τα δεκαδικά ψηφία των βαρών (**weights**) του μοντέλου ώστε να χωρέσουν σε μόλις 4 bits. Αν και αυτό επιλύει τον χωρικό περιορισμό, συνεπάγεται φυσιολογικά μια απώλεια «εξυπνάδας» και ακρίβειας. Το μοντέλο των 4B διαθέτει επαρκή αριθμό παραμέτρων για να «αντέξει» αυτό το πλήγμα χωρίς να καταρρεύσει η δομή της γνώσης του. Αντίθετα, επιλέξαμε στρατηγικά να μην εφαρμόσουμε **quantization** στα μικρότερα μοντέλα (0.8B και 2B), καθώς η γνώση τους είναι ήδη

ασφυκτικά συμπιεσμένη σε λιγότερες παραμέτρους. Περαιτέρω στρογγυλοποίηση των βαρών τους δεν θα άφηνε περιθώριο για απώλειες και θα οδηγούσε αναπόφευκτα σε έντονες παραισθήσεις (*hallucinations*) κατά την παραγωγή κειμένου.

- **Decoding Parameters:** Αντί της προτεινόμενης στοχαστικότητας, ενεργοποιήθηκε η παράμετρος `do_sample=False`, εξαναγκάζοντας το μοντέλο σε **greedy decoding**. Αυτό εξασφαλίζει τη σταθερότητα, την επαναληψιμότητα των αποτελεσμάτων και την ταχύτητα στο **inference**.
- **Context Window Limits:** Απορρίπτοντας το μέγιστο όριο των 32k tokens, για τις Zero-Shot και Few-Shot στρατηγικές το `max_new_tokens` περιορίστηκε αυστηρά στο 20, καθώς το ζητούμενο ήταν αποκλειστικά η τελική ετικέτα. Αντίθετα, στην περίπτωση του Chain-of-Thought (CoT), το όριο αυξήθηκε ελεγχόμενα στο 512 για να δοθεί ο απαραίτητος χώρος στη συλλογιστική πορεία του μοντέλου.
- **Structural Text Anchoring:** Τα Base μοντέλα έχουν την έμφυτη τάση να λειτουργούν ως **text completers** αντί να ακολουθούν οδηγίες. Για να κατευθυνθεί σωστά η παραγωγή και να αποφευχθεί η άσκοπη φλυαρία, προστέθηκε τεχνητά η φράση 'Label:' στο τέλος του **prompt**, αναγκάζοντας το μοντέλο να συμπληρώσει άμεσα και καθαρά την κατηγορία ταξινόμησης.

Αξίζει να σημειωθεί ότι ο τελικός σχεδιασμός των **prompts** προέκυψε ύστερα από εκτεταμένα, επαναληπτική πειραματική διαδικασία. Κατά τα αρχικά δοκιμαστικά στάδια, χρησιμοποιήθηκαν απλούστερες, λιγότερο περιοριστικές δομές οδηγιών. Αυτές οι χαλαρές δομές επέτρεπαν μεν στο μικρότερο μοντέλο (Qwen3.5-0.8B) να επιτύχει ένα στοιχειώδες **Macro F1-Score** της τάξης του 0.25, ωστόσο αποδείχθηκαν εντελώς ανεπαρκείς για τον έλεγχο των μεγαλύτερων μοντέλων (2B και 4B), οδηγώντας τα σε σχεδόν απόλυτο ποσοστό άκυρων προβλέψεων.

Βρισκόμενοι μπροστά σε αυτήν την κατάσταση, επιλέξαμε στρατηγικά να αυξήσουμε την πολυπλοκότητα και την αυστηρότητα του **prompt**, εισάγοντας σαφείς δομικούς περιορισμούς (όπως η τεχνική του **Hidden CoT**), αλλά και δίνοντας στο μοντέλο τον 'ορισμό' της κάθε κλάσης, αφού άλλωστε η βιβλιογραφία ενθαρρύνει τα αναλυτικά προμπτς. Η απόφαση αυτή αποτέλεσε μια συνειδητή «θύσια» της απόδοσης του 0.8B, το οποίο δεν διέθετε την απαραίτητη ικανότητα κατανόησης (**comprehension capacity**) για να ακολουθήσει τις σύνθετες οδηγίες, με αποτέλεσμα την πλήρη κατάρρευσή του (εκτίναξη του **Invalid Rate**) στα τελικά πειράματα. Το αντιστάθμισμα (**trade-off**), ωστόσο, κρίνεται απολύτως επιτυχές, καθώς αυτή η αυστηρή δομή «ξεκλείδωσε» την πραγματική ικανότητα του 2B, βελτιστοποιώντας την παραγωγή του και ανεβάζοντας την απόδοσή του στο ≈ 0.44 (**Macro F1**). Φυσικά, κατά τη φάση των πειραματικών δοκιμών μεταξύ των μοντέλων χρησιμοποιήθηκαν τα ίδια **prompts**, ώστε να υπάρχει ένα σημείο αναφοράς για τη σύγκριση των τιμών των μετρικών τους.

3.4. Τεχνικές Βελτιστοποίησης και Εξαγωγής Αποτελεσμάτων (**Output Parsing**)

Λόγω της συσσωρευτικής φύσης της μνήμης της GPU κατά το **batch inference**, εφαρμόστηκαν τεχνικές επιθετικής διαχείρισης μνήμης. Μετά από κάθε πειραματικό κύκλο, γινόταν διαγραφή των αντικειμένων του μοντέλου και κλήση του **garbage collector** της Python, σε συνδυασμό με εκκαθάριση της προσωρινής μνήμης της CUDA.

Όσον αφορά την παραγωγή του κειμένου, επιλέχθηκε στρατηγικά η μέθοδος του **Greedy Decoding**. Η επιλογή αυτή εγγυάται τον απόλυτο ντετερμινισμό των απαντήσεων, ελαχιστο-

ποιώντας την πιθανότητα το μοντέλο να παρεκκλίνει σε άσχετη φλυαρία και **hallucinations**, προσπαθώντας να μαντέψει δημιουργικά το επόμενο **token**.

Επιπλέον, για τη διασφάλιση της συνοχής (**output consistency**) και την αξιόπιστη εξαγωγή της πρόβλεψης, υιοθετήθηκε η λογική του **Hidden Chain-of-Thought prompting**. Καθώς η ενθάρρυνση του εσωτερικού συλλογισμού παράγει μακροσκελή κείμενα που δυσκολεύουν την αυτοματοποιημένη αξιολόγηση, αναπτύχθηκε ένας ειδικός **regex-based parser (normalize_prediction)**. Αυτός ο μηχανισμός λειτουργούσε σε άμεση αρμονία με τους δομικούς περιορισμούς του **prompt**, σαρώνοντας την έξοδο του μοντέλου για να απομονώσει την έγκυρη τελική ετικέτα μέσα από τον παραγόμενο θόρυβο (π.χ. αναγνωρίζοντας μοτίβα όπως ‘1.Clear Reply’). Η προσέγγιση αυτή ήταν καθοριστική για τη δραστική μείωση του τελικού **Invalid Rate**.

3.5. Αξιολόγηση και Ανάλυση Πειραμάτων

Για την πλήρη κατανόηση της συμπεριφοράς των γλωσσικών μοντέλων, κρίνεται απαραίτητη η παράθεση του συνόλου των πειραματικών δοκιμών. Στον Πίνακα 2 παρουσιάστηκαν αναλυτικά οι μετρικές για όλους τους συνδυασμούς μεγέθους μοντέλου και στρατηγικής **prompting**. Το **Invalid Rate** καταδεικνύει το ποσοστό των περιπτώσεων όπου το μοντέλο απέτυχε να επιστρέψει μια έγκυρη ταμπέλα από την προκαθορισμένη ταξινόμια.

Η ανάλυση των αποτυχημένων πειραμάτων αποκαλύπτει εξαιρετικά ενδιαφέρουσες πτυχές της συμπεριφοράς των μοντέλων:

1. Η κατάρρευση του **Qwen-0.8B**: Το μικρότερο μοντέλο απέτυχε ολοκληρωτικά στο **Zero-Shot** και **Few-Shot** με **Invalid Rates** άνω του 94%. Σύμφωνα με την τεκμηρίωση της **Qwen**, τα πολύ μικρά **base** μοντέλα εγκλωβίζονται εύκολα σε *thinking loops* (ατέρμονους βρόγχους παραγωγής κειμένου) ή απλά αντιγράφουν το **prompt**, αδυνατώντας να επεξεργαστούν σύνθετες αρνητικές οδηγίες (π.χ. ‘**Output ONLY the exact label**’). Σώθηκε μερικώς μόνο στο **CoT**, καθώς η ελευθερία λόγου έσπασε τον βρόγχο επανάληψης.
2. Το Παράδοξο του **Few-Shot**: Σε όλα τα μοντέλα, το **Few-Shot** υποβάθμισε την απόδοση σε σχέση με το **Zero-Shot**. Στο 2B το **Macro F1** έπεσε από το 0.4320 στο 0.3009, ενώ στο 4B το **Invalid Rate** εκτοξεύτηκε στο 35.25%. Αυτό οφείλεται στο γεγονός ότι τα παραδείγματα επιμήκυναν δραματικά το **context window**. Τα **base** μοντέλα έχασαν την αρχική καθοδηγητική οδηγία μέσα στον μεγάλο όγκο κειμένου, επιβεβαιώνοντας τη βιβλιογραφία που θέλει τα **non-instruction-tuned** μοντέλα να αποσυντονίζονται από μακροσκελή **contexts**.
3. Το Χρονικό Κόστος του 4B **CoT** (421.13 λεπτά): Το πείραμα **Chain-of-Thought** στο 4B μοντέλο απαίτησε πάνω από 7 ώρες εκτέλεσης. Το επίσημο **model card** του **Qwen3.5-4B** επισημαίνει ότι το μοντέλο λειτουργεί εγγενώς σε ‘**thinking mode**’. Η χρήση της βασικής βιβλιοθήκης **transformers** χωρίς εξειδικευμένες **high-throughput** μηχανές συμπερασμού (όπως **vLLM** ή **SGLang**) σε συνδυασμό με το **4-bit quantization** οδήγησε σε ακραίο **throughput latency** (άνω των 60 δευτερολέπτων ανά δείγμα).

Βάσει των παραπάνω, το **Qwen3.5-2B** με στρατηγική **Zero-Shot** αναδεικνύεται ως η μοναδική αξιόπιστη επιλογή. Αν και το 4B (**Zero-Shot**) παρουσιάζει οριακά υψηλότερο **Accuracy** (0.5175), η συγκεκριμένη μετρική είναι παραπλανητική λόγω της ανισορροπίας των κλάσεων. Το 2B επιτυγχάνει την ιδανική ισορροπία, καταγράφοντας το υψηλότερο **Macro**

F1-Score (0.4320) με 0.00% **Invalid Rate**, αποδεικνύοντας ότι κατανόησε και εφάρμοσε τους δομικούς περιορισμούς χωρίς να απαιτεί **quantization**, το οποίο θα αλλοίωνε τις παραμέτρους του.

4. Αποτελέσματα και Συνολική Ανάλυση

4.1. Ανάλυση Αποτελεσμάτων


Η εις βάθος ανάλυση επικεντρώνεται στην οικογένεια μοντέλων **Qwen3.5-2B**, καθώς αποδείχθηκε η πλέον σταθερή, καταγράφοντας το μικρότερο ποσοστό αποτυχιών (**Invalid Rate**) σε σχέση με τις εκδόσεις των 0.8B και 4B.

Ειδικότερα για την έκδοση **Qwen3.5-0.8B**, η αστάθεια αυτή επιβεβαιώθηκε πλήρως κατά τη διάρκεια των πειραμάτων, καθώς όπως υποστηρίζει και η βιβλιογραφία, η εισαγωγή παραδειγμάτων στο **context** μπερδεψε το μικρό αυτό μοντέλο και το οδήγησε σε αδιέξοδη φλυαρία.

Παράλληλα, η αξιολόγηση της έκδοσης **Qwen3.5-4B** ανέδειξε σημαντικούς μηχανικούς περιορισμούς τόσο ως προς τον χρόνο συμπερασμού (**inference time**) όσο και ως προς τη διαχείριση της μνήμης. Ειδικότερα κατά την εκτέλεση της στρατηγικής **Chain-of-Thought (CoT)**, η υλοποίησή μας, η οποία βασίστηκε στη βιβλιοθήκη **transformers** του **Hugging Face**, επιβεβαίωσε ότι παραγωγικά περιβάλλοντα (**production workloads**) απαιτούνται εξειδικευμένες μηχανές βελτιστοποίησης, δικαιολογώντας έτσι πλήρως τη δυσανάλογη χρονική καθυστέρηση που παρατηρήθηκε στο **Kaggle**.

Επιπλέον, εξίσου απαιτητική ήταν η προσπάθεια ισορροπίας μεταξύ των δομικών απαιτήσεων του 4B και των περιορισμών των **T4 GPUs**. Ενώ η δημιουργός εταιρεία προτείνει τη διατήρηση ενός παραθύρου πλαισίου (**context length**) **128K tokens** και μέγιστου μήκους παραγωγής **32K tokens** για τη βέλτιστη απόδοση, η εφαρμογή τους θα οδηγούσε άμεσα σε σφάλματα **Out-of-Memory (OOM)**. Αυτές οι αναγκαστικές περικοπές στο μέγεθος του **context** εξηγούν την πτώση της απόδοσης του 4B στο **Few-Shot prompting** (από 27% σε 21%), καθώς το μοντέλο στερήθηκε τον απαραίτητο «χώρο» για να αναπτύξει τον συλλογισμό του. Ως αποτέλεσμα, προσπαθώντας να διαχειριστεί τα παραδείγματα στον περιορισμένο χώρο, έχασε την αρχική οδηγία ταξινόμησης (**classification task**) και παρήγαγε άκυρο κείμενο, εκτινάσσοντας το **Invalid Rate** στο 35%.


Η οπτικοποίηση αυτών των αστοχιών παρατίθεται στο Σχήμα 2, όπου επιβεβαιώνεται η δομική αδυναμία των 0.8B και 4B στις απαιτητικές στρατηγικές προσέγγισης.



Σχήμα 2: Ποσοστό Άκυρων Προβλέψεων (Invalid Output Rate %) ανά μέγεθος μοντέλου και στρατηγική Prompting.

Στο διάγραμμα αυτό καθίσταται σαφές το μέγεθος του προβλήματος για την έκδοση 0.8B, η οποία καταγράφει σχεδόν 100% αποτυχία. Αντίστοιχα, το **Few-Shot prompting** (μπορντό στήλη) αναδεικνύεται ως η πιο ασταθής στρατηγική συνολικά, «σπάζοντας» το **context window** ακόμα και στα μεγαλύτερα μοντέλα, με ποσοστά αποτυχίας 23% στο 2B και 35% στο 4B.

Έχοντας πλέον απομονώσει τον θόρυβο των αποτυχημένων απαντήσεων, η αξιολόγηση της πραγματικής ικανότητας ταξινόμησης των μοντέλων αποτυπώνεται στο συγκεντρωτικό γράφημα **Macro F1-Score** (Σχήμα 3).



Σχήμα 3: Συγκριτικό Macro F1-Score ανά μέγεθος μοντέλου (0.8B, 2B, 4B) και στρατηγική Prompting.

Όπως παρατηρούμε, η υπεροχή της έκδοσης Qwen3.5-2B είναι αδιαμφισβήτητη, καταγράφοντας την κορυφαία επίδοση (Macro F1 ≈ 0.44) υπό τη στρατηγική Zero-Shot. Αντίθετα, η κατάρρευση του 0.8B είναι προφανής, ενώ το 4B παρουσιάζει μέτρια συμπεριφορά, υποδεικνύοντας ότι οι μηχανικοί περιορισμοί δεν του επέτρεψαν να αξιοποιήσει το μέγεθός του.

Μια εξίσου σημαντική διάσταση της ανάλυσης αναδεικνύεται από τη σύγκριση της αυστηρής μετρικής Macro F1 με τη συνολική Ορθότητα (Accuracy) των μοντέλων (Σχήμα 4).




Σχήμα 4: Συνολική Ορθότητα (Accuracy) ανά μέγεθος μοντέλου και στρατηγική Prompting.

Σε αντίθεση με την εικόνα του Macro F1, όπου το Qwen3.5-2B κυριαρχεί καθαρά, στο γράφημα της Ορθότητας παρατηρούμε ότι το 4B υπό τη στρατηγική **Zero-Shot** φαίνεται να καταγράφει το υψηλότερο συνολικό ποσοστό (άνω του 50%). Το φαινόμενο αυτό αποτελεί μια στατιστική παγίδα σε προβλήματα ταξινόμησης με μη ισορροπημένα δεδομένα (**imbalanced datasets**). Ειδικότερα, το 4B επιτυγχάνει υψηλό Accuracy τεχνητά, επειδή τείνει να υπερ-προβλέπει τις πλειοψηφικές κλάσεις (**Ambivalent**, **Clear Reply**), αποτυγχάνοντας πρακτικά να αναγνωρίσει την πιο σπάνια και απαιτητική κλάση (**Clear Non-Reply**). Αυτή η αντιφατική εικόνα επιβεβαιώνει την αρχική μας μεθοδολογική απόφαση να βασιστούμε στο Macro F1-Score ως τον πλέον αξιόπιστο και αμερόληπτο δείκτη αξιολόγησης, επισφραγίζοντας το 2B (Zero-Shot) ως το πραγματικά βέλτιστο και πιο ισορροπημένο μοντέλο της μελέτης.

Ως εκ τούτου, εξετάζοντας πλέον την απόδοση του σταθερού Qwen3.5-2B στις επιμέρους κλάσεις (**Subgroup Analysis**), παρατηρούμε σημαντικές διακυμάνσεις ανάλογα με τη στρατηγική Prompting.

Όπως αποτυπώνεται στο Σχήμα 5, η ανάλυση του F1-Score ανά κλάση αναδεικνύει ξεκάθαρα τη στρατηγική **Zero-Shot** ως την πιο ισορροπημένη προσέγγιση. Συγκεκριμένα, το Zero-Shot επιτυγχάνει την υψηλότερη απόδοση στις δύο κυρίαρχες κλάσεις του συνόλου δεδομένων (dataset), δηλαδή στις κατηγορίες **Ambivalent** και **Clear Reply**.



Σχήμα 5: F1-Score ανά κλάση για το μοντέλο **Qwen-2B** υπό διαφορετικές στρατηγικές Prompting.

Αναλύοντας περαιτέρω τα παραπάνω ευρήματα, παρατηρούμε ότι στον αντίποδα η στρατηγική **Chain-of-Thought (CoT)**, παρότι διατηρεί ικανοποιητικά αποτελέσματα στις κυρίαρχες κλάσεις, καταρρέει δραματικά στην αναγνώριση της κατηγορίας **Clear Non-Reply**, με τη μετρική να βυθίζεται μόλις στο 0.12. Το στοιχείο αυτό είναι εξαιρετικά ενδιαφέρον, καθώς υποδηλώνει ότι το μοντέλο, μέσω της διαδικασίας υπερανάλυσης (*overthinking*), τείνει να «δικαιολογεί» τον πολιτικό λόγο. Από την άλλη πλευρά, η στρατηγική **Few-Shot** αποτελεί τη μοναδική μέθοδο που ενισχύει ελαφρώς την ανίχνευση του **Clear Non-Reply**. Ωστόσο, το πράττει θυσιάζοντας σημαντικό ποσοστό ευστοχίας από τις υπόλοιπες κλάσεις, γεγονός που αποδίδεται στη δυσκολία των **Base** μοντέλων να διαχειριστούν εκτεταμένα **context windows**. Συμπερασματικά, η επιλογή του **Zero-Shot** ως της τελικής βέλτιστης δοκιμής είναι πλήρως δικαιολογημένη, καθώς προσφέρει το ιδανικό **trade-off**, μεγιστοποιώντας το συνολικό **Macro F1** χωρίς να υστερεί χαρακτηριστικά σε καμία επιμέρους κατηγορία.

Επιπλέον, μια συμπληρωματική αλλά εξαιρετικά κρίσιμη διάσταση της αξιολόγησης αφορά την απόδοση των μοντέλων σε διαφορετικές υποομάδες δεδομένων με βάση όμως το μήκος του κειμένου (αριθμός λέξεων ερώτησης και απάντησης).

Παρατηρήθηκε ότι σε σύντομες και άμεσες ερωτοαπαντήσεις, όλα τα μοντέλα (ακόμη και το 0.8B) εμφάνισαν υψηλά ποσοστά σύγκλισης με τις πραγματικές ετικέτες. Ωστόσο, η απόδοση διαφοροποιήθηκε έντονα όσο αυξανόταν το μήκος της απάντησης του πολιτικού:

- Μοντέλο 0.8B: Το μεγάλο μήκος κειμένου προκάλεσε γνωστική υπερφόρτωση, οδηγώντας το σε ατέρμονους βρόγχους επανάληψης.
- Μοντέλο 4B: Λόγω των περιορισμών μνήμης της T4 GPU, οι μακροσκελείς απαντήσεις οδήγησαν σε βίαιη περικοπή του πλαισίου (**context truncation**), καταστρέφοντας τη δομή της οδηγίας.
- Μοντέλο 2B: Αποδείχθηκε το πιο ανθεκτικό σε μακροσκελή κείμενα, αν και κατέγραψε

μια μικρή πτώση στο **Macro F1-Score**, καθώς ο φλύαρος πολιτικός λόγος έτεινε να περιπλέκει και, εν τέλει, να μπερδεύει την κατάσταση.

4.1.1. Βέλτιστη δοκιμή.


Βάσει των παραπάνω, ως βέλτιστη δοκιμή αναδεικνύεται ξεκάθαρα το **Qwen3.5-2B** με στρατηγική **Zero-Shot**. Η επιλογή αυτή τεκμηριώνεται από τους εξής άξονες:

1. Ισορροπία **F1-Scores**: Πέτυχε τα υψηλότερα σκορ στις πιο κρίσιμες κλάσεις (**Ambivalent**: 0.45, **Clear Reply**: 0.53) διατηρώντας το **Clear Non-Reply** σε αξιοπρεπή επίπεδα (0.31) συγκριτικά με τον ανταγωνισμό.
2. Μηδενικό **Invalid Rate**: Παρήγαγε ακριβώς τη ζητούμενη ετικέτα στο 100% των περιπτώσεων, αποδεικνύοντας ότι το σύστημα κανόνων στο **prompt** ήταν απολύτως κατανοητό χωρίς να απαιτείται η φλυαρία του **CoT** ή ο θόρυβος του **Few-Shot**.
3. Υπολογιστική Αποδοτικότητα: Ως **Zero-Shot**, κατανάλωσε τα λιγότερα **tokens**, επιτρέποντας ταχύτατο **inference**, στοιχείο κρίσιμο για εφαρμογές πραγματικού χρόνου με περιορισμένους πόρους υλικού.

Παράμετρος / Μετρική	Βέλτιστη Διαμόρφωση / Επίδοση
Επιλεγμένο Μοντέλο	Qwen3.5-2B (Χωρίς Quantization, bfloat16)
Στρατηγική Προμπτινγκ	Zero-Shot
Μέθοδος Αποκωδικοποίησης	Greedy Decoding (do_sample=False)
Εξαγωγή Αποτελέσματος	Hidden CoT συνδυασμένο με Regex Parser
Macro F1-Score	≈ 0.44 (Κορυφαία ισορροπία κλάσεων)
Invalid Output Rate	Μηδενικό (Μέγιστη σταθερότητα απαντήσεων)

Πίνακας 3: Συνοπτικός πίνακας παραμέτρων και μετρικών της βέλτιστης δοκιμής.

4.1.2. Πίνακας Σύγχυσης. Για την περαιτέρω κατανόηση της συμπεριφοράς της βέλτιστης δοκιμής, παρατίθεται ο Πίνακας Σύγχυσης (**Confusion Matrix**), ο οποίος εστιάζει στις περιπτώσεις όπου το μοντέλο έκανε λάθος πρόβλεψη.



Σχήμα 6: Πίνακας Σύγχυσης (Confusion Matrix) για τη βέλτιστη στρατηγική Zero-Shot του μοντέλου Qwen-2B.

Αναλύοντας τα δομικά σφάλματα του συστήματος (Σχήμα 6), καθίσταται εμφανές ότι η κύρια αδυναμία του εντοπίζεται στην έντονη υπερ-πρόβλεψη (**over-prediction**) της κλάσης **Clear Reply**. Ειδικότερα, το μοντέλο ταξινομήσε εσφαλμένα 144 δείγματα ως **Clear Reply** ενώ στην πραγματικότητα ανήκαν στην κατηγορία **Ambivalent**. Αυτό το εξαιρετικά υψηλό ποσοστό σφάλματος υποδηλώνει ότι το **Base** μοντέλο συχνά παραπλανάται από την απλή συνύπαρξη λέξεων-κλειδιών στην απάντηση του πολιτικού, αδυνατώντας να συλλάβει τη βαθύτερη διπλωματικότητα ή ασάφεια των λεγομένων του, θεωρώντας τα ως μια άμεση και ξεκάθαρη τοποθέτηση.

Παράλληλα, η κλάση **Clear Non-Reply** αναδεικνύεται ως η πιο απαιτητική στην αναγνώρισή της, καταγράφοντας μόλις 10 σωστές προβλέψεις. Το μοντέλο δυσκολεύεται να εντοπίσει την απόλυτη άρνηση, τείνοντας να την κατατάσσει λανθασμένα στην πιο ήπια, ενδιάμεση κατηγορία **Ambivalent** (26 δείγματα). Παρά τις παραπάνω αστοχίες, το μοντέλο διατηρεί μια ικανοποιητική ικανότητα στον εντοπισμό των πραγματικά καθαρών απαντήσεων, πετυχαίνοντας 98 σωστές ταξινομήσεις για την κλάση **Clear Reply** και 83 για την **Ambivalent**.

Προκειμένου να απομονωθεί και να ποσοτικοποιηθεί η τάση σφάλματος του συστήματος, κατασκευάστηκε ο Πίνακας Διασταύρωσης Λανθασμένων Προβλέψεων. Ο πίνακας αυτός (Πίνακας 4) εστιάζει αποκλειστικά στα 209 συνολικά δείγματα όπου το μοντέλο απέτυχε να ταυτιστεί με την πραγματική ετικέτα (**Gold Label**).

Παρατηρώντας τα αθροίσματα, προκύπτει ένα εντυπωσιακό εύρημα: από το σύνολο των

Πίνακας 4: Πίνακας Διασταύρωσης Λανθασμένων Προβλέψεων (Qwen-2B Zero-Shot)

Πραγματική Κλάση (Gold)	Ambivalent	Clear Non-Reply	Clear Reply	Σύνολο
Ambivalent	-	10	144	154
Clear Non-Reply	26	-	5	31
Clear Reply	21	3	-	24
Σύνολο Προβλέψεων	47	13	149	209

209 λανθασμένων ταξινομήσεων, οι 154 (ποσοστό περίπου 74%) προέρχονται αποκλειστικά από την κλάση **Ambivalent**. Το γεγονός ότι σχεδόν όλα αυτά τα σφάλματα (144) κατέληξαν να ταξινομηθούν ως **Clear Reply** επιβεβαιώνει την ισχυρή προκατάληψη (bias) του Base μοντέλου. Σε περιπτώσεις όπου το κείμενο στερείται μιας ρητής και επιθετικής άρνησης, το μοντέλο αδυνατεί να αποκωδικοποιήσει τη διπλωματική στάση ή την υπεκφυγή του ομιλητή, εκλαμβάνοντας την πολυπλοκότητα της απάντησης ως θετική επιβεβαίωση. Αντίθετα, όταν το μοντέλο καλείται να ταξινομήσει πραγματικά ξεκάθαρες απαντήσεις (**Clear Reply**), τα ποσοστά σφάλματος είναι δραματικά μικρότερα (μόλις 24 λάθη στο σύνολο), αποδεικνύοντας ότι η κύρια πηγή θορύβου στις προβλέψεις είναι η γλωσσική αμφισημία.

4.2. Ανάλυση Σφαλμάτων και Συγκριτική Αξιολόγηση

Για την ακριβή αποτύπωση των μετρικών και την πλήρη διαφάνεια της αξιολόγησης, παρατίθεται παρακάτω η αυτούσια έξοδος της ανάλυσης σφαλμάτων που πραγματοποιήθηκε, το οποίο καταγράφει αναλυτικά τις συχνότητες κάθε εσφαλμένης μετάβασης για τη βέλτιστη δοκιμή. Εκδοχή αυτής παρουσιάστηκε στον παραπάνω πίνακα, ωστόσο θεωρείται θεμιτό να παρουσιαστεί και αυτούσια, συνοδευόμενη από τα αντίστοιχα ποσοστά.

Error Analysis

- Συνολικά δείγματα: 400
- Συνολικά λάθη μοντέλου: 209
- Ποσοστό Λαθών: 52.25%

Οι πιο συχνοί λόγοι μπερδέματος:

- True: 'Ambivalent' Predicted: 'Clear Reply' | 144 φορές (68.9% των λαθών)
- True: 'Clear Non-Reply' Predicted: 'Ambivalent' | 26 φορές (12.4% των λαθών)
- True: 'Clear Reply' Predicted: 'Ambivalent' | 21 φορές (10.0% των λαθών)
- True: 'Ambivalent' Predicted: 'Clear Non-Reply' | 10 φορές (4.8% των λαθών)
- True: 'Clear Non-Reply' Predicted: 'Clear Reply' | 5 φορές (2.4% των λαθών)
- True: 'Clear Reply' Predicted: 'Clear Non-Reply' | 3 φορές (1.4% των λαθών)

Όπως προκύπτει από τα παραπάνω δεδομένα και τον Πίνακα 4, τα σφάλματα του μοντέλου δεν είναι τυχαία. Αντιπαραβάλλοντας αυτά τα ευρήματα με την ενδελεχή μελέτη των λανθασμένων προβλέψεων της 2ης εργασίας (DeBERTa-v3, BERT, DistilBERT), προκύπτουν κρίσιμα συμπεράσματα για τις διαφορές μεταξύ παραγωγικών (Generative) και διαχωριστικών (Discriminative) γλωσσικών μοντέλων:

- **Generative "Αφέλεια" έναντι Discriminative "Καχυποψίας":** Η συντριπτική πλειοψηφία των λαθών του Qwen (144 φορές, το 68.9% των συνολικών λαθών) αφορά δείγματα που ήταν *Ambivalent*, αλλά προβλέφθηκαν ως *Clear Reply*. Το μοντέλο, εκπαιδευμένο να λειτουργεί ως "χρήσιμος βοηθός", εμφανίζεται υπερβολικά επιεικές απέναντι στον πολιτικό λόγο: όταν ο πολιτικός απαντά με γενικολογίες, το μοντέλο τείνει να τις εκλαμβάνει ως έγκυρες απαντήσεις. Αντίθετα, στην προηγούμενη εργασία, τα *Fine-Tuned Encoders* εμφάνισαν ακριβώς το αντίστροφο μοτίβο. Έχοντας εκπαιδευτεί αυστηρά στον εντοπισμό υπεκφυγών, μοντέλα όπως το BERT έτειναν να "γέρνουν" προς την κλάση *Ambivalent* (με πιθανότητες Softmax 55-68%) ακόμα και όταν οι απαντήσεις ήταν απολύτως ξεκάθαρες.
- **Χειρισμός Μακροσκελών Απαντήσεων και Attention Span:** Στη 2η εργασία διαπιστώθηκε ότι τα μοντέλα μικρής χωρητικότητας έχαναν το αρχικό καθαρό σήμα μιας απάντησης λόγω περιορισμένου παραθύρου προσοχής, καταλήγοντας συχνά στην ασφαλή επιλογή της αμφισημίας. Το Qwen, χάρη στο πολύ μεγαλύτερο *context window*, δεν πάσχει από αυτόν τον περιορισμό μνήμης. Παρόλα αυτά, η αποτυχία του να αναγνωρίσει την απόλυτη άρνηση (*Clear Non-Reply* ταξινομημένο ως *Ambivalent* στο 12.4% των λαθών) δείχνει ότι, ενώ "βλέπει" όλο το κείμενο, η *Base* μορφή του δυσκολεύεται να αξιολογήσει το πραγματολογικό βάρος μιας άρνησης σε σχέση με την πιθανή ευγένεια που ίσως να την περιβάλλει.
- **Η Απουσία Διαφάνειας (Softmax vs Greedy Decoding):** Μια σημαντική διαφορά στην ανάλυση σφαλμάτων έγκειται στην ερμηνευσιμότητα. Στα *Encoders*, η εξέταση των πιθανοτήτων Softmax είχε αποκαλύψει οριακές αποφάσεις (50-50), αποδεικνύοντας ότι το δίκτυο κατανοούσε τη ρευστότητα των διαχωριστικών ορίων. Στην παρούσα προσέγγιση με το Qwen, η χρήση *greedy decoding* (*do_sample=False*) εξαναγκάζει το μοντέλο σε επιλογή του επόμενου *token*. Έτσι, τα λάθη μοιάζουν πιο συστηματικά και λιγότερο ανασφαλής, αποκρύπτοντας την ενδεχόμενη εσωτερική του αμφιταλάντευση.
- **Ευπάθεια σε Παραπλανητικές Εισαγωγές:** Όπως το DistilBERT παραπλανιόταν από λέξεις άρνησης ή κατάφασης στην αρχή της πρότασης, έτσι και το *Base Qwen*, προσπαθώντας να συμπληρώσει το κείμενο, τείνει να δημιουργεί ένα ισχυρό *bias* βασισμένο στις πρώτες λέξεις του πολιτικού, παραβλέποντας συχνά τη μακροσκελή υπεκφυγή που ακολουθεί.

Συμπερασματικά, ενώ τα *Discriminative* μοντέλα χτίζουν αυστηρά και καχύποπτα όρια αποφάσεων, τα *Generative Base* μοντέλα στερούνται της απαραίτητης ταξινομικής αυστηρότητας, αναδεικνύοντας την ανάγκη για *Instruction-Tuning* όταν εφαρμόζονται σε αντίστοιχα προβλήματα.

4.3. Ιδανικό Αρχιτεκτονικό Σύστημα

Τα μοντέλα που καθοδηγούνται αποκλειστικά από *prompts* αδυνατούν να κατανοήσουν τα τεχνάσματα που συνήθως διέπουν τον πολιτικό λόγο, καθώς αδυνατούν να σταματήσουν να διαβάζουν το κείμενο με απόλυτη κυριολεξία. Έτσι, αν ένας πολιτικός απαντήσει με πολλά «*filler words*» ή γενικολογίες, το *Base* μοντέλο θεωρεί σημασιολογικά ότι, για να έχει έκταση ο λόγος του, τότε μάλλον κάτι απαντήθηκε.

Ένα ιδανικό σύστημα συλλογιστικής για την επίλυση αυτού του προβλήματος θα έπρεπε να διαθέτει μια αρχιτεκτονική δύο σταδίων:

1. **Discourse Parser (Συντακτικό Διαλόγου):** Ένα εξειδικευμένο υποσύστημα που θα χαρτογραφεί τη δομή της συνομιλίας, αναγνωρίζοντας στρατηγικές υπεκφυγής (π.χ. *attack-the-interviewer*, *agenda-shifting*).
2. **Constraint-Guided Neuro-Symbolic LLM:** Ένα μοντέλο που δεν θα κρίνει με βάση της σημασιολογικής ομοιότητας των λέξεων, αλλά θα εφαρμόζει κριτική σκέψη για το αν η απάντηση ικανοποιεί τις συνθήκες της ερώτησης, απομονώνοντας πλήρως τον διπλωματικό θόρυβο.

5. Προτάσεις για Μελλοντική Έρευνα

Η παρούσα μελέτη ανέδειξε τόσο τις δυνατότητες όσο και τους εγγενείς περιορισμούς των *base* γλωσσικών μοντέλων στην ανάλυση πολιτικού λόγου. Για τη βελτίωση της απόδοσης σε μελλοντικές εργασίες, προτείνονται οι εξής κατευθύνσεις:

1. **Instruction-Tuning (SFT) / LoRA:** Αντί για βασικό *prompting*, η εφαρμογή *Parameter-Efficient Fine-Tuning* (όπως το LoRA) πάνω σε *Instruct* εκδόσεις των μοντέλων θα μπορούσε να προσαρμόσει τα βάρη του δικτύου ώστε να αντιλαμβάνεται ειδικά την πολιτική υπεκφυγή, λύνοντας το πρόβλημα της "επιείκειας" που καταγράφηκε στην ανάλυση σφαλμάτων.
2. **Dynamic Few-Shot Prompting** μέσω **RAG:** Αντί για τη χρήση ενός στατικού μηχανισμού δειγματοληψίας (*static few-shot sampler*), μπορεί να αναπτυχθεί ένα σύστημα **Retrieval-Augmented Generation (RAG)**. Με τη χρήση διανυσματικών αναπαραστάσεων (*embeddings*), το σύστημα θα ανακτά τα k το πλήθος πιο σημασιολογικά όμοια παραδείγματα από το *Training Set* για κάθε νέα ερώτηση, παρέχοντας στο μοντέλο πολύ πιο σχετικό *context*.
3. **Ensemble Learning** με **Encoder** Μοντέλα: Ο συνδυασμός της αναλυτικής ικανότητας ενός LLM με την ισχυρή ικανότητα ταξινόμησης ενός **Fine-Tuned Encoder** θα μπορούσε να μετριάσει τα αδύνατα σημεία και των δύο αρχιτεκτονικών, προσφέροντας πιο **robust** αποτελέσματα στις δύσκολες κλάσεις.

6. Βιβλιογραφία

- [1] Διαφάνειες Διαλέξεων - Artificial Intelligence 2: Deep Learning for Natural Language Processing, 2026. Εαρινό Εξάμηνο 2025-2026, SemEval 2026 Task 6.
- [2] DAIR.AI. Prompt Engineering Guide. <https://www.promptingguide.ai/>, 2024. Featured techniques: Zero-shot, Few-shot, Chain-of-Thought.
- [3] Qwen Team. Qwen3.5-0.8B-Instruct Model Card. <https://huggingface.co/Qwen/Qwen3.5-0.8B>, 2025. Accessed: 2026.
- [4] Qwen Team. Qwen3.5-2B-Instruct Model Card. <https://huggingface.co/Qwen/Qwen3.5-2B>, 2025. Accessed: 2026.
- [5] Qwen Team. Qwen3.5-4B-Instruct Model Card. <https://huggingface.co/Qwen/Qwen3.5-4B>, 2025. Accessed: 2026.
- [6] Jurafsky, Daniel and Martin, James H. Speech and Language Processing (3rd ed. draft). <https://web.stanford.edu/~jurafsky/slp3/>, 2024. Chapters 4–5 and 7.
- [7] Paszke, Adam and others. PyTorch: An Imperative Style, High-Performance Deep Learning Library. In *Advances in Neural Information Processing Systems* 32, 2019.
- [8] Pedregosa, F. and Varoquaux, G. and Gramfort, A. and Michel, V. and Thirion, B. and Grisel, O. and Blondel, M. and Prettenhofer, P. and Weiss, R. and Dubourg, V. and Vanderplas, J. and Passos, A. and Cournapeau, D. and Brucher, M. and Perrot, M. and Duchesnay, E. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [9] Wei, Jason and Wang, Xuezhi and Schuurmans, Dale and Bosma, Maarten and Ichter, Brian and Xia, Fei and Chi, Ed and Le, Quoc V and Zhou, Denny. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. *Advances in Neural Information Processing Systems*, 35:24824–24837, 2022.
- [10] Wolf, Thomas and others. Transformers: State-of-the-Art Natural Language Processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 2020.
- [11] Wes McKinney. Data Structures for Statistical Computing in Python. In Stéfan van der Walt and Jarrod Millman, editor, *Proceedings of the 9th Python in Science Conference*, pages 56 – 61, 2010.

7. Παραρτήματα - Πρόσθετες Θεωρήσεις

Παράρτημα A: Ανάλυση της υποαπόδοσης της στρατηγικής Few-Shot

Στη σύγχρονη βιβλιογραφία των Μεγάλων Γλωσσικών Μοντέλων (LLMs), η στρατηγική **Few-Shot prompting** θεωρείται παραδοσιακά ως ένας αποτελεσματικός τρόπος ενίσχυσης της απόδοσης, ειδικά για μικρότερα μοντέλα. Η παροχή παραδειγμάτων (**in-context learning**) βοηθά συνήθως το μοντέλο να κατανοήσει τη ζητούμενη δομή και το ύφος της εξόδου. Ωστόσο, κατά τη διάρκεια της παρούσας μελέτης, παρατηρήθηκε ένα φαινομενικό παράδοξο: η προσέγγιση **Few-Shot** κατακρήμνισε την απόδοση, καταγράφοντας τα υψηλότερα ποσοστά άκυρων προβλέψεων (**Invalid Rate**) σε σχέση με τη **Zero-Shot**.

Αυτή η απόκλιση από τη θεωρία αποδίδεται σε δύο βασικούς περιορισμούς που σχετίζονται με το μέγεθος του παραθύρου πλαισίου (**context window**):

- **Υπερφόρτωση Μνήμης και Περικοπή (Truncation)** στο 4B: Η εισαγωγή εκτενών παραδειγμάτων αύξησε δραματικά τον αριθμό των **tokens** εισόδου. Για το μοντέλο **Qwen3.5-4B**, αυτό οδήγησε άμεσα σε σφάλματα **Out-of-Memory (OOM)** στις διαθέσιμες **T4 GPUs**. Για να καταστεί δυνατή η εκτέλεση, απαιτήθηκε αυστηρή περικοπή του **context**. Συνεπώς, το μοντέλο έχασε κρίσιμα μέρη των παραδειγμάτων ή και της αρχικής οδηγίας, με αποτέλεσμα να παράγει άκυρες απαντήσεις αδυνατώντας να ολοκληρώσει με επιτυχία την ταξινόμηση.
- **Γνωστική Υπερφόρτωση και Thinking Loops** στο 0.8B: Από την άλλη πλευρά, το μικρότερο μοντέλο της σειράς (0.8B) δεν διέθετε την απαραίτητη αρχιτεκτονική χωρητικότητα για να επεξεργαστεί τον μεγάλο όγκο πληροφορίας των παραδειγμάτων. Αντί να διδαχθεί από αυτά, «μπερδεύτηκε», χάνοντας τον ειρμό της αρχικής εντολής και εγκλωβιζόμενο σε ατέρμονους βρόγχους παραγωγής ασυναρτησιών (**thinking loops**).

Συμπερασματικά, η στρατηγική **Few-Shot** σε απαιτητικά **tasks** (όπως η ανάλυση πολιτικού λόγου) απαιτεί ισχυρούς υπολογιστικούς πόρους που να υποστηρίζουν μεγάλα **context windows**, καθώς και μοντέλα ικανά να επεξεργαστούν εκτενή **prompts** χωρίς να καταρρέει η προσοχή τους (**attention mechanisms**).