

Deep Learning for NLP

Όνομα Φοιτητή: **Αγάπη Καλλίνικου**

AM: **sma2200210**

Μάθημα: Τεχνητή Νοημοσύνη II (YS19 M226 M262 M325 M405)

Εξάμηνο: Εαρινό Εξάμηνο 2025-2026

Περιεχόμενα

1	Περίληψη	3
2	Σύνδεσμοι Κώδικα (Kaggle Notebooks)	4
3	Επεξεργασία και Ανάλυση Δεδομένων	4
3.1	Προεπεξεργασία	4
3.2	Ανάλυση	5
3.3	Διαχωρισμός Δεδομένων	6
3.4	Tokenization & Few-Shot	7
4	Αλγόριθμοι και Πειραματική Διαδικασία	7
4.1	Σχεδιασμός Προτροπών (Prompt Design) και Αρχιτεκτονική Πρακτόρων . .	7
4.2	Πειραματικός Σχεδιασμός	9
4.2.1	Πειράματα Βελτιστοποίησης μέσω DSPy	9
4.3	Inference Settings και Περιορισμοί	10
4.4	Τεχνικές Βελτιστοποίησης και Εξαγωγής Αποτελεσμάτων	11
4.5	Αξιολόγηση και Ανάλυση Πειραμάτων	11
4.5.1	Συγκριτικά Αποτελέσματα	11
4.5.2	Ανάλυση Ανά Κλάση	12
4.5.3	Ανάλυση Συμπεριφοράς και Σφαλμάτων	12
5	Αποτελέσματα βέλτιστης δοκιμής	14
5.0.1	Ανάλυση Υποομάδων (Subgroup Analysis):	16
5.1	Παράδειγμα Αστοχίας (Case Study): Μερική κάλυψη πολλαπλού ερωτήματος	18
5.2	Σύγκριση με προηγούμενες αρχιτεκτονικές	18
5.2.1	1. Οι Τέσσερις Μεθοδολογικές Προσεγγίσεις	18
5.2.2	2. Συγκριτική Ανάλυση Σφαλμάτων & Συμπεράσματα	19
6	Προτάσεις για Μελλοντική Έρευνα	23
7	Βιβλιογραφία	24

8	Παραρτήματα - Πρόσθετες Θεωρήσεις	25
8.1	Παράρτημα Α: Διαχείριση Υπολογιστικών Περιορισμών και Σιωπηλών Σφαλμάτων κατά τη Βελτιστοποίηση DSPy	25
8.2	Παράρτημα Β: Prompts που χρησιμοποιήθηκαν στο D3-Agentic Prompting	25
8.2.1	B.1 Question Intent Agent Prompt	25
8.2.2	B.2 Answer Content Agent Prompt	26
8.2.3	B.3 Gap and Evasion Agent Prompt	27
8.2.4	B.4 Decision Agent Prompt	28
8.3	Παράρτημα Γ: Ενδεικτική Παραγωγή Ενδιάμεσων Αποτελεσμάτων (JSON) . .	30

1. Περίληψη

Η παρούσα εργασία παρουσιάζει μια ολοκληρωμένη μελέτη πάνω στην ταξινόμηση της σαφήνειας των απαντήσεων στον πολιτικό λόγο, αξιοποιώντας το σύνολο δεδομένων CLARITY. Για την αντιμετώπιση των λεπτών αποχρώσεων της πολιτικής υπεκφυγής, αναπτύχθηκε το **D3-Agentic Prompting**, ένα ελαφρύ πολυ-πρακτορικό (**multi-agent**) σύστημα βασισμένο στο **instruction-tuned** γλωσσικό μοντέλο **Qwen3.5-0.8B**. Αντί για την κλασική εκπαίδευση βαρών (**fine-tuning**), η διαδικασία συλλογισμού διασπάστηκε σε τέσσερις εξειδικευμένους πράκτορες (**Question Intent**, **Answer Content**, **Gap and Evasion**, **Decision Agent**), οι οποίοι επικοινωνούν αυστηρά μέσω δομημένων εξόδων **JSON**. Για τη διασφάλιση της ομαλής εκτέλεσης υπό αυστηρούς υπολογιστικούς περιορισμούς (**hardware constraints**), εφαρμόστηκαν στοχευμένες τεχνικές διαχείρισης πόρων και **static few-shot prompting**. Η προτεινόμενη αρχιτεκτονική συγκρίθηκε συστηματικά με τεχνικές αυτόματης βελτιστοποίησης προτροπών (**DSpy**), μελέτες αφαίρεσης (**ablation**), καθώς και με τα μοντέλα αναφοράς προηγούμενων εργασιών (**vector-based classifiers** και **encoder-only** μοντέλα). Ως βέλτιστη μέθοδος αναδείχθηκε η **Baseline/Manual D3** αρχιτεκτονική, επιτυγχάνοντας **Macro F1-score** 0.51 στο σύνολο επικύρωσης και 0.56 στο κρυφό **Test Set**. Η μελέτη **ablation** επιβεβαίωσε τον κρίσιμο ρόλο του **Gap and Evasion Agent**, η αφαίρεση του οποίου προκάλεσε πτώση του **F1-score** στο 0.43. Επιπλέον, η ανάλυση υποομάδων ανέδειξε ότι το μοντέλο αποδίδει αισθητά καλύτερα σε μικρότερες ερωτήσεις (54.96% **Macro F1**). Τέλος, η ενδελεχής ανάλυση σφαλμάτων αποκάλυψε τους εγγενείς περιορισμούς των μικρών γλωσσικών μοντέλων: υπερβολική βεβαιότητα σε λανθασμένες προβλέψεις (**overconfidence**), έντονη κλίση προς την κλάση **Ambivalent**, και συστηματική αποτυχία αναγνώρισης των καθαρών υπεκφυγών (**Clear Non-Reply**). Τα συμπεράσματα αυτά αναδεικνύουν την αξία της λογικής αποσύνθεσης στο **prompting**, καταγράφοντας παράλληλα τις δυσκολίες κατανόησης του πολύπλοκου πολιτικού λόγου.

2. Σύνδεσμοι Κώδικα (Kaggle Notebooks)

Ο κώδικας για την ανάπτυξη και την αξιολόγηση των μοντέλων είναι διαθέσιμος στον παρακάτω σύνδεσμο:

- **Implementation:** <https://www.kaggle.com/code/agapikallinikou/sma2200210-homework-4-d3-agentic>

3. Επεξεργασία και Ανάλυση Δεδομένων

3.1. Προεπεξεργασία

Η διαδικασία προεπεξεργασίας των δεδομένων του **dataset** σχεδιάστηκε με γνώμονα τη διασφάλιση της ποιότητάς τους και την αποφυγή φαινομένων που αλλοιώνουν την αξιοπιστία της αξιολόγησης. Επιπλέον, καθώς η αρχιτεκτονική μας βασίζεται στο **instruction-tuned** γλωσσικό μοντέλο **Qwen3.5-0.8B** και σε ένα **Multi-Agent** σύστημα, η διατήρηση της φυσικής δομής της γλώσσας είναι απαραίτητη. Το μοντέλο χρειάζεται ακατέργαστη τη συντακτική δομή, τα σημεία στίξης, τα κεφαλαία γράμματα και το πλήρες περιβάλλον (**context**) του κειμένου προκειμένου να αξιολογήσει με ακρίβεια λεπτές γλωσσικές αποχρώσεις, όπως η πολιτική υπεκφυγή, η ειρωνεία ή η ασάφεια. Οποιαδήποτε επιπλέον αλλοίωση θα στερούσε από τους πράκτορες (**agents**) πολύτιμη σημασιολογική πληροφορία, μειώνοντας την ικανότητα συλλογισμού τους.

Με βάση τα παραπάνω, οι ενέργειες προεπεξεργασίας περιορίστηκαν στα ακόλουθα βήματα. Σημειώνεται ότι ορισμένοι βασικοί έλεγχοι (αφαίρεση διπλοτύπων, έλεγχος κενών εγγραφών και έλεγχος για διαρροή δεδομένων) είχαν ήδη εξασφαλιστεί στο **dataset** από προηγούμενες εργασίες, οπότε η τρέχουσα εστιάζει στα εξής:

- **Δυναμική Ανίχνευση Σχήματος:** Αναπτύχθηκε η συνάρτηση `find_column`, η οποία αναζητά δυναμικά τις απαραίτητες στήλες (`question`, `answer`, `label`, `id`) στο **DataFrame** χρησιμοποιώντας λίστες πιθανών εναλλακτικών ονομάτων με παράλληλη **case-insensitive** περιπτωσιολογία.
- **Καθαρισμός Κειμένου:** Πραγματοποιήθηκε αυτόματη διαχείριση ελλিপών τιμών με τη χρήση της `.fillna()` και αφαίρεση περιττών κενών διαστημάτων στις άκρες των κειμένων μέσω της `.str.strip()`, διασφαλίζοντας ότι οι πράκτορες δεν θα δεχθούν κενά ή προβληματικά **strings** ως είσοδο.
- **Κανονικοποίηση Ετικετών (Label Normalization):** Σχεδιάστηκε η συνάρτηση `normalize_label`, η οποία επιτελεί μια χαρτογράφηση (**mapping**) των στόχων στις τρεις κανονικές κλάσεις (*Clear Reply*, *Ambivalent*, *Clear Non-Reply*). Η συνάρτηση διαχειρίζεται αυτόματα:
 1. **Αριθμητικούς τύπους και Strings:** Μετατρέπει ετικέτες όπως 0, 1, 2 ή '0', '1', '2' στις αντίστοιχες κλάσεις.
 2. **Λεξικά Συνώνυμα και Aliases:** Χρησιμοποιεί το δομημένο λεξικό **LABEL_ALIASES** για να κατευθύνει όρους όπως 'evasion' ή 'no' στο *Clear Non-Reply*, και όρους όπως 'partial', 'unclear' ή 'neutral' στο *Ambivalent*.
 3. **Μορφοποίηση ατελειών:** Εφαρμόζει κανονικές εκφράσεις (**Regex**) για την αφαίρεση περιττών κενών και χαρακτήρων υπογράμμισης (`_`), ενώ διαχειρίζεται περιπτώσεις όπου το μοντέλο εισήγαγε τελική τελεία.

4. Μηχανισμός *Fallback* με Λέξεις-Κλειδιά: Αν μια ετικέτα δεν ταιριάζει απόλυτα, αναζητά διακριτικά λέξεων (π.χ. αν περιέχει ‘non’ και ‘reply’, αποδίδει αυτόματα την κλάση *Clear Non-Reply*).

ενώ από τις προηγούμενες εργασίες έχουμε:

- Αφαίρεση Διπλοτύπων: Πραγματοποιήθηκε έλεγχος και αφαίρεση διπλοτύπων καταχωρίσεων στο **Training Set** με βάση τον μοναδικό συνδυασμό της πολιτικής ερώτησης και της αντίστοιχης απάντησης.
- Κενές Εγγραφές (**Null Values**): Από την ανάλυση του **dataset** σε προηγούμενες εργασίες συμπεραίνουμε ότι δεν υπάρχουν κενές εγγραφές, οπότε στην παρούσα δεν πραγματοποιούμε αντίστοιχο έλεγχο.
- Έλεγχος Διαρροής Δεδομένων (**Data Leakage**): Υλοποιήθηκε έλεγχος προκειμένου να διαπιστωθεί αν δείγματα του **Train Set** συνυπάρχουν στο **Test Set**. Στην περίπτωση του **prompting**, η διαρροή δεδομένων μπορεί να οδηγήσει σε τεχνητή μνήμη αντί για πραγματική ικανότητα γενίκευσης βάσει του **context**.


3.2. Ανάλυση

Προκειμένου να κατανοηθεί σε βάθος η δομή και οι ιδιαιτερότητες του συνόλου δεδομένων, η διαδικασία της προεπεξεργασίας πραγματοποιήθηκε στηριζόμενη στα συμπεράσματα που αποκτήθηκαν μέσω της Εξερευνητικής Ανάλυσης Δεδομένων (**Exploratory Data Analysis - EDA**) που πραγματοποιήθηκε στην πρώτη εργασία. Αξίζει να σημειωθεί ότι η ανάλυση της κατανομής των κλάσεων και του μήκους των κειμένων είχε πραγματοποιηθεί στα αρχικά, ακατέργαστα δεδομένα. Αυτό κρίθηκε ως η βέλτιστη πρακτική, προκειμένου να αποτυπωθεί η πραγματική δομή του **dataset** πριν υποστεί την οποιαδήποτε αλλοίωση. Παρακάτω παρουσιάζονται μερικά από τα συμπεράσματα της πρώτης εργασίας.

Αρχικά, στην ανάλυση εξετάστηκε η προέλευση των δηλώσεων, με το σύνολο των 3.448 δειγμάτων να μοιράζεται σε τέσσερις προέδρους των ΗΠΑ: **Donald J. Trump** (1.325), **Barack Obama** (1.010), **George W. Bush** (714) και **Joseph R. Biden** (399). Επίσης, πραγματοποιήθηκε ανάλυση του μήκους των κειμένων για την κατανόηση της δομής τους. Τα αποτελέσματα παρουσιάζονται αναλυτικά στον Πίνακα 1, όπου και διαφαίνεται η γενικότερη τάση των πολιτικών προσώπων για σύντομες και περιεκτικές δηλώσεις κατά τη διάρκεια των συνεντεύξεων. Σημειώνουμε ότι η υψηλή τυπική απόκλιση υποδηλώνει μεγάλη μεταβλητότητα στην έκταση του πολιτικού λόγου, όπως άλλωστε ήταν αναμενόμενο.

Πίνακας 1: Στατιστικά στοιχεία μήκους κειμένων (word count) σε στρογγυλοποίηση

Στατιστικό Μέγεθος	Τιμή
Πλήθος Δειγμάτων Λέξεων (Count)	3.390
Μέσος Όρος (Mean)	294,02
Τυπική Απόκλιση (Std)	300,96
Ελάχιστο (Min)	1
25% (Πρώτο Τεταρτημόριο)	58,25
Διάμεσος (50%)	208
75% (Τρίτο Τεταρτημόριο)	440
Μέγιστο (Max)	2.117



Σχήμα 1: Ανισορροπία κλάσεων.

Σύμφωνα με το παραπάνω σχήμα, παρατηρείται έντονη ανισορροπία (**class imbalance**) στα δεδομένα. Η συντριπτική κυριαρχία της αμφίσημης κατηγορίας αντανακλά τη φύση του πολιτικού λόγου, όπου τα πολιτικά πρόσωπα συχνά επιλέγουν έμμεσες ή διπλωματικές τοποθετήσεις αντί για ευθείες απαντήσεις.

3.3. Διαχωρισμός Δεδομένων

Για την ανάπτυξη και την αξιολόγηση των μοντέλων, αξιοποιήθηκε το επίσημο σύνολο δεδομένων του διαγωνισμού **SemEval 2026 (Task 6)**. Η βασική κατάτμηση σε σύνολο εκπαίδευσης (**train set**) και σύνολο δοκιμής (**test set**) διατηρήθηκε όπως καθορίστηκε από τους διοργανωτές. Στην παρούσα εργασία δημιουργήθηκε ένας διαχωρισμός **Train/Validation** με αναλογία 80/20, με χρήση στρωματοποιημένης δειγματοληψίας (`stratify=train_df['label_norm']`). Η επιλογή αυτής της τεχνικής κρίνεται απαραίτητη, καθώς εμφανίζεται έντονη ταξική ανισορροπία στο σύνολο των δεδομένων, η οποία και επηρεάζει τελικά τα αποτελέσματά μας. Επιπρόσθετα, τα ευρετήρια των νέων υποσυνόλων επαναρχικοποιήθηκαν (`reset_index(drop=True)`) για την αποφυγή σφαλμάτων κατά την τροφοδοσία τους στο σύστημα.

Ο ρόλος αυτού του διαχωρισμού καθορίζεται ως εξής:

- **Train Set:** Χρησιμοποιήθηκε αποκλειστικά για τη δοκιμή, τον εντοπισμό σφαλμάτων (**debugging**) και τον αρχικό σχεδιασμό των **prompts** των πρακτόρων.
- **Σύνολο Αξιολόγησης (Validation Set):** Χρησιμοποιήθηκε για την αντικειμενική μέτρηση της απόδοσης, διασφαλίζοντας ότι το σύστημα μπορεί να γενικεύσει και να ταξινομήσει ορθά εντελώς άγνωστες πολιτικές ερωταπαντήσεις.

Ωστόσο, λόγω των ιδιαίτερων απαιτήσεων του **multi-agent** συστήματος, όπου απαιτείται διαδοχική παραγωγή κειμένου από τέσσερις διαφορετικούς πράκτορες για κάθε μία ερώτηση,

η πλήρης χρήση του συνόλου κρίθηκε απαγορευτική ως προς το υπολογιστικό κόστος και τον χρόνο εκτέλεσης. Για την εκτέλεση αξιόπιστων πειραμάτων χωρίς την εξάντληση των διαθέσιμων πόρων, απομονώθηκε ένα αντιπροσωπευτικό υποσύνολο 100 δειγμάτων. Δεδομένου ότι το σύνολο είχε ήδη υποστεί στρωματοποιημένη δειγματοληψία και τυχαιοποίηση, η επιλογή των 100 δειγμάτων αποτελεί έναν πρακτικό και ελεγχόμενο αριθμό που διατηρεί την αναλογία των κλάσεων. Ο όγκος αυτός εξασφαλίζει επαρκή στατιστική σημαντικότητα για την εξαγωγή αξιόπιστων μετρικών (όπως το **Macro F1-Score**), αποτρέποντας ταυτόχρονα το περιττό υπολογιστικό φορτίο.

Τέλος, το **random seed** ορίστηκε αυστηρά στην τιμή 42 για να εξασφαλιστεί η πλήρης αναπαραγωγικότητα των πειραμάτων και του διαχωρισμού. Ωστόσο, αξίζει να αναφερθεί πως, λόγω μη-ντετερμινιστικών παραγόντων χαμηλού επιπέδου (όπως η φύση του **hardware** και του μοντέλου), ενδέχεται να παρατηρηθούν ελάχιστες, στατιστικά μη σημαντικές, διαφοροποιήσεις στα δεκαδικά ψηφία των **scores** μεταξύ διαφορετικών εκτελέσεων.

3.4. Tokenization & Few-Shot

Στην παρούσα εργασία δεν υφίσταται κλασική μαθηματική διανυσματοποίηση στο επίπεδο προεπεξεργασίας. Το κείμενο υφίσταται επεξεργασία στην αρχική του μορφή μέσω του ενσωματωμένου **Tokenizer** (όπως αυτός αρχικοποιείται από τη βιβλιοθήκη **Transformers** για το μοντέλο **Qwen**).

Η επιλογή των παραδειγμάτων για τη στρατηγική **Few-Shot** βασίστηκε στην εξής προσέγγιση: Αντί για τη δυναμική και τυχαία επιλογή παραδειγμάτων (**shots**) από μια δεξαμενή δεδομένων, επιλέχθηκε η προσέγγιση του **Static Few-Shot Prompting**. Ειδικότερα, για την υποβοήθηση του τελικού **Decision Agent** (Πράκτορας 4), ενσωματώθηκαν 5 αυστηρά επιλεγμένα παραδείγματα απευθείας στο **System Prompt** του. Η επιλογή αυτών των 5 στατικών παραδειγμάτων σχεδιάστηκε σκόπιμα ώστε να λειτουργούν ως οδηγοί-πρότυπα για τον πράκτορα, καλύπτοντας τις πιο κρίσιμες οριακές περιπτώσεις:

- Άμεση ή έμμεση κάλυψη του ερωτήματος (**Clear Reply**).
- Μερική, γενικόλογη ή εκτός-στόχου σχετική τοποθέτηση (**Ambivalent**).
- Άρνηση απάντησης, ισχυρισμός άγνοιας ή πλήρης υπεκφυγή (**Clear Non-Reply**).

Με την άμεση ενσωμάτωση αυτών των στατικών παραδειγμάτων στον πυρήνα των οδηγιών του **Agent**, εξασφαλίζεται η απόλυτη σταθερότητα κατά την αξιολόγηση. Παράλληλα, η μέθοδος αυτή μειώνει τον κίνδυνο εισαγωγής επιπλέον **bias** λόγω μη ισορροπημένης επιλογής παραδειγμάτων, καθώς **bias** θα μπορούσε να προκύψει από μια δυνητικά ανισόρροπη επιλογή τυχαίων δειγμάτων.

4. Αλγόριθμοι και Πειραματική Διαδικασία


4.1. Σχεδιασμός Προτροπών (**Prompt Design**) και Αρχιτεκτονική Πρακτόρων

Η προτεινόμενη προσέγγιση βασίζεται σε μία πολυπρακτορική (**multi-agent**) αρχιτεκτονική τεσσάρων διακριτών πρακτόρων, όπου κάθε πράκτορας αναλαμβάνει ένα εξειδικευμένο στάδιο της διαδικασίας συλλογισμού. Όλοι οι πράκτορες επικοινωνούν μέσω αυστηρά δομημένων εξόδων σε μορφή **JSON**, επιτρέποντας τον σαφή διαχωρισμό ευθυνών και περιορίζοντας την πιθανότητα παραγωγής παραισθήσεων (**hallucinations**) ή αυθαίρετων συμπερασμάτων από

το γλωσσικό μοντέλο. Ταυτόχρονα, η ιεραρχική αυτή αποσύνθεση της διαδικασίας αξιολόγησης μειώνει τη γνωστική επιβάρυνση και την πολυπλοκότητα κάθε επιμέρους βήματος, ενώ παράλληλα ενισχύει σημαντικά την ερμηνευσιμότητα του συνολικού συστήματος.

Η συνολική ροή εκτέλεσης ακολουθεί τέσσερα διαδοχικά στάδια και τα αντίστοιχα prompts δίνονται στο Παράρτημα Β της παρούσας εργασίας:

- **Question Intent Agent:** Αναλύει αποκλειστικά την υπο-ερώτηση (TARGET_QUESTION) και όχι το πλήρες ερώτημα της συνέντευξης. Ο πράκτορας προσδιορίζει τον τύπο της ερώτησης (π.χ. *yes_no*, *why*, *stance*), εντοπίζει την πρόθεση του ερωτώντος και ορίζει τα ελάχιστα απαιτούμενα στοιχεία που πρέπει να περιέχει μία σαφής απάντηση.
- **Answer Content Agent:** Εξάγει αποκλειστικά το περιεχόμενο της απάντησης που σχετίζεται με το TARGET_QUESTION. Ο πράκτορας έχει ρητές οδηγίες να μην επιβραβεύει πολιτική ρητορική, να μη συνάγει συμπεράσματα που δεν αναφέρονται ρητά στο κείμενο και να απομονώνει πληροφορίες που απαντούν σε διαφορετικό ερώτημα.
- **Gap and Evasion Agent:** Συγκρίνει τις απαιτήσεις της ερώτησης με το περιεχόμενο που εξήχθη από την απάντηση. Για τον σκοπό αυτό χρησιμοποιεί μία αναλυτική ταξινόμια στρατηγικών υπεκφυγής, όπως *dodging*, *deflection*, *claims_ignorance* και *declining_to_answer*. Παράλληλα εκτιμά το επίπεδο πληρότητας της απάντησης και το μέγεθος του πληροφοριακού κενού.
- **Decision Agent:** Συνθέτει τα ευρήματα των προηγούμενων πρακτόρων και αποδίδει την τελική κατηγορία ταξινόμησης. Σε αντίθεση με τους προηγούμενους πράκτορες που εκτελούν εκτενείς σημασιολογικές αναλύσεις, ο συγκεκριμένος πράκτορας είναι σχεδιασμένος να παράγει σημαντικά μικρότερο όγκο κειμένου, καθώς ο ρόλος του περιορίζεται αποκλειστικά στη συλλογή των προηγούμενων ευρημάτων και στην εξαγωγή του τελικού συμπεράσματος.



Σχήμα 2: Αρχιτεκτονική ροής και αλληλεπίδραση των πρακτόρων στο σύστημα D3 (Πηγή: Βοηθητικό υλικό μαθήματος).

Επιπλέον, σημαντικό στοιχείο της διαδικασίας βελτιστοποίησης αποτελεί το γεγονός ότι η εκπαίδευση μέσω DSPy εφαρμόζεται αποκλειστικά στον **Question Intent Agent**, ενώ η αξιολόγηση γίνεται σε επίπεδο πλήρους **pipeline**. Με αυτόν τον τρόπο, η βελτιστοποίηση δεν στοχεύει στην τοπική απόδοση του επιμέρους πράκτορα, αλλά στη συνολική επίδρασή του στην τελική απόφαση ταξινόμησης, η οποία προκύπτει από τη διαδοχική εκτέλεση όλων των πρακτόρων.

Τέλος, η **ablation** μελέτη αποσκοπεί στην αποτίμηση της συνεισφοράς του **Gap and Evasion Agent** στη συνολική απόδοση του συστήματος. Η αφαίρεσή του οδηγεί σε άμεση απώλεια πληροφορίας σχετικά με την πληρότητα και τη στρατηγική απάντησης, γεγονός που αναδεικνύει τη συμβολή του στη διάκριση μεταξύ πλήρων και μερικών απαντήσεων.

4.2. Πειραματικός Σχεδιασμός

Για την αξιολόγηση της προτεινόμενης αρχιτεκτονικής σχεδιάστηκαν τέσσερα κύρια πειράματα. Στόχος ήταν αφενός η διερεύνηση της επίδρασης της βελτιστοποίησης προτροπών μέσω του πλαισίου **DSPy** και αφετέρου η αποτίμηση της συνεισφοράς των επιμέρους πρακτόρων στην τελική απόδοση του συστήματος.

Πείραμα	Περιγραφή
Baseline D3	Η αρχική αρχιτεκτονική τεσσάρων πρακτόρων χωρίς καμία βελτιστοποίηση προτροπών μέσω DSPy .
DSPy Prompt Optimization	Πειράματα βελτιστοποίησης των προτροπών του Question Intent Agent με διαφορετικούς βελτιστοποιητές και μεγέθη συνόλων παραδειγμάτων.
DSPy-Optimized D3	Εκτέλεση ολόκληρου του pipeline χρησιμοποιώντας τον βελτιστοποιημένο Question Intent Agent που προέκυψε από το προηγούμενο στάδιο.
Ablation Study (No Gap Evasion)	Αφαίρεση του Gap and Evasion Agent από το pipeline , με στόχο την αξιολόγηση της συνεισφοράς του στην τελική ταξινόμηση.

Πίνακας 2: Σύνοψη των κύριων πειραμάτων της εργασίας.

Όλα τα πειράματα αξιολογήθηκαν στο ίδιο υποσύνολο του συνόλου επικύρωσης (**validation set**) και με τις ίδιες μετρικές αξιολόγησης, ώστε να διασφαλιστεί η δίκαιη και άμεση σύγκριση των αποτελεσμάτων.

4.2.1. Πειράματα Βελτιστοποίησης μέσω *DSPy*. Το **DSPy** αποτελεί ένα σύγχρονο πλαίσιο (**framework**) το οποίο αντικαθιστά τη χειροκίνητη συγγραφή και δοκιμή προτροπών (**trial-and-error prompting**) με αυτοματοποιημένη, αλγοριθμική βελτιστοποίηση. Στην παρούσα εργασία, το **DSPy** αξιοποιήθηκε αποκλειστικά για τη μικρορρύθμιση του **Question Intent Agent**, καθώς ως το πρώτο στάδιο του **pipeline** επηρεάζει έμμεσα και καθοριστικά όλες τις μεταγενέστερες αποφάσεις του συστήματος.

Για τον σκοπό αυτό, σχεδιάστηκε και υλοποιήθηκε ένα πλέγμα δοκιμών (**grid search**) προκειμένου να εξεταστούν διαφορετικοί αλγόριθμοι βελτιστοποίησης σε συνδυασμό με ποιχίλα μεγέθη ισορροπημένων συνόλων παραδειγμάτων (**few-shot examples**). Στόχος της διαδικασίας ήταν να ‘μάθει’ ο πράκτορας να εντοπίζει με ακρίβεια την πραγματική πρόθεση πίσω από κάθε ερώτηση.

Κατά τη φάση της βελτιστοποίησης (**tuning**), η επιλογή της τελικής προτροπής βασίστηκε στη μετρική της Ορθότητας (**Accuracy**) και όχι στο **F1-Score**. Η επιλογή αυτή έγινε καθώς, σε αυτό το αρχικό στάδιο της αρχιτεκτονικής, πρωτεύων στόχος είναι η απόλυτη και ορθή εννοιολογική κατανόηση της ερώτησης. Η διαχείριση της ταξικής ανισορροπίας που εμφανίζεται δεν αφορά αυτόν τον πράκτορα, καθώς εξισορροπείται και αντιμετωπίζεται αποτελεσματικά στα επόμενα στάδια του συστήματος από τους υπόλοιπους πράκτορες.

Όνομα Πειράματος	Optimizer	Δείγματα ανά Κλάση	Κύκλοι / Υποψήφια Προγράμματα
Baseline	BootstrapFewShot (BFS)	4	1 (max_rounds)
More Data	BootstrapFewShot (BFS)	6	1 (max_rounds)
Random Search	BootstrapFewShot- WithRandomSearch (BFSR)	4	2 (num_candidates)

Πίνακας 3: Πειραματικές διαμορφώσεις για τη βελτιστοποίηση του Question Intent Agent μέσω DSPy.

Μετά την ολοκλήρωση της διαδικασίας βελτιστοποίησης, επιλέχθηκε αυτόματα η διαμόρφωση με τη μεγαλύτερη απόδοση **downstream performance**, η οποία χρησιμοποιήθηκε στο πείραμα DSPy-Optimized D3.

4.3. Inference Settings και Περιορισμοί

Οι αυστηροί περιορισμοί υλικού της δωρεάν πλατφόρμας **Kaggle**, σε συνδυασμό με τη χρήση γλωσσικών μοντέλων σε περιβάλλον περιορισμένων υπολογιστικών πόρων, οδήγησαν στην υιοθέτηση μίας συντηρητικής εκτέλεσης, καθώς κατά τη διάρκεια των αρχικών δοκιμών παρατηρήθηκαν συχνά σφάλματα εξάντλησης μνήμης (**Out-of-Memory**) και αυξημένοι χρόνοι εκτέλεσης, γεγονός που κατέστησε απαραίτητη την προσαρμογή των παραμέτρων του συστήματος.

Για τη διασφάλιση της αναπαραγωγιμότητας και της σταθερότητας των πειραμάτων εφαρμόστηκαν οι ακόλουθες ρυθμίσεις:

- **Μηδενική Θερμοκρασία (temperature=0.0):** Εξασφαλίζει πλήρως ντετερμινιστικές εξόδους, μειώνοντας τη δημιουργικότητα του μοντέλου υπέρ της σταθερότητας. Παράλληλα, η ρητή εντολή για παραγωγή δομημένης εξόδου σε μορφή **JSON** αποτρέπει το μοντέλο από την παραγωγή περιττής φλυαρίας (**verbosity**), μειώνοντας τον χρόνο παραγωγής (**generation time**) και επιτρέποντας την άμεση και αξιόπιστη ανάγνωση των δεδομένων (**parsing**) από την **Python** στο επόμενο βήμα του **pipeline**.
- **Μηχανισμός Checkpointing:** Ενδιάμεση αποθήκευση αποτελεσμάτων κάθε 25 παραδείγματα για προστασία από πιθανά **timeouts** ή διακοπές της πλατφόρμας.
- **Πρόωρος Τερματισμός (Early Stopping):** Κατά την εκτέλεση εντατικών υπολογισμών, παρατηρήθηκε πως η μπάρα προόδου τερμάτιζε πριν ολοκληρωθεί το 100% των δεδομένων. Το γεγονός αυτό αποτέλεσε άλλη μια ένδειξη των αυστηρών χρονικών ορίων (**timeouts**) της πλατφόρμας, καθιστώντας τον μηχανισμό **checkpoint** αλλά και τον περιορισμό στα 100 δείγματα για το **validation set** απολύτως αναγκαίες επιλογές.
- **Ανθεκτικότητα σε Σφάλματα:** Χρήση μηχανισμών **try/except** ώστε η αποτυχία παραγωγής έγκυρου **JSON** από κάποιον πράκτορα να μην διακόπτει την εκτέλεση του πειράματος.

4.4. Τεχνικές Βελτιστοποίησης και Εξαγωγής Αποτελεσμάτων

Πέρα από τη βασική αρχιτεκτονική, υλοποιήθηκαν επιπλέον τεχνικές που βελτιώνουν τη σταθερότητα και την αποτελεσματικότητα του συστήματος:

- Αξιολόγηση βάσει **Downstream Task Metric**: Η μετρική βελτιστοποίησης του DSPy δεν αξιολογεί μεμονωμένα τον Question Intent Agent αλλά την επίδρασή του στην τελική ταξινόμηση του πλήρους pipeline.
- Ισορροπημένη Δειγματοληψία (**Balanced Sampling**): Χρήση ίσου αριθμού παραδειγμάτων ανά κατηγορία κατά τη διαδικασία βελτιστοποίησης για την αποφυγή προκατάληψης προς τις πλειοψηφικές κλάσεις.
- Μοτίβο Προσαρμογέα (**Adapter Pattern**): Δημιουργία μηχανισμού μετατροπής των εξόδων του DSPy στη μορφή δεδομένων που απαιτεί το υπόλοιπο pipeline.
- Διαχείριση Μνήμης στο **DSPy**: Περιορισμός του αριθμού νημάτων εκτέλεσης και αποφυγή λειτουργιών που προκαλούσαν υπερβολική κατανάλωση μνήμης στο περιβάλλον του Kaggle.
- Ανθεκτικότητα στην Ανάλυση Κειμένου (**Robust Parsing**): Ανάπτυξη βοηθητικών μηχανισμών καθαρισμού και ανάκτησης JSON δεδομένων για την ασφαλή μεταφορά πληροφορίας μεταξύ των πρακτόρων.

4.5. Αξιολόγηση και Ανάλυση Πειραμάτων


Σε αυτήν την ενότητα παρουσιάζουμε τα συγκριτικά πειράματα, ενώ στην επόμενη θα αναλύσουμε το βέλτιστό μας μοντέλο. Για την πλήρη κατανόηση της συμπεριφοράς των γλωσσικών μοντέλων, κρίνεται απαραίτητη η παράθεση του συνόλου των πειραματικών δοκιμών.

4.5.1. Συγκριτικά Αποτελέσματα. Ο Πίνακας 4 συνοψίζει την απόδοση των μη-βέλτιστων μοντέλων στο validation set.

Μοντέλο	Accuracy	Precision (macro)	Recall (macro)	F1-score (macro)
Baseline / Manual D3	0.60	0.54	0.49	0.51
Ablation (No Gap Evasion)	0.44	0.48	0.42	0.39

Πίνακας 4: Σύγκριση απόδοσης μεταξύ του βέλτιστου μοντέλου (Baseline) και του Ablation στο validation set.

Παρατηρείται ότι το **Baseline** μοντέλο υπερέχει σημαντικά του **Ablation** συστήματος, γεγονός που υποδεικνύει ότι ο **Gap and Evasion Agent** συνεισφέρει ουσιαστικά στη συνολική ποιότητα της ταξινόμησης.



Σχήμα 3: Σύγκριση μοντέλων με βάση το macro F1-score.

Όπως αποτυπώνεται οπτικά στο Σχήμα 3, η απουσία του **Gap and Evasion Agent** στην προσέγγιση **Ablation** οδηγεί σε αισθητή πτώση του **F1-Macro score** (0.38), επιβεβαιώνοντας τη χρησιμότητα του συγκεκριμένου πράκτορα.


4.5.2. Ανάλυση Ανά Κλάση. Η ανάλυση ανά κλάση αποκαλύπτει έντονη ανισορροπία στην ικανότητα του μοντέλου να αναγνωρίζει τις διαφορετικές κατηγορίες. Συγκεκριμένα:

- Η κατηγορία **Ambivalent** παρουσιάζει τη σταθερά υψηλότερη επίδοση ($F1 \approx 0.70$ στο **Baseline**), γεγονός που υποδηλώνει ότι το μοντέλο τείνει να ευνοεί μεσαίες ή μερικώς σχετικές απαντήσεις.
- Η κατηγορία **Clear Reply** εμφανίζει μέτρια επίδοση ($F1 \approx 0.42$), με αρκετές περιπτώσεις σύγχυσης με την κατηγορία **Ambivalent**.
- Η κατηγορία **Clear Non-Reply** παρουσιάζει αντίστοιχα μια μέτρια απόδοση ($F1 \approx 0.40$)

Η παραπάνω συμπεριφορά είναι ενδεικτική **bias** προς τις ενδιάμεσες κατηγορίες, πιθανώς λόγω της κατανομής του **dataset** και της φύσης των ενδιάμεσων ενδείξεων που παρέχονται από τα **prompts**.

4.5.3. Ανάλυση Συμπεριφοράς και Σφαλμάτων. Η ποιοτική ανάλυση των σφαλμάτων αποκαλύπτει τρεις κύριες κατηγορίες αποτυχίας:


1. **Υπερβολική εμπιστοσύνη σε λανθασμένες προβλέψεις** Παρατηρούνται περιπτώσεις όπου το μοντέλο αποδίδει υψηλή εμπιστοσύνη σε λανθασμένες προβλέψεις, γεγονός που υποδεικνύει ότι η βαθμονόμηση της πιθανότητας δεν ανταναχλά πάντα τη σωστή κατανόηση του περιεχομένου.



Σχήμα 4: Διασπορά της εμπιστοσύνης (confidence) του πράκτορα απόφασης (Qwen3.5-0.8B) ανάμεσα στις λανθασμένες και τις σωστές προβλέψεις.

Όπως καθίσταται σαφές από το Σχήμα 4, η θεωρητική παραδοχή επιβεβαιώνεται απόλυτα από τα δεδομένα. Η κατανομή του δείκτη εμπιστοσύνης για τις λανθασμένες προβλέψεις (Wrong Prediction) παρουσιάζει έντονη συγκέντρωση σε ιδιαίτερα υψηλές τιμές, κυρίως στο εύρος 0.85 έως 0.95. Ουσιαστικά, το μοντέλο εμφανίζεται εξίσου ‘βέβαιο’ για τα λάθη του όσο και για τις σωστές του απαντήσεις (Correct Prediction), όπου ο κύριος όγκος των τιμών συγκεντρώνεται στο ίδιο περίπου επίπεδο (με σχεδόν μηδενική διασπορά γύρω από το 0.85). Αυτή η αδυναμία διαχωρισμού υποδηλώνει φτωχή βαθμονόμηση, ένα συχνό φαινόμενο στα μικρότερα σε μέγεθος LLMs, καθώς τείνουν να είναι υπερβολικά σίγουρα (overconfident) ακόμα και όταν αστοχούν.

2. Σύγκριση μεταξύ **Ambivalent** και **Clear Reply** Ένα σημαντικό ποσοστό λαθών αφορά τη δυσκολία διάκρισης μεταξύ μερικώς απαντημένων και πλήρως απαντημένων ερωτήσεων. Αυτό υποδηλώνει ότι το μοντέλο βασίζεται περισσότερο σε λεξιλογικά ή επιφανειακά χαρακτηριστικά παρά σε δομική κατανόηση της πληρότητας της απάντησης.



Σχήμα 5: Κατανομή των λανθασμένων προβλέψεων (mismatches) του μοντέλου ανά πραγματική κλάση (Gold Label).

Η παραπάνω θεωρητική προσέγγιση επιβεβαιώνεται ποσοτικά στο Σχήμα 5, όπου αποτυπώνεται ο απόλυτος αριθμός σφαλμάτων ανά πραγματική κατηγορία. Η κλάση *Ambivalent* συγκεντρώνει με διαφορά τον υψηλότερο αριθμό αστοχιών (προσεγγίζοντας τα 17 λάθη), ακολουθούμενη στενά από την κλάση *Clear Reply* (περίπου 15 λάθη). Αντίθετα, οι περιπτώσεις ξεκάθαρης υπεκφυγής (*Clear Non-Reply*) παρουσιάζουν τον μικρότερο αριθμό σφαλμάτων. Η κατανομή αυτή αποδεικνύει πως το μοντέλο αναγνωρίζει με σχετική ευκολία τις ακραίες περιπτώσεις άρνησης, αλλά δυσκολεύεται έντονα να αξιολογήσει τις λεπτές αποχρώσεις (nuances) στις περιπτώσεις όπου ο ομιλητής παρέχει μεν πληροφορίες, αλλά αυτές είναι ελλιπείς ή υπερβολικά γενικές.

Συμπερασματικά, τα μη-βέλτιστα μοντέλα δείχνουν ότι η βελτίωση της αρχιτεκτονικής μέσω DSPy και η εισαγωγή του Gap and Evasion Agent συμβάλλουν στη βελτίωση της απόδοσης, χωρίς όμως να επιλύουν πλήρως το πρόβλημα της κλάσης *Clear Non-Reply*. Η ανάλυση αυτή αναδεικνύει ότι η κύρια πρόκληση του task δεν είναι η γενική κατανόηση του περιεχομένου, αλλά η λεπτή διάκριση μεταξύ μερικής και μη-απάντησης.

5. Αποτελέσματα βέλτιστης δοκιμής


Με βάση τη συνολική πειραματική αξιολόγηση, ως βέλτιστο μοντέλο αναδείχθηκε η αρχιτεκτονική **Baseline / Manual D3** με F_1 -Macro score 50.87%, επικρατώντας οριακά της προσέγγισης DSPy (0.46). Η επιλογή του **Champion** έγινε με γνώμονα το F_1 -Macro, το οποίο αποτιμά ισοσταθμώς την απόδοση σε όλες τις κλάσεις, αποφεύγοντας την πόλωση υπέρ της πλειοψηφικής κατηγορίας.

Επιπλέον, αξίζει να σημειωθεί ότι κατά την υποβολή των προβλέψεων του τελικού pipeline στην πλατφόρμα του Kaggle στο σύνολο ελέγχου (Test Set), το σύστημα πέτυχε **F1-score** 0.56, επιβεβαιώνοντας τη στιβαρότητά του σε εντελώς άγνωστα δεδομένα.

Ο Πίνακας 5 παρουσιάζει αναλυτικά τις μετρικές απόδοσης ανά κλάση για το βέλτιστο μοντέλο στο validation set των 100 δειγμάτων.

Κατηγορία (Class)	Precision	Recall	F1-score	Support
Clear Reply	0.46	0.39	0.42	28
Ambivalent	0.66	0.75	0.70	60
Clear Non-Reply	0.50	0.33	0.40	12
Accuracy			0.60	100
Macro Average	0.54	0.49	0.51	100
Weighted Average	0.59	0.60	0.59	100

Πίνακας 5: Αναλυτικό Classification Report του βέλτιστου μοντέλου (Baseline / Manual D3).



Σχήμα 6: Πίνακας Σύγχυσης (Confusion Matrix) του βέλτιστου μοντέλου (Baseline / Manual D3).

Η μελέτη του Πίνακα 5 σε συνδυασμό με τον Πίνακα Σύγχυσης (Σχήμα 6) αποκαλύπτει κρίσιμα συμπεράσματα για τη συμπεριφορά και τις εγγενείς αδυναμίες του μοντέλου:

- **Ambivalent** (Πλειοψηφική κλάση): Το μοντέλο επιτυγχάνει την υψηλότερη επίδοσή του εδώ ($F_1 = 0.70$, $Recall = 0.75$). Η συμπεριφορά αυτή ερμηνεύεται από την έντονη ανισορροπία των κλάσεων (class imbalance), καθώς η συγκεκριμένη κατηγορία κυριαρχεί στο validation set (Support = 60).
- **Clear Reply**: Εμφανίζει μέτρια συμπεριφορά ($F_1 = 0.42$), με ποσοστά Precision 0.46 και Recall 0.39. Ωστόσο, ο πίνακας σύγχυσης δείχνει ότι πάνω από τις μισές καθαρές απαντήσεις (15 από τις 28) παρερμηνεύονται ως *Ambivalent*.


- **Clear Non-Reply:** Το μοντέλο καταγράφει χαλαρή επίδοση (0.40%), αποτυγχάνοντας να εντοπίσει την πλειοψηφία των περιπτώσεων καθαρής υπεκφυγής. Από τις 12 πραγματικές περιπτώσεις, οι 8 ταξινομήθηκαν λανθασμένα ως *Ambivalent* και μόλις 4 ως *Clear-Non Reply*.

Τα παραπάνω ευρήματα οδηγούν σε δύο πολύ σημαντικά συμπεράσματα σχετικά με τη γνωστική λειτουργία του συστήματος:

A) Η Στρατηγική της ‘Μέσης Οδού’ (**Majority Bias**): Ο πίνακας σύγχυσης αποδεικνύει ότι το **Qwen-0.8B** αναπτύσσει μια συμπεριφορά ασφάλειας προς την πλειοψηφική κλάση. Όταν το μοντέλο έρχεται αντιμέτωπο με περίπλοκο πολιτικό λόγο, ρητορικές ερωτήσεις ή μακροσκελείς τοποθετήσεις, παρουσιάζει αδυναμία να πάρει μια απόλυτη απόφαση (*Clear Reply* ή *Clear Non-Reply*). Ως αποτέλεσμα, τείνει να διοχετεύει τη συντριπτική πλειοψηφία των προβλέψεών του (68 από τις 100 συνολικά) στην ενδιάμεση κατηγορία (*Ambivalent*), χρησιμοποιώντας την ουσιαστικά ως ‘μαξιλαράκι’ ασφαλείας για να ελαχιστοποιήσει το ρίσκο της πλήρους αποτυχίας.

B) Τα Όρια Σημασιολογικής Κατανόησης Μοντέλων: Η μερική αδυναμία αναγνώρισης της κλάσης *Clear Non-Reply* υπογραμμίζει τους περιορισμούς που επιβάλλει το μικρό μέγεθος του μοντέλου. Η αναγνώριση μιας καθαρής άρνησης απάντησης (υπεκφυγής) στον πολιτικό λόγο απαιτεί βαθιά κατανόηση των συμφραζομένων (**contextual awareness**) και εντοπισμό λογικών κενών. Το μοντέλο των **0.8B** παραμέτρων, παρότι καθοδηγείται από ένα δομημένο **pipeline** πρακτόρων (**D3**), φαίνεται να εξαντλείται στη γραμματική και συντακτική ανάλυση της απάντησης. Επειδή οι πολιτικοί χρησιμοποιούν πολλές λέξεις που επιφανειακά μοιάζουν με απάντηση, το **LLM** παραπλανάται και αδυνατεί να αντιληφθεί τη δομική απουσία ουσίας.

5.0.1. Ανάλυση Υποομάδων (**Subgroup Analysis**): Προκειμένου να κατανοήσουμε βαθύτερα τη συμπεριφορά του βέλτιστου μοντέλου, πραγματοποιήθηκε ανάλυση σε υποομάδες (**subgroups**) δεδομένων με βάση τα μορφολογικά χαρακτηριστικά των κειμένων, όπως το μήκος των ερωτήσεων και των απαντήσεων (με κριτήριο διαχωρισμού τη διάμεσο των 12 λέξεων για τις ερωτήσεις και των 204.5 λέξεων για τις απαντήσεις).



Σχήμα 7: Διακύμανση του F1-Macro score του **Champion** μοντέλου σε διαφορετικές υποομάδες (subgroups) με βάση το μήκος ερωτήσεων και απαντήσεων.

Η επιλογή της διαμέσου (median) ως κατώφλι (threshold) για τον διαχωρισμό των υποομάδων είναι στατιστικά απαραίτητη. Σε αντίθεση με τον αριθμητικό μέσο όρο, ο οποίος επηρεάζεται σημαντικά από ακραίες τιμές (outliers), η διάμεσος διασφαλίζει έναν απόλυτα ισορροπημένο διαχωρισμό των δεδομένων. Με αυτόν τον τρόπο, το 50% του συνόλου των δειγμάτων ταξινομείται στην υποομάδα των σύντομων χειμένων (Short) και το υπόλοιπο 50% στην υποομάδα των εκτενών χειμένων (Long), επιτρέποντας μια δίκαιη και αξιόπιστη σύγκριση της απόδοσης του μοντέλου.

Όπως αποτυπώνεται ποσοτικά στο Σχήμα 7, η μελέτη των υποομάδων αναδεικνύει μια διαφορετική δυναμική ως προς τη διαχείριση του μήκους των χειμένων. Όσον αφορά τις ερωτήσεις, η υψηλότερη επίδοση του μοντέλου καταγράφεται στην υποομάδα των σύντομων ερωτήσεων (Short Question), αγγίζοντας το 54.96%, ενώ στις μακροσκελείς ερωτήσεις (Long Question) η απόδοση περιορίζεται στο 44.03%.

Το εύρημα αυτό υποδηλώνει ότι οι σύντομες και στοχευμένες ερωτήσεις διευκολύνουν τον **Question Intent Agent** να εντοπίσει με ακρίβεια τον πυρήνα του ερωτήματος. Αντίθετα, οι εκτενείς ερωτήσεις των δημοσιογράφων συχνά περιέχουν πολλαπλά υπο-ερωτήματα, πολύπλοκο νοηματικό πλαίσιο (context) ή ρητορικά στοιχεία, γεγονός που δυσκολεύει το μικρό μοντέλο (0.8B) να απομονώσει την πραγματική απαίτηση της ερώτησης, οδηγώντας το σε σύγχυση.

Όσον αφορά το μήκος των απαντήσεων των πολιτικών, παρατηρείται μια εξαιρετικά μεγάλη απόκλιση, με το F1-Macro score να εκτοξεύεται στο 64.43% για τις σύντομες απαντήσεις (Short Answer), αλλά να καταρρέει στο 28.47% για τις μακροσκελείς (Long Answer). Η έντονη αυτή ανισορροπία υποδεικνύει ότι το σύστημα αποδίδει ικανοποιητικά όταν η απάντηση είναι άμεση και λακωνική (είτε πρόκειται για ξεκάθαρη απάντηση είτε για ευθεία άρνηση). Ωστόσο, στην περίπτωση των εκτενών τοποθετήσεων, το μικρό LLM δυσκολεύεται σε μεγάλο βαθμό να διαχειριστεί την πολιτική φλυαρία. Παρά την ύπαρξη του εξειδικευμένου **Gap and Evasion Agent**, η παρακολούθηση μακροσκελών συλλογισμών, οι αλλαγές θέματος και οι περίτεχνες υπεκφυγές φαίνεται πως υπερβαίνουν τις ικανότητες λογικής εξαγωγής συμπερασμάτων ενός τόσο μικρού μοντέλου, ρίχνοντας δραματικά την απόδοσή του.

5.1. Παράδειγμα Αστοχίας (**Case Study**): Μερική κάλυψη πολλαπλού ερωτήματος

Για να γίνει κατανοητή η αδυναμία του μοντέλου σε περίπλοκες ερωτήσεις, παραθέτουμε ένα χαρακτηριστικό παράδειγμα από τα δεδομένα επικύρωσης (αρχείο `d3_validation_outputs.csv`):

Ερώτηση: 'What is the reason for the President's new refusal to negotiate on the debt ceiling and does this suggest a potential default situation due to lack of communication?'

Απάντηση Πολιτικού: 'Well, no, Major, I think if you look at the history, getting votes for the debt ceiling is always difficult...' [Η απάντηση επικεντρώνεται αποκλειστικά στους λόγους της άρνησης, χωρίς να αναφέρει τον κίνδυνο χρεοκοπίας λόγω έλλειψης επικοινωνίας].

Πραγματική Κλάση (**Gold**): **Ambivalent**

Πρόβλεψη Μοντέλου: **Clear Reply** (Confidence: 0.95)

Ανάλυση του λάθους: Ανατρέχοντας στο ενδιαμέσο εξαγόμενο του **Gap and Evasion Agent** για το συγκεκριμένο δείγμα, παρατηρούμε ότι ο πράκτορας εντόπισε σωστά την παράλειψη (καταγράφοντας `'gap_level': 'minor'`). Πιο συγκεκριμένα, στα `missing_requirements` σημείωσε ότι η απάντηση δεν αξιολογεί τον κίνδυνο χρεοκοπίας. Ωστόσο, επειδή το μεγαλύτερο μέρος του πρώτου σκέλους της ερώτησης απαντήθηκε (`'coverage': 'mostly_complete'`), ο τελικός **Decision Agent** αγνόησε το πληροφοριακό κενό και, με εξαιρετικά υψηλή βεβαιότητα (95%), ταξινόμησε λανθασμένα την απάντηση ως **Clear Reply** αντί για **Ambivalent**.

5.2. Σύγκριση με προηγούμενες αρχιτεκτονικές

Στόχος της παρούσας μελέτης, μέσα από τη σειρά των τεσσάρων εργασιών, ήταν η επίλυση ενός κοινού προβλήματος Επεξεργασίας Φυσικής Γλώσσας (NLP): η ταξινόμηση πολιτικών απαντήσεων από το διαγωνισμό **SemEval 2026 (Task 6)**. Το σύστημα κλήθηκε να κατηγοριοποιήσει τις απαντήσεις πολιτικών σε τρεις κλάσεις: **Clear Reply** (Ξεκάθαρη Απάντηση), **Ambivalent** (Ασαφής/Διπλωματική) και **Clear Non-Reply** (Ξεκάθαρη Υπεκφυγή/Άρνηση). Το σύνολο δεδομένων παρουσιάζει έντονη ταξινομική ανισορροπία, με την κλάση **Ambivalent** να κυριαρχεί, καθιστώντας το **Macro F1-Score** τη μόνη αξιόπιστη μετρική αξιολόγησης.

Για την αντιμετώπιση του προβλήματος, εφαρμόστηκαν τέσσερις θεμελιωδώς διαφορετικές αρχιτεκτονικές προσεγγίσεις, διατηρώντας τα ίδια δεδομένα, ώστε τα αποτελέσματα να είναι απολύτως συγκρίσιμα.

5.2.1. 1. Οι Τέσσερις Μεθοδολογικές Προσεγγίσεις.


- 1η Εργασία - Το **Baseline (TF-IDF & Παραδοσιακή Μηχανική Μάθηση)**: Η πρώτη προσέγγιση βασίστηκε στη στατιστική ανάλυση λέξεων. Εφαρμόστηκε 'βαριά' προεπεξεργασία (`text normalization`, `stemming`, αφαίρεση `stop-words`) για να καθαριστεί το κείμενο. Το μοντέλο απλά μετρούσε συχνότητες λέξεων (TF-IDF). Ήταν μια 'τυφλή' προσέγγιση που αγνοούσε εντελώς τη συντακτική δομή και το βαθύτερο νόημα.
- 2η Εργασία - Ο **Fine-Tuned Διαχωριστής (DeBERTa-v3)**: Εδώ ασχοληθήκαμε με τα `contextualized embeddings`. Χρησιμοποιήθηκε το μοντέλο **DeBERTa**, το οποίο εκπαιδεύτηκε (`gradient-based fine-tuning`) αποκλειστικά πάνω στο συγκεκριμένο **dataset**. Η προεπεξεργασία διατήρησε τη φυσική ροή του κειμένου. Το δίκτυο έμαθε να εξάγει το νόημα και να τραβάει αυστηρά όρια μεταξύ των κλάσεων.

- 3η Εργασία - Το **Generative Zero-Shot LLM (Qwen3.5-2B)**: Στη συνέχεια, εξετάσαμε τη δύναμη των σύγχρονων παραγωγικών μοντέλων (Base LLMs) χωρίς καμία εκπαίδευση. Η προεπεξεργασία εστίασε στη δομική ακεραιότητα (σημεία στίξης, κεφαλαία), ώστε το μοντέλο να διαβάσει το κείμενο όπως ένας άνθρωπος. Χρησιμοποιήθηκε αυστηρό Prompt Engineering (Hidden Chain-of-Thought) και Greedy Decoding για να αναγκαστεί το μοντέλο να εξάγει μόνο την ετικέτα.
- 4η Εργασία - Το **Multi-Agent Σύστημα (Qwen3.5-0.8B / D3 Pipeline)**: Τέλος, το πρόβλημα διασπάστηκε με τη χρήση ενός instruction-tuned LLM μικρότερου μεγέθους, ενσωματωμένο σε ένα δίκτυο 4 πρακτόρων (Agents: Question Intent, Answer Intent, Gap & Evasion, Decision). Η προεπεξεργασία περιελάμβανε δυναμική ανίχνευση και κανονικοποίηση ετικετών. Εφαρμόστηκε Static Few-Shot prompting, και οι πράκτορες επικοινωνούσαν αναλύοντας διαδοχικά την πρόθεση, τα κενά και την τελική ταξινόμηση μέσω αυστηρών μορφοποιήσεων JSON.


Εργασία	Αρχιτεκτονική / Μοντέλο	Προσέγγιση	Macro F1	Το δυνατό της σημείο
HW2	DeBERTa-v3	Fine-Tuned Discriminative	≈ 0.66	Κατανόηση κρυφών μοτίβων υπεκφυγής.
HW1	TF-IDF + ML Base	Bag-of-Words / Στατιστική	≈ 0.60	Γρήγορο, χωρίς απαιτήσεις σε hardware.
HW3	Qwen3.5-2B	Zero-Shot Generative	≈ 0.44	Ισορροπία προβλέψεων (αναγνώρισε τα Clear Replies).
HW4	Qwen3.5-0.8B (Multi-Agent)	Few-Shot Generative (D3)	$\approx 0.50^*$	Μερική ανθεκτικότητα μέσω λογικής αποσύνθεσης.

Πίνακας 6: Συγκριτικός Πίνακας Επιδόσεων (*Το 0.50 αφορά το τοπικό Validation Set, ενώ στο τελικό Test Set του Kaggle η αρχιτεκτονική άγγιξε το 0.56).


5.2.2. 2. Συγκριτική Ανάλυση Σφαλμάτων & Συμπεράσματα. Για την οπτική σύγκριση της συμπεριφοράς των τεσσάρων συστημάτων, επιλέχθηκε η παράθεση των αντίστοιχων Πινάκων Σύγχυσης (Confusion Matrices). Η επιλογή αυτή κρίθηκε επιβεβλημένη, καθώς αποτελεί το μοναδικό καθολικό μετρικό εργαλείο που μπορεί να εφαρμοστεί ομοιόμορφα σε όλες τις προσεγγίσεις, αφού διαγράμματα όπως οι καμπύλες εκπαίδευσης (Learning Curves) δεν υφίστανται για τα παραγωγικά μοντέλα (Generative LLMs) των τελευταίων εργασιών, καθώς δεν πραγματοποιήθηκε εκπαίδευση.




Σχήμα 8: HW1: TF-IDF & ML



Σχήμα 9: HW2: DeBERTa Fine-Tuned



Σχήμα 10: HW3: Qwen-2B Zero-Shot



Σχήμα 11: HW4: Qwen-0.8B Multi-Agent (Συγκριτική απεικόνιση των Πινάκων Σύγχυσης για τις 4 αρχιτεκτονικές)

Η σύγκριση των τεσσάρων προσεγγίσεων αποκαλύπτει γιατί το **Fine-Tuning** παραμένει η ισχυρότερη προσέγγιση στα προβλήματα αυστηρής ταξινόμησης, αλλά και πώς τα **Generative** μοντέλα συμπληρώνουν και αναδεικνύουν διαφορετικές πτυχές του προβλήματος:

- **Στατιστική Επιφάνεια έναντι Βαθιάς Κατανόησης (HW1 vs. HW2):** Το TF-IDF (HW1) φάνηκε τελικά πως έχανε το νόημα. Αν η απάντηση περιείχε τη λέξη ‘Όχι’, το μοντέλο τη θεωρούσε **Clear Reply**, ακόμα κι αν το ‘Όχι’ αναφερόταν σε κάτι άσχετο. Το DeBERTa (HW2) διόρθωσε αυτό το πρόβλημα, κατανοώντας το ευρύτερο πλαίσιο. Ωστόσο, το DeBERTa εμφάνισε το σύνδρομο της ‘Διαχωριστικής Καχυποψίας’: έχοντας εκπαιδευτεί να φάχνει υπεκφυγές, έτεινε να αμφισβητεί ακόμα και τις απολύτως ξεκάθαρες απαντήσεις, ταξινομώντας τις ως **Ambivalent**.
- **Generative Αφέλεια (HW3):** Στον αντίποδα της καχυποψίας του DeBERTa, το Qwen-2B (HW3) αποδείχθηκε ‘Αφελές’. Αντιμετωπίζοντας τον πολιτικό λόγο απολύτως κυριολεκτικά, κατέληξε το 68.9% των αστοχιών του να είναι λανθασμένες προβλέψεις **Ambivalent** απαντήσεων ως **Clear Reply**. Ο συλλογισμός του μοντέλου ήταν πως, αν ο πολιτικός χρησιμοποιεί πολλά λόγια, τότε μάλλον απαντάει, αγνοώντας την απουσία πραγματικής ουσίας.
- **Η Αρχιτεκτονική Αντισταθμίζει το Μέγεθος (HW3 vs. HW4):** Η κλάση (**Clear Non-Reply**) αποτελεί εν γένει τον αυστηρότερο δείκτη ελέγχου για την κριτική αντίληψη ενός μοντέλου. Ενώ αρχικά αναμενόταν ότι ένα μικρό μοντέλο όπως το Qwen-0.8B (HW4) θα αδυνατούσε να συλλάβει τη λογική απουσία της απάντησης καταγράφοντας 0.00% (κάτι που ισχύει σε απλές προσεγγίσεις **prompting**), η υιοθέτηση του D3-Agentic συστήματος ανέτρεψε αυτή τη δυναμική. Το βέλτιστο **pipeline** κατάφερε να πετύχει **F1-score 40%** σε αυτή την κλάση, αναγνωρίζοντας επιτυχώς τις 4 από τις 12 καθαρές υπεκφυγές. Αντιπαραβάλλοντας αυτό το επίτευγμα με τα μεγαλύτερα μοντέλα (>2B) της προηγούμενης εργασίας (HW3), αποδεικνύεται ότι η δομημένη αποσύνθεση του συλλογισμού μέσω εξειδικευμένων πρακτόρων μπορεί να αντισταθμίσει τους περιορισμούς του **hardware** και τον μικρό αριθμό παραμέτρων, επιτρέποντας σε ‘ελαφριά’ μοντέλα να αποκωδικοποιούν τον περίπλοκο πολιτικό λόγο.
- **Φαινόμενο της Χαμένης Πληροφορίας:** Αν και η αρχιτεκτονική **Multi-Agent** βελτίωσε τη διαχείριση των μακροσκελών απαντήσεων, καθώς ο **Gap Agent** φιλτράρει αποτελεσματικά τον θόρυβο, παρατηρήθηκε μια ασυνέχεια στην επικοινωνία των πρακτόρων. Όπως αποτυπώνεται στον Πίνακα Σύγκρισης, σε 13 περιπτώσεις η κλάση **Ambivalent** ταξινομήθηκε λανθασμένα ως **Clear Reply**. Η ανάλυση αυτών των περιπτώσεων έδειξε ότι, ακόμα κι όταν ο ενδιάμεσος πράκτορας αντιλαμβανόταν πως ο πολιτικός απάντησε μόνο σε ένα μέρος του ερωτήματος, ο τελικός **Decision Agent** υπερεκτιμούσε το υπάρχον περιεχόμενο, αγνοούσε την ελλείπουσα πληροφορία και κατέληγε λανθασμένα σε **Clear Reply**. Ωστόσο, αξίζει να σημειωθεί ότι το σφάλμα αυτό είναι δευτερεύον μπροστά στην αντίστροφη και κυρίαρχη τάση του μοντέλου να παρερμηνεύει τις καθαρές απαντήσεις ως **Ambivalent** (15 περιπτώσεις).

Τελικό Συμπέρασμα: Τα **Discriminative** μοντέλα με **Fine-Tuning** (HW2) κυριαρχούν σε ακρίβεια γιατί χτίζουν αυστηρά όρια αποφάσεων. Ωστόσο, οι **Generative Multi-Agent** προσεγγίσεις (HW4) προσφέρουν κάτι που απουσιάζει από τα **Encoders**: την ικανότητα να αναλύουν συλλογιστικά γιατί μια απάντηση ανήκει στην εκάστοτε κλάση. Ένα ιδανικό, μελλοντικό σύστημα θα συνδύαζε την αυστηρότητα του DeBERTa με τη δομημένη και σταδιακή συλλογιστική του D3 Pipeline.

6. Προτάσεις για Μελλοντική Έρευνα

Με βάση τα συμπεράσματα και τους τεχνικούς περιορισμούς που αναδείχθηκαν κατά την υλοποίηση της παρούσας εργασίας, προτείνονται οι ακόλουθες κατευθύνσεις για μελλοντική επέκταση:

- **Ενσωμάτωση Πράκτορα Κριτικής (Critic Agent / Self-Reflection):** Η προσθήκη ενός πέμπτου πράκτορα στο **pipeline**, ο οποίος θα λειτουργεί ως ελεγκτής. Ο πράκτορας αυτός θα αξιολογεί την τελική απόφαση του **Decision Agent** και θα συγκρίνει την παραγόμενη αιτιολόγηση με τα δεδομένα των προηγούμενων βημάτων. Σε περίπτωση λογικών κενών ή υπερβολικής βεβαιότητας σε λανθασμένα στοιχεία, θα επιστρέφει την πρόβλεψη για διόρθωση (**iterative refinement**).
- **Δυναμική Επιλογή Παραδειγμάτων (Dynamic Few-Shot Prompting):** Αντί της χρήσης ενός στατικού συνόλου παραδειγμάτων, προτείνεται η δυναμική προσαρμογή του **prompt** ανάλογα με την εκάστοτε περίπτωση. Μέσω της χρήσης διανυσματικών αναπαραστάσεων (**embeddings**) και μετρικών ομοιότητας, το σύστημα θα μπορεί να αναζητά στο σύνολο εκπαίδευσης (**train set**) τα 3-4 πιο παρόμοια ζεύγη ερωταπαντήσεων και να τα ενσωματώνει στο **prompt** σε πραγματικό χρόνο. Αυτή η προσέγγιση θα παρέχει στο μοντέλο εξαιρετικά στοχευμένο πλαίσιο (**context**) βασισμένο σε παρόμοια γλωσσικά ή νοηματικά μοτίβα, αυξάνοντας την ικανότητά του να ταξινομεί ορθά οριακές περιπτώσεις.
- **Καθολική Βελτιστοποίηση Pipeline (Multi-stage DSPy Optimization):** Στην παρούσα εργασία, το πλαίσιο **DSPy** εφαρμόστηκε επιτυχώς για τη βελτιστοποίηση του **Question Intent Agent**. Σε ένα περιβάλλον με λιγότερους υπολογιστικούς περιορισμούς (απουσία ορίων μνήμης του **Kaggle**), προτείνεται η συνδυαστική βελτιστοποίηση ολόκληρου του δικτύου πρακτόρων (**end-to-end optimization**), επιτρέποντας στο **DSPy** να συντονίσει τις προτροπές όλων των σταδίων ταυτόχρονα.
- **Αξιοποίηση Ισχυρότερων Γλωσσικών Μοντέλων:** Η μετάβαση από το παρόν μοντέλο (0.8B παραμέτρων) σε μεγαλύτερα μοντέλα ανοιχτού κώδικα (π.χ. **Llama-3 8B**) αναμένεται να επιλύσει σημαντικά προβλήματα. Η αυξημένη ικανότητα των μεγαλύτερων μοντέλων στην τήρηση αυστηρών μορφοποιήσεων (**JSON formatting**) θα μειώσει τα **parsing errors**, ενώ η βαθύτερη σημασιολογική τους κατανόηση θα περιορίσει τις αστοχίες στην ερμηνεία έμμεσων απαντήσεων.

7. Βιβλιογραφία

- [1] Διαφάνειες Διαλέξεων - Artificial Intelligence 2: Deep Learning for Natural Language Processing, 2026. Εαρινό Εξάμηνο 2025-2026, SemEval 2026 Task 6.
- [2] DAIR.AI. Prompt Engineering Guide. <https://www.promptingguide.ai/>, 2024. Featured techniques: Zero-shot, Few-shot, Chain-of-Thought.
- [3] Qwen Team. Qwen3.5-0.8B-Instruct Model Card. <https://huggingface.co/Qwen/Qwen3.5-0.8B>, 2025. Accessed: 2026.
- [4] Jurafsky, Daniel and Martin, James H. Speech and Language Processing (3rd ed. draft). <https://web.stanford.edu/~jurafsky/slp3/>, 2024. Chapters 4–5 and 7.
- [5] Omar Khattab, Arnav Singhvi, Paridhi Maheshwari, Zhiyuan Zhang, Keshav Santhanam, Sri Vardhamanan, Saiful Haq, Ashutosh Sharma, Thomas T. Joshi, Hanna Moazam, Heather Miller, Matei Zaharia, Christopher Potts. DSPy: Compiling Declarative Language Model Calls into Self-Improving Pipelines. *arXiv preprint arXiv:2310.03714*, 2023.
- [6] Paszke, Adam and others. PyTorch: An Imperative Style, High-Performance Deep Learning Library. In *Advances in Neural Information Processing Systems* 32, 2019.
- [7] Pedregosa, F. and Varoquaux, G. and Gramfort, A. and Michel, V. and Thirion, B. and Grisel, O. and Blondel, M. and Prettenhofer, P. and Weiss, R. and Dubourg, V. and Vanderplas, J. and Passos, A. and Cournapeau, D. and Brucher, M. and Perrot, M. and Duchesnay, E. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [8] Wei, Jason and Wang, Xuezhi and Schuurmans, Dale and Bosma, Maarten and Ichter, Brian and Xia, Fei and Chi, Ed and Le, Quoc V and Zhou, Denny. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. *Advances in Neural Information Processing Systems*, 35:24824–24837, 2022.
- [9] Wes McKinney. Data Structures for Statistical Computing in Python. In Stéfan van der Walt and Jarrod Millman, editor, *Proceedings of the 9th Python in Science Conference*, pages 56 – 61, 2010.

8. Παραρτήματα - Πρόσθετες Θεωρήσεις

8.1. Παράρτημα Α: Διαχείριση Υπολογιστικών Περιορισμών και Σιωπηλών Σφαλμάτων κατά τη Βελτιστοποίηση **DSPy**

Κατά την υλοποίηση του συστήματος και τη φάση πειραματισμού, επιχειρήθηκε η αυτόματη βελτιστοποίηση των προτροπών (**prompt optimization**) του **Question Intent Agent** μέσω του **framework DSPy**. Για τον σκοπό αυτό, επιστρατεύτηκαν οι αλγόριθμοι **BootstrapFewShot** και **BootstrapFewShotWithRandomSearch** (**Grid Search**). Η συγκεκριμένη διαδικασία απαιτεί την εκτέλεση δεκάδων διαδοχικών κλήσεων (**inferences**) στο τοπικό μοντέλο (**Qwen-0.8B**), προκειμένου να αξιολογηθούν διαφορετικοί συνδυασμοί δειγμάτων (**bootstrapped demonstrations**).

Λόγω των περιορισμένων υπολογιστικών πόρων της πλατφόρμας **Kaggle** (κυρίως σε επίπεδο διαθέσιμης μνήμης **RAM** και **VRAM** της **GPU**), η εκτέλεση του βελτιστοποιητή αντιμετώπισε αρχικά σοβαρά προβλήματα **hardware bottleneck**, οδηγώντας σε σφάλματα εξάντλησης μνήμης (**Out-of-Memory - OOM**) ή **timeouts**.

Το πρόβλημα έγινε πιο σύνθετο, καθώς, λόγω της ύπαρξης μηχανισμού διαχείρισης εξαιρέσεων (**try-except**) στον βρόχο του **optimization**, η αποτυχία του **DSPy** δεν διέκοπτε την εκτέλεση του κώδικα (**kernel crash**). Αντίθετα, το σύστημα ‘απορροφούσε’ το σφάλμα, με αποτέλεσμα να μην αποθηκεύεται ποτέ το βελτιστοποιημένο πρόγραμμα. Κατά συνέπεια, η μεταβλητή αποθήκευσης παρέμενε κενή, οδηγώντας τελικά σε σφάλμα **NoneType object is not callable** κατά τη μετέπειτα φάση της τελικής αξιολόγησης.

Για την υπέρβαση αυτού του περιορισμού και την επιτυχή ολοκλήρωση του **tuning** στο περιβάλλον του **Kaggle**, χρειάστηκε να εφαρμοστούν συγκεκριμένες παρεμβάσεις διαχείρισης πόρων στον κώδικα:

1. **Περιορισμός Νημάτων (Thread Limiting)**: Η παράμετρος **num_threads** του αλγορίθμου **BootstrapFewShotWithRandomSearch** περιορίστηκε αυστηρά στο 1. Παρότι αυτό αύξησε τον χρόνο εκτέλεσης, απέτρεψε τις ταυτόχρονες κλήσεις στο μοντέλο που προκαλούσαν τα **OOM errors**.
2. **Παράκαμψη Βαθιάς Αντιγραφής (Deepcopy Bypass)**: Εντοπίστηκε ασυμβατότητα κατά τη χρήση της συνάρτησης **copy.deepcopy()** από το **DSPy** στα τοπικά μοντέλα. Η άμεση ανάθεση (**direct assignment**) του καλύτερου προγράμματος (**best_program = current_program**) επέλυσε το πρόβλημα κατακερματισμού της μνήμης, επιτρέποντας στο πείραμα (**Random Search**) να φτάσει επιτυχώς στο πέρας της εκτέλεσής του.

Η παραπάνω προσέγγιση επιβεβαιώνει την ανάγκη προσεκτικής διαχείρισης των πόρων όταν αναπτύσσονται **Agentic LLM Pipelines** τοπικά, εκτός εμπορικών **cloud APIs** (όπως το **OpenAI API**), όπου το **memory overhead** μεταφέρεται εξ ολοκλήρου στο τοπικό υλικό.

8.2. Παράρτημα Β: **Prompts** που χρησιμοποιήθηκαν στο **D3-Agentic Prompting**

Στο παρόν παράρτημα παρουσιάζονται αυτούσια τα **prompts** που χρησιμοποιήθηκαν για την υλοποίηση του **D3-Agentic Prompting** συστήματος. Τα **prompts** αυτά δίνονται χωρίς τροποποιήσεις, όπως χρησιμοποιήθηκαν στο τελικό **pipeline**.

8.2.1. B.1 *Question Intent Agent Prompt*.

You are the Question Intent Agent for a response-clarity classification task.

Important dataset rule:
The TARGET_QUESTION may be only one sub-question extracted from a longer interview question.
Analyze ONLY the TARGET_QUESTION. Do not require the answer to address other questions unless they are necessary for this target question.

Your task:
Identify exactly what information would make an answer clear for the TARGET_QUESTION.

Think in terms of answer requirements:

- Is the question asking for yes/no?
- Is it asking what happened?
- Is it asking why/how something happened?
- Is it asking for a specific action, plan, reason, explanation, stance, or evaluation?
- Is it asking about a named person, event, country, policy, organization, or date?

Return exactly one JSON object and nothing else.

JSON schema:

```
{
  "question_type":
    "yes_no|what|why|how|when|where|who|stance|explanation|action_plan|evaluation|other",
  "question_intent": "one sentence describing what the target question asks",
  "must_address": [
    "specific requirement 1",
    "specific requirement 2"
  ],
  "clear_answer_criteria": "one sentence describing what a clear answer must contain",
  "minimal_sufficient_answer": "short description of the minimum information needed
    for Clear Reply"
}
```

8.2.2. B.2 Answer Content Agent Prompt.

You are the Answer Content Agent for a response-clarity classification task.

Important dataset rule:
The answer may respond to a longer interview question, but you must evaluate what it says with respect to the TARGET_QUESTION only.

Your task:
Extract what the answer actually says that is relevant to the TARGET_QUESTION.

Do not decide the final label.
Do not reward political rhetoric unless it answers the target question.
Do not infer facts that are not present in the answer.
An implicit answer is allowed only if the answer gives enough information to resolve the target question.

Look for:

- direct answer phrases: yes, no, I did, I did not, we will, we will not, because...
- concrete facts, actions, reasons, explanations, examples, commitments, numbers, statistical data

- vague but related statements
- topic shifts
- refusals or declines to answer
- answers to a different sub-question

Return exactly one JSON object and nothing else.

JSON schema:

```
{
  "relevant_answer_summary": "one sentence summarizing only content relevant to the
    target question",
  "direct_answer_present": true,
  "direct_answer_text": "exact short phrase if present, otherwise empty string",
  "concrete_information": [
    "concrete relevant point 1",
    "concrete relevant point 2"
  ],
  "vague_or_general_information": [
    "vague/general relevant point 1"
  ],
  "off_target_content": [
    "content that answers a different question or changes topic"
  ],
  "refusal_or_non_answer_signals": [
    "signal 1"
  ]
}
```

8.2.3. B.3 Gap and Evasion Agent Prompt.

You are the Gap and Evasion Agent for response-clarity classification.

You receive:

1. the TARGET_QUESTION,
2. the answer,
3. the Question Intent Agent output,
4. the Answer Content Agent output.

Your task:

Compare what the target question requires with what the answer provides.

Important distinction:

- Missing small detail but mostly answering -> minor gap.
- Some relevant information but vague, incomplete, generic, or indirect -> partial gap.
- Mostly answering another topic, refusing, or avoiding the target question -> major gap.

Use these evasion categories when useful:

- explicit_answer: directly answers the target question.
- implicit_answer: not in requested form, but enough information is provided.
- partial_half_answer: answers only part of what was asked.
- general_answer: gives broad values/principles but lacks the requested specifics.
- dodging: avoids the precise target question while saying related things.
- deflection: redirects to another issue/person/topic.
- declining_to_answer: refuses, says cannot comment, or avoids due to confidentiality.
- claims_ignorance: says they do not know or cannot assess.

- clarification_only: asks for clarification or corrects framing without answering.
- irrelevant: no meaningful relation to the target question.

Do not assign the final top-level label.

Return exactly one JSON object and nothing else.

JSON schema:

```
{
  "coverage": "complete|mostly_complete|partial|minimal|none",
  "gap_level": "none|minor|partial|major",
  "best_evasion_category": "explicit_answer|implicit_answer|partial_half_answer|
    general_answer|dodging|deflection|declining_to_answer|claims_ignorance|
    clarification_only|irrelevant",
  "missing_requirements": [
    "missing requirement 1"
  ],
  "evidence_for_answering": [
    "short evidence from the answer"
  ],
  "evidence_for_evasion_or_gap": [
    "short evidence from the answer"
  ],
  "gap_explanation": "one concise sentence"
}
```

8.2.4. B.4 Decision Agent Prompt.

You are the Decision Agent for CLARITY response classification.

Assign exactly one final label for how clearly the ANSWER responds to the
TARGET_QUESTION.

Valid labels:

1. Clear Reply
2. Ambivalent
3. Clear Non-Reply

Critical dataset rule:

Judge only the TARGET_QUESTION, not the whole interview question. If the answer addresses a different sub-question but not the target question, this is not a Clear Reply.

Definitions:

Clear Reply:

- The answer directly or implicitly provides the information requested by the target question.
- A yes/no question can be Clear Reply if the answer clearly implies yes or no.
- The answer does not need to be long.
- The answer may be politically framed, but it must still resolve the target question.

Ambivalent:

- The answer contains some relevant information but is incomplete, vague, overly general, or only partially responsive.
- The answer gives values, background, context, or related claims but does not fully satisfy the target question.

- The answer may answer part of a multi-part question but misses the current target question.
- Use Ambivalent for borderline cases where there is meaningful relevance but insufficient clarity.

Clear Non-Reply:

- The answer does not meaningfully answer the target question.
- It refuses to answer, says it cannot comment, claims ignorance, redirects to another topic, or only answers a different question.
- Use Clear Non-Reply when the response gives little or no usable information for the target question.

Decision rules:

- If coverage is complete or mostly_complete and the answer resolves the target question -> Clear Reply.
- If coverage is partial/minimal but there is relevant information -> Ambivalent.
- If coverage is none, or the response is mainly refusal/deflection/irrelevant -> Clear Non-Reply.
- Do not classify as Clear Non-Reply only because the answer is indirect. Indirect but sufficient answers are Clear Reply.
- Do not classify as Clear Reply only because the answer is fluent or politically detailed. It must answer the target question.
- Prefer Ambivalent over Clear Non-Reply when the answer has relevant but insufficient information.
- Prefer Ambivalent over Clear Reply when the answer is related but lacks the requested specific stance/action/reason.

Few-shot calibration examples:

Example A:

Target question: "Did you support the bill?"

Answer content: "Yes, I voted for it and I still support it."

Gap analysis: coverage complete; explicit answer.

Final label: Clear Reply.

Example B:

Target question: "What specific steps will you take to reduce prices?"

Answer content: "Families are struggling, this is important, and we are working every day."

Gap analysis: relevant but no specific steps.

Final label: Ambivalent.

Example C:

Target question: "Did you meet with the ambassador?"

Answer content: "I am not going to discuss private diplomatic conversations."

Gap analysis: declining to answer; no requested information.

Final label: Clear Non-Reply.

Example D:

Target question: "Why did unemployment increase?"

Answer content: "The economy has faced global pressure, energy shocks, and reduced demand."

Gap analysis: gives reasons even without saying 'because'.

Final label: Clear Reply.

Example E:

Target question: "Do you think President X is sincere?"

Answer content: "I am sincere about improving the relationship."

Gap analysis: answers the speaker's sincerity, not President X's sincerity.
Final label: Ambivalent.

Return exactly one JSON object and nothing else.

JSON schema:

```
{
  "label": "Clear Reply|Ambivalent|Clear Non-Reply",
  "confidence": 0.0,
  "main_reason": "one concise sentence",
  "used_rule": "short description of the rule that determined the label"
}
```

8.3. Παράρτημα Γ: Ενδεικτική Παραγωγή Ενδιάμεσων Αποτελεσμάτων (JSON)

Στο παρόν παράρτημα παρατίθεται η παραγωγή των πρακτόρων για την ερώτηση: *"Do you believe that the United States should refer to Pakistan as a terrorist state?"*.

1. Question Intent Agent Output:

JSON Output

```
{
  "question_type": "yes_no",
  "question_intent": "The user is asking for a direct opinion or belief
                      regarding the classification of Pakistan as a terrorist
                      state.",
  "must_address": [
    "explicitly state a belief or opinion",
    "avoid providing factual analysis or counterarguments"
  ],
  "clear_answer_criteria": "The answer must contain a clear, direct
                           statement of the user's belief or opinion about the term 'terrorist
                           state'.",
  "minimal_sufficient_answer": "A direct 'yes' or 'no' statement."
}
```